



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Χρήση Μεγάλων Γλωσσικών Μοντέλων στην
Ανίχνευση Κυβερνοεπιθέσεων

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

ΓΕΩΡΓΙΟΥ ΠΑΝΑΓΙΩΤΗ ΒΕΡΓΟΥ

Επιβλέπων: Χρήστος Μακρής

Πάτρα, Σεπτέμβριος 2025



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Χρήση Μεγάλων Γλωσσικών Μοντέλων στην Ανίχνευση Κυβερνοεπιθέσεων

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΓΕΩΡΓΙΟΥ ΠΑΝΑΓΙΩΤΗ ΒΕΡΓΟΥ

Επιβλέπων: Χρήστος Μακρής

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 2η Σεπτεμβρίου 2025.

(Υπογραφή)

(Υπογραφή)

(Υπογραφή)

.....
Χρήστος Μακρής
Αναπληρωτής Καθηγητής

.....
Σπύρος Σιούτας
Καθηγητής

.....
Αριστείδης Ηλίας
ΕΔΙΠ

Πάτρα, Σεπτέμβριος 2025



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ
ΠΛΗΡΟΦΟΡΙΚΗΣ

Copyright ©–All rights reserved Γεώργιος Παναγιώτης Βέργος, 2025.

Με την επιφύλαξη παντός δικαιώματος.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Το περιεχόμενο αυτής της εργασίας δεν απηχεί απαραίτητα τις απόψεις του Τμήματος, του Επιβλέποντα, ή της επιτροπής που την ενέκρινε.

Υπεύθυνη Δήλωση

Βεβαιώνω ότι είμαι συγγραφέας αυτής της πτυχιακής εργασίας, και ότι κάθε βοήθεια την οποία είχα για την προετοιμασία της είναι πλήρως αναγνωρισμένη και αναφέρεται στην πτυχιακή εργασία. Επίσης έχω αναφέρει τις όποιες πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών ή λέξεων, είτε αυτές αναφέρονται ακριβώς είτε παραφρασμένες. Επίσης, βεβαιώνω ότι αυτή η πτυχιακή εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για τις απαιτήσεις του προγράμματος σπουδών του τμήματος Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής του Πανεπιστημίου Πατρών.

(Υπογραφή)

.....
Γεώργιος Παναγιώτης Βέργος

Περίληψη

Η κυβερνοασφάλεια αποτελεί έναν από τους κλάδους της επιστήμης των υπολογιστών με τη μεγαλύτερη άνθιση τα τελευταία χρόνια, από την αυξανόμενη ανάγκη προστασίας των συστημάτων από επιθέσεις. Ταυτόχρονα, η εξέλιξη κλάδων όπως η τεχνητή νοημοσύνη έχει διαμορφώσει αναλόγως την κυβερνοασφάλεια, όπου χρησιμοποιείται τόσο στην αντιμετώπιση των επιθέσεων όσο και στην δημιουργία νέων.

Σε αυτή την διπλωματική εργασία μελετάται η εφαρμογή καινοτόμων τεχνικών βαθιάς μάθησης και συγκεκριμένα Μεγάλων Γλωσσικών Μοντέλων επάνω σε προβλήματα κυβερνοασφάλειας. Συγκεκριμένα, μελετούνται δύο κλασσικά προβλήματα κυβερνοασφάλειας και προτείνεται μία διαφορετική προσέγγιση στην προεπεξεργασία των ροών δικτυακών πακέτων και ο συνδυασμός της με σύγχρονα Γλωσσικά Μοντέλα. Ακόμη, προτείνονται δύο σύγχρονες τροποποιήσεις στην αρχιτεκτονική των μοντέλων προκειμένου να επιλυθούν κάποια προβλήματα αποδοτικότητας που είναι κοινά στα Μεγάλα Γλωσσικά Μοντέλα.

Στο πρώτο πρόβλημα πραγματοποιείται πειραματική σύγκριση διάφορων Μεγάλων Γλωσσικών Μοντέλων ως προς την ικανότητα τους να επιλύουν το συγκεκριμένο πρόβλημα. Στο δεύτερο πρόβλημα κυβερνοασφάλειας, αξιολογείται και συγκρίνεται πειραματικά το προτεινόμενο μοντέλο με την διαφορετική προσέγγιση με κλασσικά μοντέλα μηχανικής μάθησης δηλαδή με μοντέλα που λαμβάνουν ως είσοδο ροές δικτυακών πακέτων.

Λέξεις Κλειδιά

Μετασχηματιστές, Κυβερνοεπιθέσεις, Ανίχνευση Ανωμαλιών, Μεγάλα Γλωσσικά Μοντέλα, BERT, Αρχεία Καταγραφής

Abstract

Cybersecurity is a sector of computer science with the biggest growth in recent years, due to the increasing need of protecting computer systems from attacks. Simultaneously, the evolution of branches of computer science such as artificial intelligence, has shaped cybersecurity accordingly, where it is utilized both for defending against attacks but also for creating new ones.

This thesis, examines applications of modern deep learning techniques and especially Large Language Models in cybersecurity problems. Specifically, this work focuses on two common cybersecurity problems and a new approach in network packet flow preprocessing alongside its combination with Large Language Models is proposed. Additionally, two modern modifications in the proposed model's architecture are suggested in order to address efficiency issues shared by Large Language Models.

In the first problem an experimental comparison of different Language Models is conducted, related to their ability to solve this specific problem. In the second cybersecurity problem, the proposed model with the proposed approach is evaluated and compared experimentally with classic machine learning algorithms that use network packet flows as their inputs.

Keywords

Transformers, Cyberattacks, Anomaly Detection, Large Language Models, BERT, Log Files

στην οικογένεια μου

Ευχαριστίες

Θα ήθελα καταρχήν να ευχαριστήσω τον αναπληρωτή καθηγητή κ. Μακρή για την επίβλεψη αυτής της διπλωματικής εργασίας και για την πολύτιμη βοήθεια που μου προσέφερε κατά την εκπόνηση της. Επίσης ευχαριστώ ιδιαίτερα τους Δρ. Σιούτα και κ. Ηλία για την καθοδήγησή τους και την εξαιρετική συνεργασία που είχαμε. Ακόμη ευχαριστώ θερμά τον υποψήφιο διδάκτορα κ. Καπαδούκα για το πολύτιμο επικουρικό του έργο στην εκπόνηση αυτής της διπλωματικής. Τέλος θα ήθελα να ευχαριστήσω την οικογένεια μου για την καθοδήγηση και την ηθική συμπαράσταση που μου προσέφερε όλα αυτά τα χρόνια.

Περιεχόμενα

Περίληψη	i
Abstract	iii
Ευχαριστίες	vii
Περιεχόμενα	xi
Κατάλογος Σχημάτων	xiii
Κατάλογος Πινάκων	xvi
1 Εισαγωγή	1
1.1 Σημασία του Προβλήματος	1
1.2 Στόχοι της Διπλωματικής Εργασίας	1
1.3 Διάρθρωση της Διπλωματικής Εργασίας	2
2 Θεωρητικό Υπόβαθρο Κυβερνοεπιθέσεων και Ανίχνευσης Ανωμαλιών	3
2.1 Θεωρητικό Υπόβαθρο Ανίχνευσης Ανωμαλιών	3
2.1.1 Κατηγορίες Ανίχνευσης Ανωμαλιών	3
2.1.2 Αλγόριθμοι Ανίχνευσης Ανωμαλιών	4
2.2 Θεωρητικό Υπόβαθρο Κυβερνοεπιθέσεων	5
2.2.1 Κατηγορίες Κυβερνοεπιθέσεων	5
2.2.2 Είδη Κυβερνοεπιθέσεων	6
3 Θεωρητικό Υπόβαθρο Μάθησης και Γλωσσικών Μοντέλων	9
3.0.1 Κατηγορίες Μάθησης	9
3.0.2 Αλγόριθμοι Μάθησης	10
4 Αρχιτεκτονική Προτεινόμενων Μοντέλων	21
4.1 Αρχιτεκτονική Μοντέλου Ανίχνευσης Ανωμαλιών σε Αρχεία Καταγραφής Εφαρμογής	21

4.2	Αρχιτεκτονική Προτεινόμενου Μοντέλου Κατηγοριοποίησης Ροών Δικτυακών Πακέτων	24
4.3	Αρχιτεκτονική Μοντέλων Βασισμένων σε Ροές	27
4.4	Σχεδιαστικές Αποφάσεις	27
4.4.1	Μεγάλος Όγκος Δεδομένων	27
4.4.2	Ανισορροπία Κλάσεων	28
5	Υλοποίηση Προτεινόμενων Μοντέλων	31
5.1	Φύση Δεδομένων	31
5.1.1	Αρχεία Καταγραφής Εφαρμογών	31
5.1.2	Ροές Δικτυακών Πακέτων	32
5.2	Λεπτομέρειες Υλοποίησης	33
5.2.1	Περιβάλλον Υλοποίησης	33
5.2.2	Σύνολα Δεδομένων	34
5.2.3	Σύνολα Δεδομένων για Κατηγοριοποίηση Ροών Δικτυακών Πακέτων	36
6	Ανάλυση Απόδοσης Μοντέλων	39
6.1	Μετρικές Αξιολόγησης Μοντέλων Μηχανικής Μάθησης	39
6.2	Τεχνικές Αξιολόγησης	42
6.3	Αποτελέσματα	43
6.3.1	Διαδική Κατηγοριοποίηση στο HDFS _{v1} Σύνολο Δεδομένων	43
6.3.2	Διαδική Κατηγοριοποίηση στο Edge-IoTset Σύνολο Δεδομένων	44
6.3.3	Πολυταξική Κατηγοριοποίηση στο Edge-IoTset Σύνολο Δεδομένων	44
6.3.4	Διαδική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων	46
6.3.5	Πολυταξική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων	47
7	Εξηγήσιμη Τεχνητή Νοημοσύνη	49
7.1	Θεωρητικό Υπόβαθρο Εξηγήσιμης Τεχνητής Νοημοσύνης	49
7.1.1	Κατηγορίες Τεχνικών Εξηγήσιμης Τεχνητής Νοημοσύνης	49
7.1.2	Τεχνικές Εξηγήσιμης Τεχνητής Νοημοσύνης	50
7.2	Μετρικές Αξιολόγησης Τεχνικών Εξηγήσιμης Τεχνητής Νοημοσύνης	52
7.2.1	Sensitivity	52
7.2.2	Infidelity	52
7.2.3	Faithfulness	53
7.2.4	Αποτελέσματα Μετρικών Εξηγησιμότητας	54
8	Σχετικές Εργασίες και Μελέτη Βιβλιογραφίας	59
8.1	Σχετικές Εργασίες για Ανίχνευση Ανωμαλιών Σε Αρχεία Καταγραφής Εφαρμογών	59
8.2	Σχετικές Εργασίες σε Άλλα Σύνολα Δεδομένων	61
8.3	Σχετικές Εργασίες για Κατηγοριοποίηση Ροών Δικτυακών Πακέτων	62

9	Επίλογος	69
9.1	Συμπεράσματα για Ανίχνευση Ανωμαλιών σε Αρχεία Καταγραφής Εφαρμογών	69
9.2	Συμπεράσματα για Κατηγοριοποίηση Ροών Δικτυακών Πακέτων	69
9.2.1	Δυαδική Κατηγοριοποίηση	69
9.2.2	Πολυταξική Κατηγοριοποίηση	70
9.3	Συμπεράσματα Τεχνικών Εξηγήσιμης Τεχνητής Νοημοσύνης	70
9.4	Προτάσεις για Μελλοντική Έρευνα και Πιθανές Επεκτάσεις	71
A'	Διαγράμματα Σύγχυσης Αποτελεσμάτων Γλωσσικών Μοντέλων	73
A'.1	Δυαδική Κατηγοριοποίηση στο HDFS Σύνολο Δεδομένων	74
A'.2	Δυαδική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων	78
A'.3	Δυαδική Κατηγοριοποίηση στο Edge-IIoTset Σύνολο Δεδομένων	79
A'.4	Πολυταξική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων	80
A'.5	Πολυταξική Κατηγοριοποίηση στο Edge-IIoTset Σύνολο Δεδομένων	81
B'	Πειραματικές Λεπτομέρειες	83
B'.1	Παράμετροι Γλωσσικών Μοντέλων ανά Πρόβλημα	83
B'.2	Πηγαίος Κώδικας	84

Κατάλογος Σχημάτων

3.1	Πολυεπίπεδο Αντίληπτρο	11
3.2	Αρχιτεκτονική Μετασχηματιστή	14
3.3	Παράδειγμα Ενσωματώσεων για ένα Κείμενο	17
3.4	Αρχιτεκτονική του BERT	18
4.1	Ροή Εργασιών Μοντέλου Ανίχνευσης Ανωμαλιών σε Αρχεία Καταγραφής	23
4.2	Παράδειγμα Ροής Κωδικοποιημένης σε Κείμενο	25
4.3	Ροή Εργασιών Προτεινόμενου Μοντέλου	26
4.4	Εκπαίδευση με LoRa	28
5.1	Αρχείο Καταγραφής στο Λειτουργικό Σύστημα Linux	32
5.2	Αρχείο Καταγραφής στο Λειτουργικό Σύστημα Android	32
5.3	Παράδειγμα Ροής Δικτυακών Πακέτων	32
5.4	Διάνυσμα στο HDFS	35
6.1	Μητρώο Σύγχυσης	41
6.2	Διάσπαση σε Υποσύνολα Εκπαίδευσης, Επικύρωσης και Ελέγχου	42
A'.1	Μητρώο Σύγχυσης για το DistilBERT	74
A'.2	Μητρώο Σύγχυσης για το ALBERT	75
A'.3	Μητρώο Σύγχυσης για το BERT	76
A'.4	Μητρώο Σύγχυσης για το RoBERTa	77
A'.5	Μητρώο Σύγχυσης για το DistilBERT	78
A'.6	Μητρώο Σύγχυσης για το DistilBERT	79
A'.7	Μητρώο Σύγχυσης για το DistilBERT	80
A'.8	Μητρώο Σύγχυσης για το DistilBERT	81

Κατάλογος Πινάκων

5.1	Κατηγορίες Εγγραφών στο HDFS_v1 Σύνολο Δεδομένων	35
5.2	Κατηγορίες Επιθέσεων στο IoT-23	36
5.3	Κατηγορίες και Είδη Επιθέσεων στο Edge-IoTset	37
6.1	Διαδική Κατηγοριοποίηση στο HDFS Σύνολο Δεδομένων	43
6.2	Διαδική Κατηγοριοποίηση στο Edge-IoTset Σύνολο Δεδομένων	44
6.3	Μετρικές για την Κλάση Benign	44
6.4	Μετρικές για την Κλάση DDoS	45
6.5	Μετρικές για την Κλάση Injection	45
6.6	Μετρικές για την Κλάση Malware	45
6.7	Μετρικές για την Κλάση Information Gathering	45
6.8	Διαδική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων	46
6.9	Μετρικές για την Κλάση Benign	47
6.10	Μετρικές για την Κλάση DDoS	47
6.11	Μετρικές για την Κλάση Okiru	47
6.12	Μετρικές για την Κλάση PartOfAHorizontalPortScan	48
6.13	Μετρικές για την Κλάση C&C (Command and Control)	48
7.1	Αποτελέσματα Διαδικού Μοντέλου DistilBERT στο HDFS Σύνολο Δεδομένων.	54
7.2	Αποτελέσματα Διαδικού Μοντέλου ALBERT στο HDFS Σύνολο Δεδομένων	55
7.3	Αποτελέσματα Διαδικού Μοντέλου BERT στο HDFS Σύνολο Δεδομένων	55
7.4	Αποτελέσματα Διαδικού Μοντέλου RoBERTa στο HDFS Σύνολο Δεδομένων	55
7.5	Αποτελέσματα Διαδικού Μοντέλου στο IoT-23 Σύνολο Δεδομένων	56
7.6	Αποτελέσματα Πολυταξικού Μοντέλου στο IoT-23 Σύνολο Δεδομένων	56
7.7	Αποτελέσματα Διαδικού Μοντέλου στο Edge-IoTset Σύνολο Δεδομένων	57
7.8	Αποτελέσματα Πολυταξικού Μοντέλου στο Edge-IoTset Σύνολο Δεδομένων	57
8.1	Διαδική Κατηγοριοποίηση του Μοντέλου LogFiT των Crispin Almodovar et al. [4] στο HDFS Σύνολο Δεδομένων	60
8.2	Αποτελέσματα Προτεινόμενου Μοντέλου στο HDFS Σύνολο Δεδομένων, Yihan Zhou et al. [69]	60
8.3	Αποτελέσματα Μοντέλου LogST [68] στο HDFS (Mingyang Zhang et al.)	61

8.4	Αποτελέσματα των Καλύτερων ML και DL Μοντέλων στην Πολυταξική Κατηγοριοποίηση του Συνδυαστικού Συνόλου Δεδομένων A. Alzu'bi et al. [5]	62
8.5	Διαδική Κατηγοριοποίηση Προτεινόμενων Μοντέλων στο IoT-23 Σύνολο Δεδομένων (Alia Ahli et al.) [3]	62
8.6	Πολυταξική Κατηγοριοποίηση Προτεινόμενων Μοντέλων στο IoT-23 Σύνολο Δεδομένων (Alia Ahli et al.) [3]	63
8.7	Πολυταξική Κατηγοριοποίηση του Μοντέλου AAE-KNN στο IoT-23 Σύνολο Δεδομένων [2] (Nada Abdalgawa et al.)	63
8.8	Πολυταξική Κατηγοριοποίηση του Μοντέλου BiGAN-KNN στο IoT-23 Σύνολο Δεδομένων [2] (Nada Abdalgawa et al.)	64
8.9	Πολυταξική Κατηγοριοποίηση του Μοντέλου securityBERT (Mohamed Amine Ferrag et al.) στο Edge-IIoTset Σύνολο Δεδομένων [21]	65
8.10	Διαδική Κατηγοριοποίηση στο Edge-IIoTset (Mohamed Amine Ferrag, Othmane Friha et al.) [20]	66
8.11	Μετρικές για την Κλάση Benign [20]	66
8.12	Μετρικές για την Κλάση DDoS [20]	66
8.13	Μετρικές για την Κλάση Injection [20]	67
8.14	Μετρικές για την Κλάση Malware [20]	67
8.15	Μετρικές για την Κλάση Information Gathering [20]	67
B.1	Παράμετροι Γλωσσικών Μοντέλων	83

Κεφάλαιο 1

Εισαγωγή

1.1 Σημασία του Προβλήματος

Η εξέλιξη της τεχνολογίας και της πληροφορικής έχει οδηγήσει στη δημιουργία υπηρεσιών που βελτιώνουν την ποιότητα ζωής του ανθρώπου και διευκολύνουν τις καθημερινές του συναλλαγές. Επιχειρήσεις, οργανισμοί και κυβερνήσεις έχουν ψηφιοποιήσει τις υπηρεσίες τους μέσω συστημάτων που εκτελούν πολλές εφαρμογές και πρωτόκολλα, διασυνδεδεμένα μεταξύ τους με πολλά δίκτυα να παρεμβάλλονται ανάμεσά τους. Ως εκ τούτου, είναι ευάλωτα σε κακόβουλους χρήστες οι οποίοι εκπονούν επιθέσεις εις βάρος τους προκειμένου να κλέψουν ευαίσθητες πληροφορίες, να προκαλέσουν οικονομική ζημιά στις επιχειρήσεις τους και να αποκομίσουν οι ίδιοι κέρδη από αυτές.

Ακόμη, όσο προοδεύει η τεχνολογία τόσο βελτιώνονται και οι επιθέσεις που δέχονται τα συστήματα αυτά είτε ως προς την πολυπλοκότητα και το μέγεθος τους είτε ως προς τους τρόπους και το μέγεθος της ζημιάς που μπορούν να προκαλέσουν. Ταυτόχρονα, η εξέλιξη της τεχνητής νοημοσύνης έχει επιτρέψει την αξιοποίηση της σε συστήματα αντιμετώπισης κυβερνοεπιθέσεων. Ιδιαίτερα, χρησιμοποιούνται τεχνικές μηχανικής μάθησης στον εντοπισμό κακόβουλων δικτυακών πακέτων και σε συστήματα εντοπισμού εισβολών.

Συγχρόνως, τα Μεγάλα Γλωσσικά Μοντέλα αποτελούν έναν καινοτόμο κλάδο της τεχνητής νοημοσύνης με εφαρμογή σε πολλούς τομείς όπως η επεξεργασία φυσικής γλώσσας, η επεξεργασία εικόνας. Ως μοντέλα βαθιάς μάθησης έχουν αρκετές προοπτικές στην κυβερνοασφάλεια, ιδιαίτερα σε περιπτώσεις όπου τα χειριζόμενα δεδομένα είναι κειμενικά.

1.2 Στόχοι της Διπλωματικής Εργασίας

Στόχος αυτής της εργασίας είναι η πειραματική μελέτη και αξιοποίηση Μεγάλων Γλωσσικών Μοντέλων (Large Language Models) επάνω σε ζητήματα κυβερνοασφάλειας. Κατασκευάζονται σύγχρονα μοντέλα μηχανικής μάθησης και συγκρίνεται η απόδοσή τους πειραματικά με Μεγάλα Γλωσσικά Μοντέλα. Η αξιολόγηση αυτή τελείται επάνω σε δύο ξεχωριστά προβλήματα της κυβερνοασφάλειας σε διάφορα σύνολα δεδομένων.

1.3 Διάρθρωση της Διπλωματικής Εργασίας

Στο κεφάλαιο 2 γίνεται μία εισαγωγή στην ανίχνευση ανωμαλιών καθώς και σε θέματα κυβερνοεπιθέσεων. Παρουσιάζονται οι βασικές κατηγορίες ανίχνευσης ανωμαλιών καθώς και η σχέση της με την κυβερνοασφάλεια. Έπειτα, αναλύονται κάποιες κατηγορίες και είδη κυβερνοεπιθέσεων με έμφαση σε αυτές που πραγματεύονται τα σύνολα δεδομένων που χρησιμοποιήθηκαν σε αυτήν την διπλωματική εργασία. Ακολούθως, στο κεφάλαιο 3, αναλύονται οι βασικές κατηγορίες μηχανικής μάθησης και περιγράφεται αναλυτικά το θεωρητικό υπόβαθρο των αλγόριθμων που υλοποιήθηκαν.

Έπειτα στο κεφάλαιο 4 αναλύεται η αρχιτεκτονική κάθε μοντέλου που υλοποιήθηκε στο πλαίσιο αυτής της εργασίας. Συγκεκριμένα, παρουσιάζεται η αρχιτεκτονική και οι υλοποιητικές λεπτομέρειες των κλασικών μοντέλων που βασίζονται σε ροές δικτυακών πακέτων, του προτεινόμενου μοντέλου για την ανίχνευση κυβερνοεπιθέσεων καθώς και του μοντέλου για την ανίχνευση ανωμαλιών σε αρχεία καταγραφής.

Στο κεφάλαιο 5 περιγράφεται το περιβάλλον υλοποίησης, παρέχονται πληροφορίες για τη φύση των δεδομένων που πραγματεύεται κάθε πρόβλημα και παρουσιάζονται τα σύνολα δεδομένων στα οποία αξιολογήθηκαν όλα τα μοντέλα της εργασίας καθώς και κάποιες σχεδιαστικές αποφάσεις.

Στη συνέχεια, στο κεφάλαιο 6 καλύπτονται οι μετρικές αξιολόγησης των μοντέλων που υλοποιήθηκαν όπως και οι τεχνικές αξιολόγησης του κύριου γλωσσικού μοντέλου που πραγματεύεται αυτή η εργασία. Ακόμη, παρουσιάζονται τα πειραματικά αποτελέσματα όλων των μοντέλων σε κάθε σύνολο δεδομένων χρησιμοποιώντας τις παραπάνω μετρικές.

Ακολούθως, στο κεφάλαιο 7 παρουσιάζεται το θεωρητικό υπόβαθρο της εξήγησιμης τεχνητής νοημοσύνης, των βασικών τεχνικών που θα χρησιμοποιηθούν για την εξήγηση των προβλέψεων του κύριου γλωσσικού μοντέλου της εργασίας, οι μετρικές αξιολόγησης αυτών των τεχνικών καθώς και τα αποτελέσματα αυτών των τεχνικών επάνω στο κύριο μοντέλο με βάση τις παραπάνω μετρικές.

Στο κεφάλαιο 8 γίνεται μία μελέτη της βιβλιογραφίας στα δύο προβλήματα κυβερνοασφάλειας που πραγματεύεται η διπλωματική, κυρίως στα σύνολα δεδομένων που μελετούνται στο κεφάλαιο 5.

Τέλος στο κεφάλαιο 9, επισημαίνονται τα συμπεράσματα που προέκυψαν από τα πειράματα αυτής της εργασίας. Αρχικά, παρουσιάζονται τα συμπεράσματα σε τεχνικό επίπεδο για κάθε σύνολο δεδομένων και έπειτα για τη γενική ικανότητα των προτεινόμενων μοντέλων να επιλύουν τα δύο κύρια προβλήματα της εργασίας. Ταυτοχρόνως, προτείνονται τρόποι με τους οποίους θα μπορούσαν να βελτιωθούν τα προτεινόμενα μοντέλα τόσο στην απόδοση όσο και στην υπολογιστική ταχύτητα ενώ προτείνεται η μελλοντική μελέτη παραπλήσιων μοντέλων στα ίδια προβλήματα.

Κεφάλαιο 2

Θεωρητικό Υπόβαθρο Κυβερνοεπιθέσεων και Ανίχνευσης Ανωμαλιών

Σε αυτό το κεφάλαιο παρουσιάζεται το θεωρητικό υπόβαθρο των τομέων της κυβερνοασφάλειας που πραγματεύεται αυτή η διπλωματική εργασία. Αρχικά, γίνεται αναφορά στις υπάρχουσες κατηγορίες κυβερνοεπιθέσεων και ανίχνευσης ανωμαλιών. Μελετώνται γνωστές τεχνικές ανίχνευσης ανωμαλιών και έπειτα παρουσιάζονται αναλυτικά διάφορα είδη επιθέσεων που μελετώνται στα μετέπειτα πειράματα.

2.1 Θεωρητικό Υπόβαθρο Ανίχνευσης Ανωμαλιών

Η Ανίχνευση Ανωμαλιών (Anomaly Detection) στοχεύει στον εντοπισμό συμπεριφορών, μοτίβων και στην περίπτωση της ανάλυσης δεδομένων σε δεδομένα που διαφοροποιούνται σημαντικά από την πλειοψηφία των δεδομένων τα οποία εμφανίζουν μία κοινότυπη συμπεριφορά. Η ανίχνευση ανωμαλιών εφαρμόζεται σε πολλά πεδία όπως η κυβερνοασφάλεια, η όραση υπολογιστών και τα οικονομικά. Στο πλαίσιο αυτής της εργασίας μελετάται η ανίχνευση ανωμαλιών σε αρχεία καταγραφής εφαρμογών και σε ροές δικτυακών πακέτων.

2.1.1 Κατηγορίες Ανίχνευσης Ανωμαλιών

Η ανίχνευση ανωμαλιών διακρίνεται σε πολλές κατηγορίες ανάλογα τις τεχνικές. Ωστόσο, επειδή αυτή η διπλωματική εργασία μελετά την ανίχνευση ανωμαλιών μέσω εφαρμογής γλωσσικών μοντέλων επάνω σε αρχεία καταγραφής, επί το πλείστον αναφέρονται οι κατηγορίες ανίχνευσης ανωμαλιών που χρησιμοποιούν μηχανική μάθηση. Στις τεχνικές των υπόλοιπων κατηγοριών γίνεται μία σύντομη αναφορά.

Επιβλεπόμενη Ανίχνευση Ανωμαλιών

Η Επιβλεπόμενη Ανίχνευση Ανωμαλιών (Supervised Anomaly Detection) είναι ένα είδος ανίχνευσης ανωμαλιών, στο οποίο ο αλγόριθμος απαιτεί εκπαίδευση με χαρακτηρισμένα δεδομένα ως κανονικά και μη κανονικά (ανωμαλίες). Κατά την εκπαίδευση του ο αλγόριθμος συσχετίζει τάσεις και μοτίβα στα δεδομένα με την έξοδο που του παρέχει ο άνθρωπος. Είναι και η μέθοδος που θα μελετηθεί στο πλαίσιο αυτής της διπλωματικής εργασίας.

Μη Επιβλεπόμενη Ανίχνευση Ανωμαλιών

Στην Μη επιβλεπόμενη Ανίχνευση Ανωμαλιών (Unsupervised Anomaly Detection), δεν υπάρχει χαρακτηρισμός των δεδομένων ως κανονικά και μη κανονικά. Εδώ ο αλγόριθμος ανακαλύπτει συσχετίσεις μεταξύ των δεδομένων καθώς και μοτίβα που αποκλίνουν από την κανονική συμπεριφορά χωρίς ανθρώπινη επίβλεψη. Λόγω της έλλειψης χαρακτηρισμένων δεδομένων καθώς και της δυσκολίας χαρακτηρισμού τους, αποτελεί την πιο συχνή κατηγορία αλγορίθμων ανίχνευσης ανωμαλιών.

Ημιεπιβλεπόμενη Ανίχνευση Ανωμαλιών

Στην Ημιεπιβλεπόμενη Ανίχνευση Ανωμαλιών (Semi-Supervised Anomaly Detection) ο αλγόριθμος ανίχνευσης ανωμαλιών εκπαιδεύεται αρχικά με ένα μικρό σύνολο χαρακτηρισμένων δεδομένων και χρησιμοποιεί την πληροφορία που αποκόμισε από αυτά τα δεδομένα για να χαρακτηρίσει νέα μη χαρακτηρισμένα. Έπειτα, χρησιμοποιεί τα νέα χαρακτηρισμένα δεδομένα καθώς και τα αρχικά για να εξειδικευτεί περισσότερο. Συνήθως όμως, σε αυτό το είδος ανίχνευσης ανωμαλιών ένα μοντέλο εκπαιδεύεται σε κανονικά δεδομένα και έπειτα κατά την πρόβλεψη νέων δειγμάτων, αν κάποιο δείγμα παρεκκλίνει αρκετά από την κανονική συμπεριφορά που έχει μάθει ο αλγόριθμος κατά την εκπαίδευση τότε χαρακτηρίζεται ως ανωμαλία.

2.1.2 Αλγόριθμοι Ανίχνευσης Ανωμαλιών

Αλγόριθμοι Ανίχνευσης Ανωμαλιών που Βασίζονται σε Μηχανική Μάθηση

Αλγόριθμοι ανίχνευσης ανωμαλιών που χρησιμοποιούν τεχνικές μηχανικής μάθησης διακρίνονται σε πολλά είδη, ανάλογα την κατηγορία μάθησης στην οποία εμπίπτουν. Αλγόριθμοι επιβλεπόμενης ανίχνευσης ανωμαλιών αποτελούν μεταξύ άλλων οι Μηχανές Διανυσμάτων Υποστήριξης (Support Vector Machines) [15], τα Τεχνητά Νευρωνικά Δίκτυα [53], τα Δέντρα Αποφάσεων [11] και οι Κ-Πλησιέστεροι Γείτονες [22]. Μη επιβλεπόμενοι αλγόριθμοι ανίχνευσης ανωμαλιών περιλαμβάνουν αλγόριθμους συσταδοποίησης, κανόνων συσχετίσεων αλλά και δομές όπως οι Αυτοκωδικοποιητές [53]. Επίσης σε αυτούς περιλαμβάνονται το Απομονωμένο Δάσος (Isolation Forest) [38] και η Μηχανή Διανυσμάτων Υποστήριξης μίας Κλάσης (One Class Support Vector Machine) [55].

Αλγόριθμοι Ανίχνευσης Ανωμαλιών Βασιζόμενοι στην Στατιστική

Εκτός από αλγορίθμους ανίχνευσης ανωμαλιών που χρησιμοποιούν τεχνικές μάθησης για να προσδιορίσουν τις ανωμαλίες, υπάρχουν και απλούστερες μέθοδοι οι οποίες εντοπίζουν τις ανωμαλίες χρησιμοποιώντας τις στατιστικές ιδιότητες των δεδομένων που μελετούν. Τέτοιες μέθοδοι, αποτελούν η οπτικοποίηση των δεδομένων μέσω διαγραμμάτων όπου κάποιος μπορεί να παρατηρήσει εάν κάποιο δείγμα αποκλίνει σημαντικά από τα υπόλοιπα και στατιστικοί έλεγχοι όπως ο έλεγχος Grubbs [26], η βαθμολογία Z.

2.2 Θεωρητικό Υπόβαθρο Κυβερνοεπιθέσεων

2.2.1 Κατηγορίες Κυβερνοεπιθέσεων

Επιθέσεις Άρνησης Υπηρεσιών

Οι Επιθέσεις Άρνησης Υπηρεσιών (Denial Of Service Attacks) [58, p. 241] είναι μία κατηγορία κυβερνοεπιθέσεων, κατά τις οποίες ο επιτιθέμενος προσπαθεί να καταστήσει έναν εξυπηρετητή ή ένα δίκτυο, μη διαθέσιμο προς τους χρήστες του. Αυτό συνήθως το επιτυγχάνει, στέλνοντας έναν τεράστιο αριθμό από ψεύτικα αιτήματα στον εξυπηρετητή-θύμα με στόχο να τον υπερφορτώσει και είτε να σταματήσει να λειτουργεί τελείως ή να μην μπορεί να εξυπηρετήσει τα πραγματικά αιτήματα.

Μία παραλλαγή αυτής της κατηγορίας είναι οι Κατανεμημένες Επιθέσεις Άρνησης Υπηρεσιών (Distributed Denial Of Service Attacks) [58, p. 250], στις οποίες η επίθεση δεν προέρχεται από μία πηγή αλλά ο επιτιθέμενος συντονίζει πολλές διακριτές πηγές οι οποίες τελούν υπό τον έλεγχο του (zombies), να στείλουν ταυτόχρονα τεράστιο αριθμό ψεύτικων αιτημάτων στο θύμα. Αυτές οι επιθέσεις είναι και συνήθως δυσκολότερο να αντιμετωπιστούν αφού ο αμυνόμενος πρέπει να εξουδετερώσει όλες τις πηγές τις επίθεσης αλλά και είναι αδύνατο να ταυτοποιήσει τον επιτιθέμενο. Επίσης, εφόσον η πληροφορία που στέλνουν αυτές οι πηγές είναι πολύ μεγαλύτερη από μία κοινή επίθεση άρνησης υπηρεσιών το θύμα συνήθως καταρρέει γρηγορότερα.

Επιθέσεις Έγχυσης

Οι Επιθέσεις Έγχυσης (Injection Attacks) [58, p. 382] είναι μία κατηγορία κυβερνοεπιθέσεων στις οποίες ο επιτιθέμενος εισάγει κακόβουλο κώδικα σε ένα σύστημα μέσω των δεδομένων κάποιας εφαρμογής προκειμένου να ανακτήσει ευαίσθητες πληροφορίες από αυτό, να προκαλέσει βλάβες και να αποκτήσει εξουσίες επάνω του.

Επιθέσεις Κακόβουλου Λογισμικού

Το Κακόβουλο Λογισμικό (Malware) [58, p. 200] είναι οποιοδήποτε λογισμικό, το οποίο έχει σκοπό να βλάψει ένα υπολογιστικό σύστημα ή δίκτυο. Είναι ένας ευρύς όρος που περιλαμβάνει πολλά είδη λογισμικών με χαρακτηριστικότερα τους Δούρειους Ίππους [58, p. 219]

όπου ο κακόβουλος κώδικας αποτελεί κρυφή λειτουργία ενός φαινομενικά αθώου προγράμματος, τα Λυτρισμικά, τους Ιούς [58, p. 204], τα Σκουλήκια (Worms) [58, p. 210] δηλαδή λογισμικά που αντιγράφουν τον εαυτό τους και μεταδίδονται σε άλλα συστήματα μέσω ενός δικτύου επαναλαμβάνοντας την διαδικασία σε κάθε μολυσμένο σύστημα με στόχο να επιβραδυνθεί πολύ το δίκτυο, το Λογισμικό Κατασκοπείας (Spyware) και τα Rootkits [58, p. 227] δηλαδή λογισμικό το οποίο κρύβει την συμπεριφορά του από τους κανονικούς χρήστες ενός συστήματος παρέχοντας ταυτόχρονα δικαιώματα υπερχρήστη στον επιτιθέμενο.

Επιθέσεις Ενδιάμεσου

Οι Επιθέσεις Ενδιάμεσου (Man In The Middle Attacks) είναι μία κατηγορία επιθέσεων όπου μεταξύ ενός πελάτη και ενός διακομιστή παρεμβάλλεται ο επιτιθέμενος. Ο επιτιθέμενος μπορεί να παρακολουθήσει τις συναλλαγές μεταξύ των δύο αυτών οντοτήτων, να κλέψει πληροφορίες, ή ακόμα και να προσποιηθεί κάποια από αυτές.

Επιθέσεις Συλλογής Πληροφοριών

Οι επιθέσεις Συλλογής Πληροφοριών (Information Gathering) [58, p. 270] είναι επιθέσεις οι οποίες έχουν σκοπό να συλλέξουν πληροφορίες για ένα σύστημα, προκειμένου ο επιτιθέμενος να μάθει προηγουμένως άγνωστες ευπάθειες αυτού. Έπειτα, εκμεταλλευόμενος αυτές τις ευπάθειες μπορεί να επιστρατεύσει άλλα είδη επιθέσεων για να βλάψει περεταίρω το σύστημα. Ακόμη, μπορεί να αποκτήσει πρόσβαση σε ευαίσθητες πληροφορίες και διαπιστευτήρια αποκτώντας πρόσβαση στο σύστημα επιτρέποντας του να μεγιστοποιήσει τη ζημιά που μπορεί να προκαλέσει εκ των έσω και να μεγιστοποιήσει το κέρδος του.

2.2.2 Είδη Κυβερνοεπιθέσεων

Επιθέσεις Άρνησης Υπηρεσιών Επιπέδου Εφαρμογής

Αυτές οι επιθέσεις άρνησης υπηρεσιών στοχεύουν πρωτόκολλα εφαρμογής του επιπέδου 7 του OSI στέλνοντας έναν υψηλό αριθμό ψεύτικων αιτημάτων. Χαρακτηριστικό παράδειγμα είναι η επίθεση HTTP DoS ή HTTP flood [58, p. 253] όπου ο επιτιθέμενος στέλνει σε έναν διακομιστή ιστού υψηλό αριθμό HTTP αιτημάτων σε πολύ μικρό χρονικό διάστημα. Έτσι, ο διακομιστής δεσμεύει επεξεργαστική ισχύ, πολλή μνήμη και εύρος ζώνης προκειμένου να εξυπηρετήσει το κάθε αίτημα.

Ογκομετρικές Επιθέσεις Άρνησης Υπηρεσιών

Αυτές οι επιθέσεις άρνησης υπηρεσιών έχουν στόχο την εξάντληση του εύρους ζώνης του θύματος ώστε να μην μπορεί να εξυπηρετήσει τη νόμιμη δικτυακή κίνηση. Χαρακτηριστικό παράδειγμα αυτών των επιθέσεων είναι η επίθεση UDP DoS [58, p. 249] όπου ο επιτιθέμενος στέλνει μεγάλο όγκο UDP πακέτων σε ένα σύστημα ώστε αυτό να κορεστεί και να μην μπορεί να επεξεργαστεί την κανονική δικτυακή κίνηση. Πολλές φορές στόχος του επιτιθέμενου αποτελεί όχι μόνο το σύστημα αλλά και το τείχος προστασίας που βρίσκεται ανάμεσα τους.

Μία επιπλέον επίθεση τέτοιου τύπου είναι η ICMP DoS [58, p. 249] στην οποία ο επιτιθέμενος στέλνει έναν τεράστιο αριθμό από ICMP αιτήματα στο σύστημα και αυτό έχει ως αποτέλεσμα να επιβραδύνεται σημαντικά η λειτουργία του στην προσπάθεια του να απαντήσει σε κάθε ICMP αίτημα.

Επιθέσεις Άρνησης Υπηρεσιών Πρωτοκόλλου

Αυτές οι επιθέσεις στοχεύουν τα επίπεδα μεταφοράς και δικτύου του μοντέλου OSI. Παραδείγματα τέτοιων επιθέσεων είναι η επίθεση TCP SYN πλημμύρα [58, p. 250] όπου ο επιτιθέμενος στέλνει σε ένα σύστημα πάρα πολλά TCP SYN αιτήματα, με αυτό να απαντάει αντιστοίχως με TCP SYN-ACK στα οποία όμως ο επιτιθέμενος δεν θα απαντήσει ποτέ με τα αντίστοιχα TCP ACK. Οπότε το σύστημα αναγκάζεται να συντηρεί συνδέσεις οι οποίες δεν θα τερματιστούν ποτέ δεσμεύοντας πόρους για να τις κρατήσει ενεργές.

Έγχυση SQL

Η Επίθεση Έγχυσης SQL (SQL Injection) [58, p. 384] είναι ένα είδος κυβερνοεπίθεσης στο οποίο, ο επιτιθέμενος εισάγει κακόβουλα ερωτήματα σε ένα σύστημα διαχείρισης βάσεων δεδομένων προκειμένου να ανακτήσει ευαίσθητες πληροφορίες από τη βάση δεδομένων, να τροποποιήσει κατά βούληση ή ακόμα και να βλάψει την βάση. Αυτά τα κακόβουλα ερωτήματα εισάγονται συνήθως κρυμμένα μεταξύ κανονικών δεδομένων σε μία εφαρμογή που χρησιμοποιεί τη βάση δεδομένων όπως μία ιστοσελίδα.

Επίθεση XSS

Η επίθεση XSS (Cross-Site Scripting) [58, p. 387] είναι ένα είδος επίθεσης έγχυσης όπου ο επιτιθέμενος εισάγει κακόβουλο κώδικα σε μία ιστοσελίδα ώστε όταν κάποιος χρήστης επισκεπτεί την συγκεκριμένη ιστοσελίδα, ο κώδικας αυτός να εκτελεστεί και να αποκτήσει πρόσβαση στα δεδομένα των cookies, σε πληροφορίες της συνόδου του χρήστη στην ιστοσελίδα ή ακόμα και να εκτελέσει κακόβουλες ενέργειες εκ μέρους του θύματος κρύβοντας την ταυτότητα του επιτιθέμενου.

Ransomware

Το Λυτρισμικό (Ransomware) [58, p. 221] είναι ένα είδος κακόβουλου λογισμικού το οποίο όταν εκτελεστεί, κρυπτογραφεί τα δεδομένα του χρήστη και καθιστά αδύνατη την πρόσβαση σε αυτά χωρίς κάποιο κλειδί αποκρυπτογράφησης. Ο δημιουργός του λυτρισμικού απαιτεί κάποιο χρηματικό αντίτιμο για τη διάθεση του κλειδιού στο θύμα προκειμένου να έχει ξανά πρόσβαση στα δεδομένα του.

Επιθέσεις Πλαστογράφησης

Οι Επιθέσεις Πλαστογράφησης (Spoofing Attacks) ανήκουν στην κατηγορία επιθέσεων ενδιάμεσου. Σε αυτές τις επιθέσεις ανήκει η επίθεση DNS Spoofing όπου ο επιτιθέμενος

πλαστογραφεί τον διακομιστή ονοματοδοσίας ενός χρήστη ώστε να τον ανακατευθύνει σε δικές του κακόβουλες ιστοσελίδες, οι οποίες φαίνονται πανομοιότυπες με τις αντίστοιχες νόμιμες με στόχο να κλέψει διαπιστευτήρια και ευαίσθητες πληροφορίες.

Επιθέσεις Σάρωσης

Στις Επιθέσεις Σάρωσης (Scanning Attacks) ο επιτιθέμενος διεξάγει σάρωση ενός συστήματος ή ενός δικτύου ώστε να ανακαλύψει τα τρωτά σημεία τους. Ανάλογα το σκέλος του συστήματος ή του δικτύου βάσει του οποίου γίνεται η σάρωση διακρίνονται σε Σάρωση Θυρών (Port Scanning) όπου αναλύονται οι αριθμοί θυρών που χρησιμοποιεί το θύμα και μπορούν να χρησιμοποιηθούν ως σημεία εισόδου του επιτιθέμενου στο σύστημα, Σάρωση Δικτύου (Network Scanning) και Σάρωση Ευπαθειών (Vulnerability Scanning).

Κεφάλαιο 3

Θεωρητικό Υπόβαθρο Μάθησης και Γλωσσικών Μοντέλων

Στο παρόν κεφάλαιο, περιγράφονται οι βασικές κατηγορίες μηχανικής μάθησης και αναφέρεται η συσχέτιση τους με την κυβερνοασφάλεια. Τέλος, καταγράφονται λεπτομερώς η αρχιτεκτονική καθώς και ο τρόπος λειτουργίας των αλγορίθμων μάθησης που υλοποιούνται με έμφαση στα μοντέλα μετασχηματιστών και ιδιαιτέρως των Γλωσσικών Μοντέλων.

3.0.1 Κατηγορίες Μάθησης

Επιβλεπόμενη Μάθηση

Η Επιβλεπόμενη Μάθηση (Supervised Learning) είναι μία κατηγορία μάθησης όπου οι αλγόριθμοι εκπαιδεύονται με δεδομένα τα οποία είναι χαρακτηρισμένα, δηλαδή ανήκουν σε κάποια κλάση εξόδου. Κάθε σημείο δεδομένων αντιστοιχίζεται σε μία αληθή ετικέτα. Το μοντέλο μηχανικής μάθησης κατά την εκπαίδευση του μαθαίνει τις συσχετίσεις μεταξύ των δεδομένων εισόδου και των κλάσεων εξόδου. Έπειτα αξιολογείται η απόδοση του μοντέλου πάνω σε νέα δεδομένα που το μοντέλο δεν έχει δει ποτέ, χρησιμοποιώντας την πληροφορία που αποκόμισε από την εκπαίδευση του. Ονομάζεται επιβλεπόμενη γιατί εδώ ο άνθρωπος παρεμβαίνει στην διαδικασία μάθησης με το να παρέχει στον αλγόριθμο τις τιμές της εξόδου. Η επιβλεπόμενη μάθηση έχει υποκατηγορίες όπως η κατηγοριοποίηση και η παλινδρόμηση.

Ημιεπιβλεπόμενη Μάθηση

Στην Ημιεπιβλεπόμενη Μάθηση (Semi-Supervised Learning) το μοντέλο μηχανικής μάθησης εκπαιδεύεται αρχικά σε έναν περιορισμένο αριθμό χαρακτηρισμένων δεδομένων και έπειτα σε ένα πολύ μεγαλύτερο αριθμό μη χαρακτηρισμένων δειγμάτων. Ενδείκνυται όταν είναι πολύ χρονοβόρα και δύσκολη η διαδικασία χαρακτηρισμού των δεδομένων σε κλάσεις εξόδου και όταν υπάρχουν περιορισμένα χαρακτηρισμένα δείγματα. Υπάρχουν διάφορες τεχνικές σε αυτό το είδος μάθησης όπως χρήση μόνο αλγορίθμων επιβλεπόμενης μάθησης, όπου ο αλγόριθμος εκπαιδεύεται αρχικά με χαρακτηρισμένα δεδομένα, έπειτα προβλέπει τα μη χαρακτηρισμένα και

τα χαρακτηρίζει με τις παραγόμενες ετικέτες και τα χρησιμοποιεί μαζί με τα αρχικά χαρακτηρισμένα δεδομένα για να επανεκπαιδέψει τον αλγόριθμο. Άλλες τεχνικές χρησιμοποιούν συνδυαστικά αλγορίθμους μη επιβλεπόμενης και επιβλεπόμενης μάθησης.

Μη Επιβλεπόμενη Μάθηση

Η Μη Επιβλεπόμενη Μάθηση (Unsupervised Learning) είναι μία κατηγορία μάθησης, όπου οι αλγόριθμοι εκπαιδεύονται με μη χαρακτηρισμένα δεδομένα και προσπαθούν να ανακαλύψουν μοτίβα και συσχετίσεις εντός τους και ο τελικός στόχος είναι να διαχωριστούν δεδομένα τα οποία έχουν μικρή ομοιότητα μεταξύ τους. Εδώ δεν παρεμβαίνει ο άνθρωπος στην διαδικασία της μάθησης. Η μη επιβλεπόμενη μάθηση έχει υποκατηγορίες όπως η συσταδοποίηση, οι κανόνες συσχέτισης και η μείωση διαστατικότητας.

Αυτοεπιβλεπόμενη Μάθηση

Η Αυτοεπιβλεπόμενη Μάθηση (Self-Supervised Learning) είναι ένα είδος μη επιβλεπόμενης μάθησης όπου το μοντέλο προεκπαιδεύεται πρώτα σε μεγάλο όγκο δεδομένων χωρίς την ανάγκη να είναι χαρακτηρισμένα. Στα μοντέλα αυτοεπιβλεπόμενης μάθησης οι χαρακτηρισμοί των δεδομένων προκύπτουν εσωτερικά χωρίς παρέμβαση από τον άνθρωπο. Έπειτα, το μοντέλο μπορεί να εκπαιδευτεί περεταίρω σε σημαντικά μικρότερο αριθμό δεδομένων μέσω κάποιου είδους μάθησης είτε επιβλεπόμενης ή μη επιβλεπόμενης μέσω μιας διαδικασίας που ονομάζεται προσαρμογή (fine-tuning). Αυτό το είδος μάθησης στο οποίο εξειδικεύεται μετέπειτα το μοντέλο λέγεται κατάντη εργασία (downstream task). Η αυτοεπιβλεπόμενη μάθηση έχει τεράστια εφαρμογή στην επεξεργασία φυσικής γλώσσας, στην όραση υπολογιστών και ιδιαίτερα σε πεδία που χρησιμοποιούνται μοντέλα μετασχηματιστών και παραλλαγών τους. Ουσιαστικά αποτελεί ένα είδος ημιεπιβλεπόμενης διαδικασίας όταν συνδυαστεί η μη επιβλεπόμενη προεκπαίδευση με την επιβλεπόμενη προσαρμογή.

3.0.2 Αλγόριθμοι Μάθησης

Δέντρο Απόφασης

Το Δέντρο Απόφασης (Decision Tree) [11] είναι ένας αλγόριθμος μάθησης με επίβλεψη. Ανάλογα το πρόβλημα μάθησης διακρίνεται σε δέντρο κατηγοριοποίησης ή δέντρο παλινδρόμησης. Έχει τη δομή δέντρου, δηλαδή διαθέτει ρίζα, ακμές, εσωτερικούς κόμβους και φύλλα. Οι εσωτερικοί κόμβοι αναπαριστούν έλεγχο της τιμής κάποιου χαρακτηριστικού, οι ακμές αναπαριστούν τις τιμές του χαρακτηριστικού που πληρούν τον έλεγχο στον γονικό τους κόμβο και τα φύλλα αναπαριστούν τις προβλέψεις του αλγορίθμου. Οπότε για ένα δείγμα του συνόλου δεδομένων ο αλγόριθμος ακολουθεί το μονοπάτι από τη ρίζα ως τα φύλλα προχωρώντας ανάλογα με τις τιμές των χαρακτηριστικών του δείγματος. Ο αλγόριθμος χρησιμοποιεί δύο μετρικές για να τοποθετήσει το βέλτιστο χαρακτηριστικό σε κάθε κόμβο, το Κέρδος Πληροφορίας (Information Gain) [49] είτε τον δείκτη Gini (Gini index) [25].

Τυχαία Δάση


Τα Τυχαία Δάση (Random Forests) [10] είναι ένας αλγόριθμος επιβλεπόμενης μάθησης, ο οποίος ανήκει στην κατηγορία των αλγορίθμων μάθησης συνόλου. Τα τυχαία δάση συνδυάζουν τις εξόδους από πολλά δέντρα αποφάσεων για να καταλήξουν στην τελική τους πρόβλεψη. Ο αλγόριθμος αρχικά δημιουργεί ένα σύνολο από δέντρα απόφασης με το καθένα ωστόσο να έχει παραχθεί από διαφορετικά δεδομένα του συνόλου δεδομένων εκπαίδευσης. Κατά την αξιολόγηση του μοντέλου, όλα τα δέντρα κατηγοριοποιούν το εκάστοτε δείγμα του συνόλου ελέγχου σε μία κλάση εξόδου με την τελική πρόβλεψη του αλγορίθμου να είναι συνήθως η πιο συχνή κλάση από αυτές τις προβλέψεις. Αυτή η τεχνική λέγεται bagging.

Πολυεπίπεδο Αντίληπτρο

Το Πολυεπίπεδο Αντίληπτρο (Multilayer Perceptron) [52][53] είναι ένας αλγόριθμος μηχανικής μάθησης ο οποίος βασίζεται στην δομή ενός τεχνητού νευρωνικού δικτύου. Διαθέτει πολλά στρώματα τεχνητών νευρώνων, το καθένα πλήρως συνδεδεμένο με το προηγούμενο. Αυτά τα στρώματα αναλόγως της λειτουργίας τους κατατάσσονται σε 3 κατηγορίες:

- Στρώμα εισόδου: Κάθε νευρώνας στο στρώμα εισόδου αντιπροσωπεύει ένα χαρακτηριστικό των δεδομένων εισόδου.
- Κρυφά στρώματα: Ένα πολυεπίπεδο αντίληπτρο μπορεί να διαθέτει οποιονδήποτε αριθμό στρωμάτων, οσονδήποτε τεχνητών νευρώνων το καθένα. Εκτελεί, μη γραμμικούς μετασχηματισμούς επάνω στα δεδομένα που δέχεται από τους νευρώνες του προηγούμενου στρώματος.
- Στρώμα εξόδου: Το στρώμα εξόδου αντιπροσωπεύει την τελική πρόβλεψη του μοντέλου και ανάλογα το πρόβλημα διαθέτει και αντίστοιχο αριθμό τεχνητών νευρώνων.

Κάθε νευρώνας έχει τη δική του συνάρτηση ενεργοποίησης η οποία δίνει στο δίκτυο τη δυνατότητα να χειρίζεται μη γραμμικές συσχετίσεις μεταξύ των δεδομένων. Αυτό είναι σημαντικό διότι τα δεδομένα κυβερνοεπιθέσεων συνήθως απαρτίζονται από περίπλοκα μοτίβα. Στην εικόνα 3.1 φαίνεται η αρχιτεκτονική ενός πολυεπίπεδου αντίληπτρου.



Σχήμα 3.1: Πολυεπίπεδο Αντίληπτρο

Η εκπαίδευση ενός πολυεπίπεδου αντίληπτρου περιλαμβάνει την ακόλουθη διαδικασία. Αρχικά, εισάγεται στο δίκτυο ένα δείγμα του συνόλου δεδομένων εκπαίδευσης μέσω του στρώματος εισόδου. Έπειτα τα δεδομένα μετασχηματίζονται μέσω των νευρώνων των κρυφών στρώματων και παράγεται η έξοδος του δικτύου από το στρώμα εξόδου. Έπειτα, αυτή η έξοδος (προβλεφθείσα) συγκρίνεται με την αναμενόμενη έξοδο μέσω μίας συνάρτησης σφάλματος. Αυτό το σφάλμα προωθείται προς τα πίσω στο δίκτυο και μέσω αυτού και τεχνικών βελτιστοποίησης ενημερώνονται τα βάρη του με σκοπό να ελαχιστοποιηθεί το σφάλμα. Αυτή η διαδικασία, επαναλαμβάνεται για όλα τα δείγματα του συνόλου δεδομένων εκπαίδευσης για έναν συγκεκριμένο αριθμό φορών που ονομάζονται εποχές εκπαίδευσης (training epochs).

XGBoost

Ο XGBoost (eXtreme Gradient Boosting) [13] είναι ένας αλγόριθμος επιβλεπόμενης μάθησης, ο οποίος ανήκει στους αλγόριθμους μάθησης συνόλου. Όπως και ο αλγόριθμος των Τυχαίων Δασών (Random Forest) συνδυάζει τα αποτελέσματα από πολλά δέντρα απόφασης για να παράξει την τελική του πρόβλεψη με τη διαφορά ότι η διαδικασία εκπαίδευσης είναι ακολουθιακή, δηλαδή κάθε δέντρο απόφασης χρησιμοποιεί το σφάλμα πρόβλεψης του προηγούμενου δέντρου στην εκπαίδευση του για να το μειώσει. Η αρχιτεκτονική του XGBoost προσφέρει αποδοτική επεξεργασία τεράστιου όγκου δεδομένων αποτελώντας έναν από τους πιο γρήγορους και ταυτόχρονα πιο ακριβείς αλγόριθμους μάθησης. Επίσης, φημίζεται για την εγγενή ικανότητα του να χειρίζεται αποτελεσματικά ανισορροπία στις κλάσεις εξόδου των δεδομένων.

Μετασχηματιστές

Οι Μετασχηματιστές [62] είναι μία καινοτόμα αρχιτεκτονική βαθιών νευρωνικών δικτύων η οποία έχει βρει πληθώρα εφαρμογών στην επεξεργασία φυσικής γλώσσας, επεξεργασία εικόνων, στην μετάφραση και στην αναγνώριση ομιλίας.

Η αρχιτεκτονική ενός μετασχηματιστή αποτελείται από δύο κύρια στρώματα κωδικοποιητών και αποκωδικοποιητών αντίστοιχα με κάθε κύριο στρώμα να διαθέτει τον ίδιο αριθμό κωδικοποιητών και αποκωδικοποιητών σειριακά συνδεδεμένων μεταξύ τους.

Ένας κωδικοποιητής αποτελείται από 2 στοιχεία:

- Μηχανισμός προσοχής πολλαπλών κεφαλών: Αυτός ο μηχανισμός λαμβάνει 3 εισόδους Q, K, V , οι οποίες είναι οι ενσωματώσεις που έχουν παραχθεί από την είσοδο πολλαπλασιασμένες με 3 μητρώα (W^Q, W^K, W^V) αντίστοιχα. Αυτή η τριάδα μητρώων αποτελεί μία κεφαλή του μηχανισμού αυτού και συνήθως ο μηχανισμός διαθέτει πολλές κεφαλές. Αυτά τα μητρώα είναι διαφορετικά ανά κεφαλή και τα έχει ορίσει ο μετασχηματιστής κατά την προεκπαίδευση του. Σε κάθε κεφαλή ο μετασχηματιστής υπολογίζει μία τιμή χρησιμοποιώντας τα Q, K, V . Στην έξοδο του μηχανισμού, ο μετασχηματιστής συνενώνει τα αποτελέσματα από όλες τις κεφαλές σε ένα μεγάλο μητρώο και πολλαπλασιάζει το αποτέλεσμα με ένα μητρώο W^O . Στην ουσία ο μηχανισμός αυτός υπολογίζει για

κάθε λέξη ενός κειμένου μια σειρά από βαθμολογίες που δείχνει κατά πόσο σχετίζεται αυτή η λέξη με όλες τις λέξεις του κειμένου.

- Δίκτυο εμπρόσθιας τροφοδότησης: Πρόκειται για ένα τεχνητό νευρωνικό δίκτυο το οποίο τελεί μη γραμμικούς μετασχηματισμούς στις ενσωματώσεις που παράχθηκαν από τον μηχανισμό προσοχής του κωδικοποιητή.


Ένας αποκωδικοποιητής αποτελείται από τα εξής 3 στοιχεία:

- Κεκαλυμμένος μηχανισμός αυτοπροσοχής πολλαπλών κεφαλών: Ο μηχανισμός αυτός λειτουργεί όμοια με τον μηχανισμό προσοχής πολλαπλών κεφαλών ενός κωδικοποιητή με μία βασική διαφορά. Αρχικά λαμβάνει τις ενσωματώσεις της ολισθημένης κατά δεξιά ακολουθίας και παράγει τα αντίστοιχα μητρώα Q, K, V όπως και στον κωδικοποιητή. Ομοίως σε κάθε κεφαλή του μηχανισμού αυτού υπολογίζεται μία τιμή μέσω των Q, K, V και ενός μητρώου M και όλες αυτές οι τιμές συνενώνονται και πολλαπλασιάζονται με ένα μητρώο W^O για να παραχθεί η τελική ενσωμάτωση. Το μητρώο M σχετίζεται με τη λειτουργία του αποκωδικοποιητή. Ο αποκωδικοποιητής έχει ως κύρια λειτουργία του να παράγει κείμενο οπότε είναι απαραίτητο κατά την εκπαίδευση του δεδομένης μίας ακολουθίας από σύμβολα να μπορεί για κάθε σύμβολο να προβλέψει το επόμενο του. Ωστόσο επειδή στην προεκπαίδευση ο αποκωδικοποιητής έχει πρόσβαση σε όλη την ακολουθία εάν χρησιμοποιηθεί ο κλασσικός μηχανισμός προσοχής πολλών κεφαλών, κατά τον υπολογισμό των βαθμολογιών του κάθε συμβόλου συναρτήσει των υπολοίπων, για το εκάστοτε σύμβολο θα λαμβάνεται υπόψη πληροφορία από τα επόμενα σύμβολα του τα οποία κανονικά δεν έχει προβλέψει ακόμα. Αυτό αντιτίθεται με τον τελικό σκοπό του αποκωδικοποιητή ο οποίος είναι να παράγει νέο κείμενο για μία ακολουθία εισόδου. Γι'αυτό, μέσω ενός μητρώου M σε κάθε βήμα της παραγωγής κειμένου ο μηχανισμός για το τρέχον σύμβολο λαμβάνει υπόψη πληροφορία των συμβόλων μόνο μέχρι και αυτό. Χωρίς αυτό το μητρώο ο μετασχηματιστής απλώς θα απομνημόνευε τα επόμενα σύμβολα κάθε συμβόλου και δεν θα μπορούσε πραγματικά να προβλέψει για ένα σύμβολο το λογικό επόμενο του και άρα την δυνατότητα να κατανοήσει την ροή της φυσικής γλώσσας.
- Μηχανισμός προσοχής πολλαπλών κεφαλών: Αυτός ο μηχανισμός είναι ίδιος με τον αντίστοιχο μηχανισμό ενός κωδικοποιητή και η μόνη διαφορά είναι οι είσοδοι του. Ενώ στον αντίστοιχο μηχανισμό ενός κωδικοποιητή οι είσοδοι Q, K, V παράγονται από τις ίδιες ενσωματώσεις, στον μηχανισμό του αποκωδικοποιητή η είσοδος Q παράγεται από τον κεκαλυμμένο μηχανισμό αυτοπροσοχής πολλαπλών κεφαλών του ενώ οι είσοδοι K, V προέρχονται από την έξοδο του τελευταίου κωδικοποιητή. Ουσιαστικά, ο μηχανισμός αυτός λαμβάνει πληροφορία από τον κωδικοποιητή για την ακολουθία εισόδου, δηλαδή παράγει βαθμολογίες που δείχνουν πόσο σχετίζονται τα σύμβολα από την ακολουθία που έχει παράξει ο αποκωδικοποιητής με την αρχική ακολουθία εισόδου. Αυτό έχει μεγάλη χρησιμότητα όταν ο μετασχηματιστής λαμβάνει ως είσοδο στον κωδικοποιητή

ένα κείμενο και θέλει μέσω του αποκωδικοποιητή να παράξει την μετάφραση του κειμένου αυτού σε μία άλλη γλώσσα.

- Δίκτυο εμπρόσθιας τροφοδότησης: Λειτουργεί ακριβώς όπως και στον κωδικοποιητή.

Έπειτα, η έξοδος του τελευταίου κωδικοποιητή εισάγεται στον μηχανισμό αυτοπροσοχής πολλαπλών κεφαλών κάθε αποκωδικοποιητή στο στρώμα αποκωδικοποιητών του μετασχηματιστή. Στην εικόνα 3.2 φαίνεται η αρχιτεκτονική ενός μετασχηματιστή.



Σχήμα 3.2: Αρχιτεκτονική Μετασχηματιστή

Στον αλγόριθμο 3.0.2 παρατίθεται ο αλγόριθμος ενός μετασχηματιστή.

Ψευδοκώδικας Μετασχηματιστή

```

1: Input: text  $t$ , text  $t'$ 
2: Output: Transformer output
3:  $tokens \leftarrow tokenizer(t)$ 
4:  $embeddings \leftarrow create\_embeddings(tokens)$ 
5: procedure CROSS_ATTENTION( $embeddings, encoder\_output$ )
6:    $multi\_head \leftarrow [ ]$ 
7:   for  $i \leftarrow 1$  to  $heads$  do
8:      $Q \leftarrow embeddings \cdot W_i^Q$ 
9:      $K \leftarrow encoder\_output \cdot W_i^K$ 
10:     $V \leftarrow encoder\_output \cdot W_i^V$ 
11:     $head \leftarrow softmax(\frac{Q \cdot K^T}{\sqrt{d_k}}) \cdot V$ 
12:     $multi\_head \leftarrow multi\_head || head$ 
13:   end for
14:   return  $multi\_head \cdot W^O$ 
15: end procedure
16: procedure MASKED_SELF_ATTENTION( $embeddings$ )
17:    $multi\_head \leftarrow [ ]$ 
18:   for  $i \leftarrow 1$  to  $heads$  do
19:      $Q \leftarrow embeddings \cdot W_i^Q$ 
20:      $K \leftarrow embeddings \cdot W_i^K$ 
21:      $V \leftarrow embeddings \cdot W_i^V$ 
22:      $head \leftarrow softmax(M + \frac{Q \cdot K^T}{\sqrt{d_k}}) \cdot V$ 
23:      $multi\_head \leftarrow multi\_head || head$ 
24:   end for
25:   return  $multi\_head \cdot W^O$ 
26: end procedure
27: for  $i \leftarrow 1$  to  $N$  do
28:    $output\_self \leftarrow self\_attention(embeddings) \triangleright$  βλέπε αλγόριθμος 3.0.2.
29:    $temp \leftarrow layer\_normalize(output\_self + embeddings)$ 
30:    $output\_feedforward \leftarrow feedforward(temp)$ 
31:    $encoder\_output \leftarrow layer\_normalize(output\_feedforward + temp)$ 
32:    $embeddings \leftarrow encoder\_output$ 
33: end for
34:  $embeddings\_shifted \leftarrow create\_embeddings(shift\_right(t'))$ 
35: for  $l \leftarrow 1$  to  $N$  do
36:    $output\_masked\_self \leftarrow masked\_self\_attention(embeddings\_shifted)$ 
37:    $temp \leftarrow layer\_normalize(output\_masked\_self + embeddings\_shifted)$ 
38:    $output\_cross \leftarrow cross\_attention(temp, encoder\_output)$ 
39:    $temp \leftarrow layer\_normalize(temp + output\_cross)$ 
40:    $output\_feedforward \leftarrow feedforward(temp)$ 
41:    $decoder\_output \leftarrow layer\_normalize(output\_feedforward + temp)$ 
42:    $embeddings\_shifted \leftarrow decoder\_output$ 
43: end for
44: return  $decoder\_output$ 

```

Αμφίδρομες Αναπαραστάσεις Κωδικοποιητή από Μετασχηματιστές


Οι Αμφίδρομες Αναπαραστάσεις Κωδικοποιητή από Μετασχηματιστές (Bidirectional Encoder Representations from Transformers) [16] είναι ένα γλωσσικό μοντέλο που βασίζεται στην αρχιτεκτονική ενός μετασχηματιστή. Η κύρια διαφορά του σε σχέση με τα μοντέλα μετασχηματιστών είναι η απουσία αποκωδικοποιητών στην αρχιτεκτονική του. Εν αντιθέσει με τα συνηθισμένα μοντέλα αποκωδικοποιητών το BERT σε ένα κείμενο, για κάθε λέξη λαμβάνει υπόψη τις υπόλοιπες λέξεις εκατέρωθεν της, προκειμένου να κατανοήσει βαθύτερα το νόημα της.

Αρχικά το BERT λαμβάνει ως είσοδο ένα κείμενο και το επεξεργάζεται μέσω μιας δομής που ονομάζεται tokenizer, η οποία διασπά το κείμενο σε μία ακολουθία από σύμβολα. Ουσιαστικά κάθε σύμβολο αντιστοιχίζεται σε έναν αριθμό ενώ στην ακολουθία έχουν ήδη προστεθεί ειδικά σύμβολα που συμβολίζουν την αρχή και το τέλος της. Κάθε σύμβολο δεν αναπαριστά απαραίτητα και κάθε λέξη του κειμένου αλλά μπορεί να αντιπροσωπεύει και υπολέξεις μίας λέξης και αυτό εξαρτάται από το είδος του αλγορίθμου που εκτελεί ο tokenizer.

Η είσοδος στο BERT αποτελείται από 3 μέρη:

- **Ενσωμάτωση Συμβόλου:** Κάθε σύμβολο που έχει παραχθεί από τον tokenizer αντιστοιχίζεται σε ένα διάνυσμα το οποίο το μοντέλο ανακτά από το στρώμα ενσωματώσεων του. Συγκεκριμένα στο στρώμα ενσωματώσεων το μοντέλο ανακτά από το αντίστοιχο μητρώο την γραμμή που αντιστοιχεί στον αριθμό που ανατέθηκε στο σύμβολο από τον tokenizer. Αυτή η γραμμή του μητρώου είναι η ενσωμάτωση συμβόλου για το συγκεκριμένο σύμβολο.
- **Ενσωμάτωση Θέσης:** Εδώ το BERT ανατρέχει στο αντίστοιχο μητρώο στο στρώμα ενσωματώσεων και ανακτά τη γραμμή που αναλογεί στον αριθμό που εκπροσωπεί τη θέση του συγκεκριμένου συμβόλου στην ακολουθία των συμβόλων που παρήγαγε ο tokenizer. Αυτή η γραμμή είναι η Ενσωμάτωση Θέσης αυτού του συγκεκριμένου συμβόλου. Αυτό γίνεται ώστε το μοντέλο να μπορεί να ξεχωρίσει δύο ίδια σύμβολα που βρίσκονται σε διαφορετικές θέσεις μέσα σε μία πρόταση.
- **Ενσωμάτωση Τμήματος:** Ομοίως, στην περίπτωση που η είσοδος αποτελείται από παρπάνω του ενός κειμένων, το μοντέλο ανακτά από το αντίστοιχο μητρώο στο στρώμα ενσωματώσεων τη γραμμή που αναλογεί στον αριθμό που δείχνει σε ποιο κείμενο ανήκει το συγκεκριμένο σύμβολο. Αυτή η γραμμή του μητρώου είναι η Ενσωμάτωση Τμήματος για αυτό το συγκεκριμένο σύμβολο. Αυτό γίνεται ώστε το μοντέλο να μπορέσει να ξεχωρίσει δύο ίδια σύμβολα που βρίσκονται στην ίδια θέση αλλά σε διαφορετικά κείμενα.

Τα μητρώα του στρώματος ενσωματώσεων του μοντέλου που αναφέρθηκαν προηγουμένως έχουν καθοριστεί κατά την προεκπαίδευση του BERT. Οι ενσωματώσεις κάθε συμβόλου προστίθενται μεταξύ τους για να παράγουν την τελική ενσωμάτωση της εισόδου για το εκάστοτε σύμβολο. Στην εικόνα 3.3 φαίνονται οι επιμέρους ενσωματώσεις για μία ακολουθία εισόδου.



Σχήμα 3.3: Παράδειγμα Ενσωματώσεων για ένα Κείμενο

Έπειτα, η τελική ενσωμάτωση της εισόδου, εισάγεται στον πρώτο κωδικοποιητή του μοντέλου. Από την ενσωμάτωση της εισόδου παράγονται τα μητρώα Q , K , V που εισάγονται στο μηχανισμό αυτοπροσοχής πολλαπλών κεφαλών του κωδικοποιητή. Η έξοδος του μηχανισμού αυτού προστίθεται με τις αρχικές ενσωματώσεις της εισόδου του κωδικοποιητή και το αποτέλεσμα κανονικοποιείται μέσω ενός νευρωνικού δικτύου. Το αποτέλεσμα της κανονικοποίησης εισάγεται σε ένα δίκτυο εμπρόσθιας τροφοδότησης και η έξοδος του προστίθεται με το αποτέλεσμα αυτό και κανονικοποιείται. Η τελική έξοδος του κωδικοποιητή εισάγεται στον επόμενο κωδικοποιητή. Η διαδικασία επαναλαμβάνεται τόσες φορές όσοι και οι κωδικοποιητές του μοντέλου.

Το BERT στην αρχική του μορφή διακρίνεται σε δύο εκδοχές, το BERT_{BASE} και το BERT_{LARGE}, το οποίο εξαρτάται από τον αριθμό των κωδικοποιητών που διαθέτει. Το BERT έχει προεκπαιδευτεί ως μοντέλο αυτοεπιβλεπόμενης μάθησης σε δύο μη επιβλεπόμενα προβλήματα, στην Κεκαλυμμένη Μοντελοποίηση Γλώσσας (Masked Language Modeling) και στην Πρόβλεψη Επόμενης Πρότασης (Next Sentence Prediction).


Στην Πρόβλεψη Επόμενης Πρότασης, το BERT προβλέπει δοθέντων δύο προτάσεων, αν η δεύτερη είναι η λογική συνέχεια της πρώτης. Πρακτικά, κατά την προεκπαίδευση το BERT λαμβάνει ένα πλήθος από ζεύγη προτάσεων όπου η δεύτερη είναι όντως η λογική συνέχεια της πρώτης και ένα πλήθος από ζεύγη όπου η δεύτερη πρόταση είναι μία άσχετη πρόταση προερχόμενη είτε από το ίδιο κείμενο είτε από διαφορετικό.

Στην Κεκαλυμμένη Μοντελοποίηση Γλώσσας, το BERT επιλέγει τυχαία το 15% των συμβόλων ενός κειμένου με στόχο να τα προβλέψει, βασιζόμενο στα συμφραζόμενα του κάθε συμβόλου. Κάθε επιλεγμένο σύμβολο έχει:

- 80% πιθανότητα να αντικατασταθεί με το σύμβολο [MASK].
- 10% πιθανότητα να αντικατασταθεί με ένα τυχαίο σύμβολο.
- 10% πιθανότητα να μείνει ως έχει.

Τέλος, κατά την προσαρμογή η έξοδος του BERT τροφοδοτείται σε ένα νευρωνικό δίκτυο, του οποίου η αρχιτεκτονική εξατομικεύεται στο πρόβλημα που θέλουμε να επιλύσουμε. Μεταξύ

άλλων, τέτοιο πρόβλημα είναι η κατηγοριοποίηση κειμένου σε διακριτές κατηγορίες (κλάσεις) που υλοποιεί το κύριο μοντέλο αυτής της εργασίας. Στην εικόνα 3.4 φαίνεται η αρχιτεκτονική του BERT.



Σχήμα 3.4: Αρχιτεκτονική του BERT

Στον αλγόριθμο 3.0.2 παρατίθεται ο ψευδοκώδικας του BERT.

Ψευδοκώδικας BERT

```

1: Input: Text  $t$ 
2: Output: BERT output
3:  $tokens \leftarrow tokenizer(t)$ 
4:  $embeddings \leftarrow create\_embeddings(tokens)$ 
5: procedure SELF_ATTENTION( $embeddings$ )
6:    $multi\_head \leftarrow [ ]$ 
7:   for  $i \leftarrow 1$  to  $heads$  do
8:      $Q \leftarrow embeddings \cdot W_i^Q$ 
9:      $K \leftarrow embeddings \cdot W_i^K$ 
10:     $V \leftarrow embeddings \cdot W_i^V$ 
11:     $head \leftarrow softmax(\frac{Q \cdot K^T}{\sqrt{d_k}}) \cdot V$ 
12:     $multi\_head \leftarrow multi\_head || head$ 
13:   end for
14:   return  $multi\_head \cdot W^O$ 
15: end procedure
16: for  $i \leftarrow 1$  to  $N$  do
17:    $output\_self \leftarrow self\_attention(embeddings)$ 
18:    $temp \leftarrow layer\_normalize(output\_self + embeddings)$ 
19:    $output\_feedforward \leftarrow feedforward(temp)$ 
20:    $encoder\_output \leftarrow layer\_normalize(output\_feedforward + temp)$ 
21:    $embeddings \leftarrow encoder\_output$ 
22: end for
23: return  $encoder\_output$ 

```

Εύρωστα Βελτιστοποιημένη Προσέγγιση στην Προεκπαίδευση του BERT

Η Εύρωστα Βελτιστοποιημένη Προσέγγιση στην Προεκπαίδευση του BERT (Robustly Optimized BERT Pretraining Approach) [39] είναι ένα γλωσσικό μοντέλο το οποίο βασίζεται στην αρχιτεκτονική του BERT αλλά με κάποιες διαφοροποιήσεις οι οποίες έχουν σκοπό τη βελτίωση της απόδοσης του BERT. Αρχικά το RoBERTa έχει προεκπαιδευτεί σε μεγαλύτερο όγκο δεδομένων για περισσότερο χρόνο. Ενώ το BERT έχει προεκπαιδευτεί στην κεκαλυμμένη μοντελοποίηση γλώσσας και στην πρόβλεψη επόμενης πρότασης το RoBERTa έχει προεκπαιδευτεί μόνο στην κεκαλυμμένη μοντελοποίηση γλώσσας. Ακόμη, χρησιμοποιεί διαφορετικό tokenizer.

Αποσταγμένες Αμφίδρομες Αναπαραστάσεις Κωδικοποιητή από Μετασχηματιστές

Οι Αποσταγμένες Αμφίδρομες Αναπαραστάσεις Κωδικοποιητή από Μετασχηματιστές (DistilBERT) [54] είναι ένα γλωσσικό μοντέλο το οποίο αποτελεί μία ελαφρύτερη έκδοση του BERT με σκοπό να επιταχυνθεί αλλά και να καταναλώνει λιγότερους πόρους η εκπαίδευσή του. Συγκεκριμένα, στην προεκπαίδευσή του το μοντέλο έχει εκπαιδευτεί μόνο στην κεκαλυμμένη μοντελοποίηση γλώσσας και χρησιμοποιεί τον μισό αριθμό κωδικοποιητών από το BERT_{BASE}. Ακόμη, απουσιάζουν οι ενσωματώσεις τμήματος που έχει το αρχικό μοντέλο. Παρά τις τροποποιήσεις που το καθιστούν ελαφρύτερο, σε γενικές γραμμές το DistilBERT αποδίδει σχεδόν το ίδιο καλά με το BERT οπότε ιδιαίτερα σε περιπτώσεις που ο όγκος των δεδομένων είναι μεγάλος αποτελεί καλύτερη λύση. Αυτό το επιτυγχάνει με μία τεχνική η οποία ονομάζεται Απόσταξη (Distillation) όπου τροποποιείται η συνάρτηση σφάλματος του DistilBERT προκειμένου να συνυπολογίζεται στο ολικό σφάλμα, το σφάλμα μεταξύ της πρόβλεψης του αρχικού και του νέου μοντέλου. Έτσι το συμπιεσμένο μοντέλο μαθαίνει να προσεγγίζει τη συμπεριφορά του μοντέλου δασκάλου.

Ελαφρύ BERT

Το Ελαφρύ BERT (ALBERT) [35] είναι ένα γλωσσικό μοντέλο παραλλαγή του BERT. Έχει προεκπαιδευτεί στην Κεκαλυμμένη Μοντελοποίηση Γλώσσας και στην Πρόβλεψη Σειράς Πρότασης (Sentence Order Prediction). Στην Πρόβλεψη Σειράς Πρότασης το μοντέλο λαμβάνει από το ίδιο κείμενο δύο προτάσεις και προσπαθεί να προβλέψει εάν η μία είναι η λογική συνέχεια της επόμενης. Οπότε στην προεκπαίδευσή λαμβάνει ζεύγη προτάσεων που όντως η μία είναι η λογική συνέχεια της επόμενης και ζεύγη στα οποία η σειρά των ίδιων προτάσεων έχει αλλάξει. Αυτό το πρόβλημα θεωρείται δυσκολότερο της Πρόβλεψης Επόμενης Πρότασης και έτσι οδηγεί σε καλύτερη απόδοση του μοντέλου. Μία βασική διαφορά του σε σύγκριση με το BERT είναι η κατανομή των βαρών του. Ενώ στο BERT τα βάρη είναι διαφορετικά από κωδικοποιητή σε κωδικοποιητή σε αυτό το μοντέλο όλοι οι κωδικοποιητές μοιράζονται τα ίδια βάρη. Έτσι τα συνολικά βάρη του μοντέλου είναι πολύ λιγότερα. Αυτό το καθιστά μικρότερο σε μέγεθος οπότε απαιτεί λιγότερη μνήμη και χρόνο για την προεκπαίδευσή του. Μάλιστα εν αντιθέσει με το DistilBERT δεν υπάρχει έκπτωση στην απόδοση του σε σύγκριση με το BERT ενώ σε πολλές περιπτώσεις έχει αυξηθεί.

Κεφάλαιο 4

Αρχιτεκτονική Προτεινόμενων Μοντέλων

Σε αυτό το κεφάλαιο παρουσιάζεται η αρχιτεκτονική των μοντέλων που υλοποιήθηκαν σε αυτή την εργασία. Ακόμη αναφέρονται κάποιες σχεδιαστικές λεπτομέρειες που έχουν σκοπό την βελτίωση της απόδοσης των προτεινόμενων μοντέλων.

4.1 Αρχιτεκτονική Μοντέλου Ανίχνευσης Ανωμαλιών σε Αρχεία Καταγραφής Εφαρμογής

Αρχικά τα αρχεία καταγραφής συλλέγονται από το σύστημα αρχείων και ομαδοποιούνται βάσει του αναγνωριστικού που βρίσκεται στο μήνυμα κάθε εγγραφής και ταξινομούνται χρονικά. Αυτή η ομάδα εγγραφών εκπροσωπείται από αυτό το αναγνωριστικό. Έπειτα, γίνεται εξαγωγή των προτύπων (templates) των μηνυμάτων αυτών των εγγραφών και έτσι κατασκευάζεται ένα διάνυσμα από templates για κάθε αναγνωριστικό. Στη συνέχεια, για κάθε διάνυσμα δημιουργείται ένα κείμενο το οποίο αποτελείται από τα αντίστοιχα μηνύματα των templates που αποτελείται χωρισμένα με κενό. Σε αυτή την παράγραφο αντιστοιχίζεται η ετικέτα κανονικό ή ανωμαλία. Ακολούθως, κάθε κείμενο με την αντίστοιχη ετικέτα εισάγεται στο γλωσσικό μοντέλο το οποίο το κατηγοριοποιεί καταλλήλως. Στον αλγόριθμο 4.1 παρατίθεται ο ψευδοκώδικας για την παραγωγή των κειμένων από τα διανύσματα του HDFS.

Ψευδοκώδικας Παραγωγής Κειμένων από Αρχεία Καταγραφής Εφαρμογών


```

1: procedure EXTRACT_TEXT_FROM_TEMPLATE_DICT(id)
2:   return template_dict(id)
3: end procedure
4: for all trace  $\in$  event_traces do
5:   for i  $\leftarrow$  1 to length(trace) do
6:     template_text  $\leftarrow$  extract_text_from_template_dict(trace[i])
7:     log_text  $\leftarrow$  log_text  $\cup$  {template_text || SPACE}
8:   end for
9:   log_texts  $\leftarrow$  log_texts  $\cup$  {log_text}
10: end for
11: return log_texts

```

Αυτή η αρχιτεκτονική, ενώ αφορά κυρίως το σύνολο δεδομένων HDFS μιας και αυτό μελετείται σε αυτή την διπλωματική για την ανίχνευση ανωμαλιών σε αρχεία καταγραφής, θα μπορούσε εύκολα να επεκταθεί σε οποιοδήποτε σύνολο δεδομένων το οποίο ενσωματώνει κάποιου είδους πληροφορία που θα ομαδοποιεί τις εγγραφές.

Αυτή η διαδικασία εξηγείται στην ακόλουθη ροή εργασιών 4.1



Σχήμα 4.1: Ροή Εργασιών Μοντέλου Ανίχνευσης Ανωμαλιών σε Αρχεία Καταγραφής

4.2 Αρχιτεκτονική Προτεινόμενου Μοντέλου Κατηγοριοποίησης Ροών Δικτυακών Πακέτων

Αφαιρούνται τα χαρακτηριστικά από τα σύνολα δεδομένων που έχουν ελάχιστη προβλεπτική συνεισφορά ή είναι επικίνδυνα για υπερεκπαίδευση. Οι NaN τιμές διαγράφονται και αφαιρούνται οι διπλότυπες ροές. Εδώ δεν πραγματοποιείται κανονικοποίηση στα αριθμητικά δεδομένα ούτε one-hot κωδικοποίηση στα κατηγορικά δεδομένα. Στη συνέχεια, κάθε ροή μετατρέπεται σε μία ειδική κειμενική μορφή προκειμένου το BERT να μπορεί να την χειριστεί ως είσοδο. Παράγεται μια λεκτική περιγραφή της ροής σε φυσική γλώσσα η οποία περιλαμβάνει μία αναλυτική εξήγηση του κάθε πεδίου της συνοδευόμενη από την τιμή του. Ακόμη για να δοθεί περισσότερη πληροφορία στο μοντέλο, παρέχεται για συγκεκριμένα πεδία της ροής, με τη χρήση μιας δομής λεξικού, εξήγηση της τιμής του πεδίου σε φυσική γλώσσα ώστε η αρχιτεκτονική να εκμεταλλευτεί τη κατανόηση της φυσικής γλώσσας που έχει αποκομίσει το BERT στην προεκπαίδευση του. Στον αλγόριθμο 4.2 παρατίθεται ο ψευδοκώδικας για την παραγωγή των κειμένων από τις ροές των δικτυακών πακέτων.

Ψευδοκώδικας Μετατροπής Δικτυακών Ροών σε Κείμενο

```

1: Input: Πίνακας ροών πακέτων  $D$ 
2: Output: Πίνακας κωδικοποιημένων ροών  $T$ 
3:  $T \leftarrow []$ 
4: for  $i \leftarrow 1$  to  $length(D)$  do
5:    $T[i][\text{"text"}] \leftarrow encode(D[i])$            ▷ Η συνάρτηση μετατροπής ροής σε
   κείμενο. Ένα τέτοιο παράδειγμα φαίνεται στην εικόνα 4.2
6:    $T[i][\text{"label"}] \leftarrow D[i][\text{"label"}]$ 
7: end for
8: return  $T$ 

```

Ένα παράδειγμα κωδικοποιημένης ροής, που προκύπτει ως αποτέλεσμα της παραπάνω διαδικασίας φαίνεται στην εικόνα 4.2


```

"This network flow shows a connection originating from port
→ {entry['tcp.srcport']} and destined to port
→ {entry['tcp.dstport']}. For the HTTP protocol
→ {entry['http.content_length']} bytes of content were transferred.
→ {http_response_dict[entry['http.response']]}. For the TCP
→ protocol, the length of the tcp segment was {entry['tcp.len']}
→ bytes. The packet's sequence number was {entry['tcp.seq']} and its
→ acknowledgement number was {entry['tcp.ack']} with a raw value of
→ {entry['tcp.ack_raw']}. The connection flags were: SYN
→ {entry['tcp.connection.syn']], RST {entry['tcp.connection.rst']],
→ FIN {entry['tcp.connection.fin']] and SYN-ACK
→ {entry['tcp.connection.synack']}. The overall TCP flags were set
→ to {entry['tcp.flags']], which signifies
→ {tcp_flags_dict[entry['tcp.flags']]}. Regarding the UDP protocol,
→ this flow belonged to the stream {entry['udp.stream']]. The MQTT
→ message length was {entry['mqtt.len']} bytes and the MQTT message
→ type was {entry['mqtt.msgtype']} signifying
→ {mqtt_msgtype_dict[entry['mqtt.msgtype']]}. The MQTT connection
→ flags had a value of {entry['mqtt.conflags']} meaning
→ {mqtt_conflags_dict[entry['mqtt.conflags']] and the header flags
→ were set to {entry['mqtt.hdrflags']]. Regarding the ICMP protocol
→ the icmp checksum value was recorded as {entry['icmp.checksum']}.

```

Figure 4.2: Παράδειγμα Ροής Κωδικοποιημένης σε Κείμενο

Τα βήματα της παραπάνω διαδικασίας περιγράφονται στην ροή εργασιών της εικόνας 4.3



Σχήμα 4.3: Ροή Εργασιών Προτεινόμενου Μοντέλου

Ύστερα, οι κωδικοποιημένες ροές τροφοδοτούνται σε ένα γλωσσικό μοντέλο όπως το BERT και αυτό τις ταξινομεί σε καλοήθειες ή κακόβουλες ή σε διακριτά είδη επιθέσεων ανάλογα το είδος της κατηγοριοποίησης. Οπότε το πρόβλημα ανάγεται σε κατηγοριοποίηση κειμένων. Τέλος, οι προβλέψεις του μοντέλου εξηγούνται με κάποια τεχνική εξηγήσιμης τεχνητής νοημοσύνης ώστε να δοθεί πληροφορία για τους λόγους που η ροή ταξινομήθηκε ως κανονική ή κακόβουλη. Αυτή η πληροφορία, παρουσιάζεται με τη χρήση οπτικών μέσων σε κάποιο υπεύθυνο ασφάλειας βοηθώντας τον περαιτέρω.

4.3 Αρχιτεκτονική Μοντέλων Βασισμένων σε Ροές

Για τα μοντέλα που βασίζονται σε ροές δικτυακών πακέτων ακολουθούνται τυπικά βήματα που εφαρμόζονται κατά την εκπαίδευση μοντέλων μηχανικής μάθησης. Αρχικά αφαιρούνται χαρακτηριστικά από τα σύνολα δεδομένων τα οποία μπορούν να οδηγήσουν σε υπερεκπαίδευση των μοντέλων όπως IP διευθύνσεις, αναγνωριστικά, χρονοσφραγίδες (τιμεσταμπς), χαρακτηριστικά με συντριπτικά επικρατούσες τιμές σε όλο το σύνολο δεδομένων που δεν προσέφεραν ιδιαίτερη πληροφορία και τέλος χαρακτηριστικά που είχαν ελάχιστη συνεισφορά στον καθορισμό της εξόδου. Έπειτα, γίνεται αφαίρεση των NaN τιμών από τα δεδομένα καθώς και αφαίρεση των διπλότυπων δειγμάτων. Τα δεδομένα διαχωρίζονται σε υποσύνολα εκπαίδευσης και ελέγχου. Στη συνέχεια, τα αριθμητικά χαρακτηριστικά κανονικοποιούνται με τη κανονικοποίηση MinMax και τα κατηγορικά χαρακτηριστικά κωδικοποιούνται με one-hot κωδικοποίηση.

4.4 Σχεδιαστικές Αποφάσεις

Παρακάτω, παρουσιάζονται κάποιες σχεδιαστικές αποφάσεις οι οποίες είναι κοινές στην αρχιτεκτονική όλων των γλωσσικών μοντέλων που μελετούνται σε αυτή την διπλωματική εργασία. Αυτές οι αποφάσεις προσπαθούν να επιλύσουν κοινά θέματα παρόντα σε όλα τα προβλήματα κυβερνοασφάλειας.

4.4.1 Μεγάλος Όγκος Δεδομένων

Τα δικτυακά δεδομένα κυβερνοεπιθέσεων είναι από τη φύση τους ογκώδη για μια σειρά από λόγους. Σε πολλά είδη επιθέσεων όπως οι επιθέσεις άρνησης υπηρεσιών, ο επιτιθέμενος στέλνει μεγάλο αριθμό αιτημάτων προκειμένου να παραλύσει κάποιο σύστημα. Σε περιπτώσεις μάλιστα όπου πρόκειται για μία κατανεμημένη επίθεση άρνησης υπηρεσιών ο όγκος των αιτημάτων πολλαπλασιάζεται. Ακόμη, μοντέλα βαθιάς μάθησης όπως το πολυεπίπεδο αντίληπτρο και το BERT έχουν αρχιτεκτονική μεγάλης πολυπλοκότητας και πολλές υπερπαραμέτρους εκπαίδευσης κάτι που καθιστά απαιτητική την εκπαίδευση τους. Συνδυαστικά αυτοί οι δύο παράγοντες λειτουργούν επιβαρυντικά.

Ως εκ τούτου, επί το πλείστον υλοποιούνται μοντέλα τα οποία είναι ικανά να χειριστούν αποδοτικά τον μεγάλο όγκο των δεδομένων. Πολλά από αυτά αναλύθηκαν στο κεφάλαιο 2 όπως τα Τυχαία Δάση και ο XGBoost. Ωστόσο, τα μοντέλα βαθιάς μάθησης δεν είναι εγγενώς ικανά να χειριστούν αποδοτικά τον μεγάλο όγκο των δεδομένων οπότε επιστρατεύτηκαν ιδιαίτερα στην περίπτωση των γλωσσικών μοντέλων τεχνικές επιτάχυνσης της εκπαίδευσης τους. Συγκεκριμένα, στην περίπτωση του BERT χρησιμοποιήθηκε η τεχνική LoRa (Low Rank Adaption) [30]. Πρόκειται για μία τεχνική αποδοτικής προσαρμογής ενός Μεγάλου Γλωσσικού Μοντέλου, η οποία μειώνει το πλήθος των παραμέτρων του μοντέλου που αλλάζουν κατά την εκπαίδευση.

Ουσιαστικά, η μεταβολή στο μητρώο των βαρών του μοντέλου κατά την προσαρμογή μπορεί να προσεγγιστεί ικανοποιητικά με το γινόμενο δύο μητρώων πολύ μικρότερων διαστάσε-


ων. Κατά την προσαρμογή το μοντέλο ανανεώνει μόνο τις τιμές αυτών των δύο μικρότερων μητρώων αντί να ανανεώνει το αρχικό και αρκετά μεγαλύτερο μητρώο. Έτσι, μειώνεται η απαιτούμενη μνήμη και ο χρόνος για την εκπαίδευση. Τα παραπάνω περιγράφονται από την εξίσωση 4.1:

$$W' = W + \Delta W \quad (4.1)$$

και 4.2:

$$\Delta W = A * B \quad (4.2)$$

όπου W το αρχικό μητρώο των βαρών του μοντέλου όπου σε αυτή την τεχνική παραμένει αμετάβλητο, W' το τελικό μητρώο των βαρών μετά την εκπαίδευση, ΔW η μεταβολή στο αρχικό μητρώο την οποία προσεγγίζουμε και A , B τα μητρώα μικρότερων διαστάσεων που το επιτυγχάνουν. Η κοινή διάσταση r των μητρώων A και B είναι μία υπερπαράμετρος. Στο σχήμα 4.4 φαίνεται η εκπαίδευση μέσω της τεχνικής LoRa.



Σχήμα 4.4: Εκπαίδευση με LoRa

4.4.2 Ανισορροπία Κλάσεων

Συνήθως τα σύνολα δεδομένων δικτυακών δεδομένων κυβερνοεπιθέσεων απαρτίζονται και από κανονικά αλλά και από κακόβουλα δεδομένα. Ένα σύστημα κατά τη διάρκεια μιας επίθεσης εφόσον δεν τεθεί εκτός λειτουργίας συνεχίζει να λειτουργεί κανονικά, οπότε πέρα από

την κακόβουλη δικτυακή κίνηση καταγράφεται και η κανονική. Αυτό οδηγεί συνήθως στην ανισορροπία των κλάσεων εξόδου με τα κανονικά δεδομένα να υπερτερούν αρκετά έναντι των κακόβουλων. Αυτό ενδέχεται να επηρεάσει αρνητικά την απόδοση των μοντέλων καθώς δημιουργείται προκατάληψη υπέρ της κανονικής κλάσης. Το πρόβλημα γίνεται εντονότερο όταν η κατηγοριοποίηση είναι πολυταξική οδηγώντας σε ορισμένες κατηγορίες επιθέσεων να έχουν ελάχιστο αριθμό δειγμάτων.

Γι' αυτό το λόγο, αποφασίστηκε να υλοποιηθεί στο πλαίσιο των γλωσσικών μοντέλων μία διαφορετική συνάρτηση σφάλματος η Εστιακή Συνάρτηση Σφάλματος (Focal Loss Function) [37]. Αυτή η συνάρτηση σφάλματος λύνει δύο προβλήματα που συναντά κανείς κατά την εκπαίδευση μοντέλων βαθιάς μάθησης, σε δεδομένα με ανισορροπία στις κλάσεις με κλασσικές συναρτήσεις σφάλματος όπως η Κατηγορική Διασταυρούμενη Εντροπία (Categorical Cross Entropy). Το ένα είναι η μεροληψία του μοντέλου υπέρ των πλειοψηφικών κλάσεων και το δεύτερο, η υπερβολική έμφαση του μοντέλου στα εύκολα δείγματα δηλαδή σε αυτά που το μοντέλο προβλέπει σωστά με μεγάλη πιθανότητα. Περιγράφεται από τη σχέση 4.3:

$$Loss = -a_t(1 - p_t)^{\gamma} \log(p_t) \quad (4.3)$$

Όπου p_t η πιθανότητα το συγκεκριμένο δείγμα να ανήκει στην αληθή του κλάση, η παράμετρος γ επιβάλλει μεγαλύτερη ποινή στο μοντέλο όταν αυτό δεν καταφέρει να κατηγοριοποιήσει σωστά ένα δύσκολο δείγμα (λ.χ ένα πολύ σπάνιο δείγμα κάποιας μειοψηφικής κλάσης) ενώ το α πρόκειται για ένα διάνυσμα το οποίο περιέχει τα βάρη όλων των κλάσεων στο πρόβλημα κατηγοριοποίησης. Οπότε a_t είναι ένα διάνυσμα που έχει το βάρος μόνο της αληθούς κλάσης του δείγματος. Έτσι, στις πιο συχνές κλάσεις ανατίθενται μικρότερα βάρη και στις πιο σπάνιες μεγαλύτερα βάρη προκειμένου το μοντέλο να δώσει μεγαλύτερη σημασία στα δείγματα τους. Ως βάρος κάθε κλάσης επιλέχθηκε το αντίστροφο του ποσοστού της στο σύνολο εκπαίδευσης μία συνηθισμένη επιλογή σε μοντέλα βαθιάς μάθησης.

Κεφάλαιο 5

Υλοποίηση Προτεινόμενων Μοντέλων

Στο κεφάλαιο αυτό θα παρουσιαστούν το περιβάλλον υλοποίησης πάνω στο οποίο κατασκευάστηκαν οι αλγόριθμοι μάθησης, οι βιβλιοθήκες λογισμικού που χρησιμοποιήθηκαν για την ανάπτυξη τους και τα σύνολα δεδομένων για την αξιολόγηση τους. Ακόμη, περιγράφεται η φύση των δεδομένων που χρησιμοποιούν τα πειράματα της διπλωματικής δηλαδή γίνεται ανάλυση των αρχείων καταγραφής εφαρμογών και των ροών δικτυακών πακέτων.

5.1 Φύση Δεδομένων

5.1.1 Αρχεία Καταγραφής Εφαρμογών

Τα αρχεία καταγραφής εφαρμογών είναι αρχεία κειμένου που περιέχουν πληροφορίες για τη λειτουργία κάποιας εφαρμογής, διεργασίας ή και ενός συστήματος. Ένα αρχείο καταγραφής εφαρμογής συνήθως περιλαμβάνει χρονικές πληροφορίες για κάποιο συμβάν σχετιζόμενο με την εφαρμογή, το είδος του συμβάντος, την σοβαρότητα του και την αναλυτική του περιγραφή μέσω κάποιου μηνύματος. Αποτελούν μία χρήσιμη πηγή δεδομένων για μια εφαρμογή ή και ένα ολόκληρο σύστημα βοηθώντας τους διαχειριστές ενός συστήματος σε εργασίες όπως η εκσφαλμάτωση, η παραγωγή στατιστικών, η ανίχνευση ανωμαλιών και ο εντοπισμός ύποπτων ή και κακόβουλων συμπεριφορών. Σε σύγχρονα υπολογιστικά περιβάλλοντα ο όγκος αυτών αρχείων είναι τεράστιος, γεγονός που απαιτεί την κατασκευή εργαλείων που τα επεξεργάζονται γρήγορα και αποδοτικά.

Ταυτόχρονα, έχουν αναδειχθεί σε μία σημαντική πηγή δεδομένων για την προστασία των συστημάτων. Παρέχουν πληροφορίες για τη φύση των επιθέσεων σε επίπεδο εφαρμογής σε αντίθεση με τις ροές δικτυακών πακέτων που παρέχουν πληροφορίες κυρίως στα επίπεδα μεταφοράς και δικτύου. Τα αρχεία καταγραφής χωρίζονται σε διάφορες κατηγορίες. Στις εικόνες 5.1 και 5.2 φαίνονται δύο παραδείγματα αρχείων καταγραφής.

```

Jul 27 14:41:59 combo kernel: PCI: Invalid ACPI-PCI IRQ routing table
Jul 27 14:41:59 combo kernel: PCI: Probing PCI hardware
Jul 27 14:41:59 combo kernel: PCI: Probing PCI hardware (bus 00)
Jul 27 14:41:59 combo kernel: Transparent bridge - 0000:00:1e.0
Jul 27 14:41:54 combo sysctl: kernel.core_uses_pid = 1
Jul 27 14:41:59 combo hcid[1690]: HCI daemon ver 2.4 started
Jul 27 14:41:59 combo bluetooth: hcid startup succeeded

```

Figure 5.1: Αρχείο Καταγραφής στο Λειτουργικό Σύστημα Linux

```

03-17 16:13:38.859 2227 2227 D TextView: visible is system.time.showampm
03-17 16:13:38.861 2227 2227 D TextView: mVisiblity.getValue is false
03-17 16:13:39.070 1702 1815 D WindowManager: startAnimation begin
03-17 16:13:39.079 1702 1815 D WindowManager: startAnimation end
03-17 16:13:38.955 2227 2227 I PhoneStatusBar: cancelAutohide
03-17 16:13:40.307 2626 23469 W PhoneInterfaceManager: shouldBlockLocation running ...
03-17 16:13:40.308 2626 23469 I PhoneInterfaceManager: shouldBlockLocation ret:false

```

Figure 5.2: Αρχείο Καταγραφής στο Λειτουργικό Σύστημα Android

5.1.2 Ροές Δικτυακών Πακέτων

Μία ροή δικτυακών πακέτων είναι μία ακολουθία πακέτων σε ένα δίκτυο τα οποία έχουν ομαδοποιηθεί βάσει κάποιων κοινών πεδίων τους. Υπάρχουν αρκετές εκδοχές στους ορισμούς μιας ροής όσον αφορά την επιλογή αυτών των πεδίων αλλά σε αρκετές συνηθίζεται η ομαδοποίηση των πακέτων με κοινή IP διεύθυνση πηγής και προορισμού, θύρα πηγής και προορισμού και κωδικός IP πρωτοκόλλου. Έπειτα, εκτός από τα κοινά στοιχεία μία ροή μπορεί να περιγράφει μία σύνοδο ή μία σύνδεση με χαρακτηριστικά όπως το μέσο μέγεθος των πακέτων, τη συνολική διάρκεια μετάδοσης τους, τον συνολικό όγκο δεδομένων που στάλθηκαν, την ύπαρξη ή μη πακέτων εντός της ροής που έχουν ενεργή κάποια συγκεκριμένη σημαία. Συχνά, οι ροές παράγονται από ειδικά λογισμικά όπως το Zeek, το CICFlowMeter και το NetFlow. Οι ροές δικτυακών πακέτων μπορούν εύκολα να εισαχθούν ως διανύσματα σε μοντέλα μηχανικής μάθησης για ανίχνευση κυβερνοεπιθέσεων. Στην εικόνα 5.3 φαίνεται μία ροή δικτυακών πακέτων.

Timestamp:	Source IP:	Destination IP:	Source Port:	Destination Port:	Protocol:	Duration:	Packets Sent:	Bytes Sent:
2022-05-11 15:03:22	192.168.1.2	192.168.1.3	52156	22	TCP	1e-2	100	140000

Σχήμα 5.3: Παράδειγμα Ροής Δικτυακών Πακέτων

5.2 Λεπτομέρειες Υλοποίησης

5.2.1 Περιβάλλον Υλοποίησης

Η υλοποίηση των μοντέλων έγινε σε υπολογιστικό περιβάλλον DGX σε κάρτες γραφικών NVIDIA A100, με την χρήση της γλώσσας Python, ενώ χρησιμοποιήθηκαν οι ακόλουθες βιβλιοθήκες:

Transformers

Η Transformers [65] είναι μία βιβλιοθήκη η οποία παρέχει υλοποιήσεις μοντέλων τύπου μετασχηματιστή. Διαθέτει εργαλεία για την προσαρμογή τους σε διάφορα είδη προβλημάτων, μετρικές για την αξιολόγηση τους και την εύκολη συμβίωση τους με άλλες βιβλιοθήκες βαθιάς μάθησης όπως η Tensorflow και η Pytorch.

PEFT

Η PEFT (Performance Efficient Fine Tuning) [44] είναι μία βιβλιοθήκη η οποία υποστηρίζει αποδοτική προσαρμογή μεγάλων προεκπαιδευμένων μοντέλων τύπου μετασχηματιστή μειώνοντας κατά πολύ το υπολογιστικό του κόστος σε μνήμη και χρόνο. Είναι η βιβλιοθήκη που υλοποιεί την τεχνική LoRa και επιτρέπει την ενσωμάτωση της σε μοντέλα όπως το BERT, RoBERTa, ALBERT.

Scikit-learn

Η Scikit-learn [47] είναι μία βιβλιοθήκη η οποία περιλαμβάνει υλοποιήσεις πολλών αλγορίθμων μηχανικής μάθησης. Ακόμη, διαθέτει εργαλεία για την προεπεξεργασία των δεδομένων, την εισαγωγή τους στα μοντέλα μηχανικής μάθησης καθώς και την αξιολόγηση τους.

Tensorflow

Η Tensorflow [1] παρέχει δυνατότητες κατασκευής, εκπαίδευσης και αξιολόγησης νευρωνικών δικτύων διάφορων αρχιτεκτονικών. Σημαντικό πλεονέκτημα της, είναι η δυνατότητα εξατομίκευσης της αρχιτεκτονικής του νευρωνικού δικτύου που κατασκευάζεται σε πολύ μεγάλο βαθμό.

Pandas

Η pandas [60] είναι μία βιβλιοθήκη η οποία παρέχει πολλά εργαλεία ανάλυσης δεδομένων και μετασχηματισμού τους.

SHAP

Η shap [41] είναι μία βιβλιοθήκη εξηγήσιμης τεχνητής νοημοσύνης, η οποία υλοποιεί την ομώνυμη τεχνική, παρέχει τρόπους ενσωμάτωσης της σε γνωστά μοντέλα μηχανικής μάθησης

καθώς και τρόπους απεικόνισης των εξηγήσεων της με διάφορα γραφήματα.

Ferret-XAI

Η ferret-xai [7] είναι μία βιβλιοθήκη εξηγήσιμης τεχνητής νοημοσύνης η οποία ενσωματώνει πολλές τεχνικές όπως οι SHAP, Integrated Gradients, LIME και παρέχει μετρικές για την αξιολόγηση τους που περιγράφονται στο κεφάλαιο 7. Ακόμη, παρέχει δυνατότητες εκτέλεσης των τεχνικών αυτών σε χάρτες γραφικών για γρηγορότερα αποτελέσματα.

5.2.2 Σύνολα Δεδομένων

HDFS_v1

Το σύνολο δεδομένων HDFS_v1 [66] είναι μία συλλογή από αρχεία καταγραφής συμβάντων του Κατανεμημένου Συστήματος Αρχείων Hadoop. Οι δημιουργοί του συνόλου δεδομένων το έχουν προεπεξεργαστεί κατάλληλα ώστε να μπορεί να χρησιμοποιηθεί εύκολα σε μοντέλα μηχανικής μάθησης. Συγκεκριμένα, κάθε εγγραφή αποτελείται από πληροφορίες όπως η ημερομηνία καταχώρησης της εγγραφής, το αναγνωριστικό της διεργασίας που καταχώρησε την εγγραφή, την σοβαρότητα του συμβάντος, το είδος της διεργασίας που προκάλεσε την καταχώρηση και τέλος το μήνυμα που παρήγαγε η διεργασία.

Κάθε μήνυμα της κάθε εγγραφής περιέχει πληροφορία για το block στο οποίο αναφέρεται. Ένα block στο κατανεμημένο σύστημα αρχείων Hadoop αφορά ένα τμήμα ενός αρχείου στο σύστημα. Σε κάθε block ανατίθεται και ένα αναγνωριστικό. Βάσει αυτού του αναγνωριστικού, οι δημιουργοί έχουν ομαδοποιήσει τα μηνύματα των εγγραφών με το ίδιο block αναγνωριστικό, με αποτέλεσμα σε κάθε block να αντιστοιχίζεται ένα διάνυσμα από πρότυπα μηνυμάτων (templates). Αυτό το διάνυσμα αναπαριστά μία σειρά από ενέργειες που διεξήχθησαν σε αυτό το block. Σε αυτό το διάνυσμα αντιστοιχίζεται και ο χαρακτηρισμός του ως κανονικό ή ανωμαλία. Στην εικόνα 5.4 φαίνεται η μετατροπή μίας συλλογής από εγγραφές για ένα συγκεκριμένο block στο αντίστοιχο διάνυσμα.

```

081109 203518 143 INFO dfs.DataNode$Dataxcelver: Receiving block
↪ blk_-1608999687919862906 src: /10.250.19.102:54106 dest:
↪ /10.250.19.102:50010
081109 203518 35 INFO dfs.FSNamesystem: BLOCK* NameSystem.allocateBlock:
/mnt/hadoop/mapred/system/job_200811092030_0001/job.jar.
blk_-1608999687919862906
081109 203519 143 INFO dfs.DataNode$DataXcelver: Receiving block
↪ blk_-1608999687919862906 src: /10.250.10.6:40524 dest:
↪ /10.250.10.6:50010
081109 203519 145 INFO dfs.DataNode$DataXceiver: Receiving block
↪ blk_-1608999687919862906 src: /10.250.14.224:42420 dest:
↪ /10.250.14.224:50010
081109 203519 145 INFO dfs.DataNode$PacketResponder: PacketResponder 1 for
↪ block blk_-1608999687919862906 terminating
081109 203519 145 INFO dfs.DataNode$PacketResponder: PacketResponder 2 for
↪ block blk_-1608999687919862908 terminating
081109 203519 145 INFO dfs.DataNode$PacketResponder: Recelved block
↪ blk_-1608999687919862906 of size 91178 from /10.250.10.6
081109 203519 146 INFO dfs.DataNode$PacketResponder: Recclved block
↪ blk_-1608999687919862906 of size 91178 from /10.250.19.102

```

+

```

E5, [*]Receiving block[*]src[*]dest:[*]
E9, [*]Received block[*]of size[*]from[*]
E11, [*]PacketResponder[*]for block[*]terminating[*]
E22, [*]BLOCK* NameSystem[*]allocateBlock:[*]

```

⇓

[E5, E22, E5, E5, E11, E11, E9, E9]

Figure 5.4: Διάνυσμα στο HDFS

Στον πίνακα 5.1 φαίνονται οι κατηγορίες των εγγραφών του HDFS συνόλου δεδομένων μαζί με το πλήθος των δειγμάτων κάθε κατηγορίας.

Κατηγορία	Αριθμός Εγγραφών
Benign	558223
Anomalies	16838

Πίνακας 5.1: Κατηγορίες Εγγραφών στο HDFS_v1 Σύνολο Δεδομένων

5.2.3 Σύνολα Δεδομένων για Κατηγοριοποίηση Ροών Δικτυακών Πακέτων

Σε αυτή την υποενότητα παρουσιάζονται δύο σύνολα δεδομένων ροών δικτυακών πακέτων για να μελετηθεί η απόδοση του προτεινόμενου μοντέλου στην δυαδική και πολυταξική κατηγοριοποίηση των ροών σε επιθέσεις.

IoT-23

Το σύνολο δεδομένων IoT-23 [24] είναι ένα σύνολο δικτυακών δεδομένων IoT συσκευών. Περιλαμβάνει ροές κανονικής και κακόβουλης δικτυακής συμπεριφοράς χωρισμένες σε υποκατηγορίες επιθέσεων χρήσιμες για την αξιολόγηση μοντέλων μηχανικής μάθησης. Στον πίνακα 5.2 φαίνονται οι κατηγορίες επιθέσεων στο IoT-23.

Benign	-
Malicious	DDoS Okiru C&C (Command and Control) PartOfAHorizontalPortScan Attack C&C-FileDownload C&C-Mirai C&C-Torii C&C-HeartBeat C&C-HeartBeat-FileDownload

Πίνακας 5.2: Κατηγορίες Επιθέσεων στο IoT-23

Συγκεκριμένα, επιλέχθηκε μία εκδοχή του συνόλου δεδομένων που φιλοξενείται στο Kaggle αντί του αρχικού συνόλου δεδομένων εξαιτίας του τεράστιου όγκου του. Περιλαμβάνει 20 χαρακτηριστικά και μία στήλη που χαρακτηρίζει τη ροή σε κάποιο είδος επίθεσης. Τα χαρακτηριστικά περιγράφουν τα πακέτα της εκάστοτε ροής. Παρατηρώντας τον πίνακα 5.2 υπάρχουν και κάποιες πιο εξειδικευμένες κλάσεις όπως οι C&C-FileDownload, C&C-Mirai, C&C-Torii, C&C-HeartBeat, C&C-HeartBeat-FileDownload που συνδυάζουν συμπεριφορές δύο ή και παραπάνω ειδών επιθέσεων εξειδικεύοντας τες περαιτέρω.

Edge-IIoTset

Το σύνολο δεδομένων Edge-IIoTset [20] είναι ένα σύνολο δεδομένων κυβερνοασφάλειας IoT και βιομηχανικών IoT εφαρμογών. Τα δεδομένα έχουν παραχθεί από ένα σύνολο διάφορων αισθητήρων θερμοκρασίας, pH, υγρασίας. Οι δημιουργοί έχουν καταγράψει 14 είδη επιθέσεων καταναμεμένα σε 5 κατηγορίες. Στον πίνακα 5.3 φαίνονται οι κατηγορίες και τα είδη επιθέσεων στο Edge-IIoTset.

Κατηγορία	Είδος
DDoS/DoS	TCP DoS UDP DoS HTTP DoS ICMP DoS
Information Gathering	Port Scanning OS Fingerprinting Vulnerability Scanning
Man In The Middle	DNS Spoofing ARP Spoofing
Injection	XSS SQL Injection Upload
Malware	Backdoor Password Ransomware

Πίνακας 5.3: Κατηγορίες και Είδη Επιθέσεων στο Edge-IIoTset

Συγκεκριμένα, οι δημιουργοί του συνόλου δεδομένων παρείχαν δύο εκδόσεις του μία για αξιολόγηση κλασικών μοντέλων μηχανικής μάθησης και μία για αξιολόγηση μοντέλων βαθιάς μάθησης. Για να πραγματοποιηθούν τα πειράματα σε όσο το δυνατόν περισσότερες κοινές συνθήκες και εφόσον το κύριο μοντέλο της εργασίας είναι το BERT επιλέχθηκε η έκδοση των μοντέλων βαθιάς μάθησης. Οι ροές του συνόλου δεδομένων αποτελούνται από 61 χαρακτηριστικά και περιλαμβάνουν αναγνωριστικά της ροής, χρονικές πληροφορίες, στατιστικά των πακέτων της, τιμές σημαίων και πληροφορίες για το MQTT πρωτόκολλο μιας και τα δεδομένα αφορούν IoT συσκευές. Τέλος διαθέτει δύο ακόμη στήλες, όπου η μία αφορά τον χαρακτηρισμό της ροής ως καλοήγητη ή κακόβουλη ενώ η δεύτερη αφορά τον χαρακτηρισμό της ροής σε κάποιο είδος επίθεσης.

Κεφάλαιο 6

Ανάλυση Απόδοσης Μοντέλων

Στο κεφάλαιο αυτό παρουσιάζεται το θεωρητικό υπόβαθρο των μετρικών καθώς και των τεχνικών που χρησιμοποιήθηκαν για την αξιολόγηση όλων των μοντέλων που υλοποιήθηκαν στο πλαίσιο αυτής της εργασίας. Αυτές οι μετρικές και τεχνικές πιστοποιούν την προβλεπτική ικανότητα των μοντέλων και μετράζουν την προκατάληψη τους. Έπειτα, παρατίθενται οι πίνακες των αποτελεσμάτων όλων των πειραμάτων ώστε να συγκριθεί το προτεινόμενο μοντέλο με άλλα ανταγωνιστικά.

6.1 Μετρικές Αξιολόγησης Μοντέλων Μηχανικής Μάθησης

Αληθώς Θετικά

Αληθώς Θετικά (True Positives) ορίζεται, σε ένα πρόβλημα ταξινόμησης, το πλήθος των δειγμάτων που ανήκουν σε μία συγκεκριμένη κλάση και ταξινομήθηκαν σε αυτήν.

Αληθώς Αρνητικά

Αληθώς Αρνητικά (True Negatives) ορίζεται, σε ένα πρόβλημα ταξινόμησης, το πλήθος των δειγμάτων που δεν ανήκουν σε μία συγκεκριμένη κλάση και δεν ταξινομήθηκαν σε αυτήν.

Ψευδώς Θετικά

Ψευδώς Θετικά (False Positives) ορίζεται, σε ένα πρόβλημα ταξινόμησης, το πλήθος των δειγμάτων που δεν ανήκουν σε μία συγκεκριμένη κλάση και ταξινομήθηκαν σε αυτήν.

Ψευδώς Αρνητικά

Ψευδώς Αρνητικά (False Negatives) ορίζεται, σε ένα πρόβλημα ταξινόμησης, το πλήθος των δειγμάτων που ανήκουν σε μία συγκεκριμένη κλάση και δεν ταξινομήθηκαν σε αυτήν.

Ορθότητα

Η Ορθότητα (Accuracy) είναι μία μετρική αξιολόγησης μοντέλων επιβλεπόμενης μάθησης, η οποία μετρά σε ένα πρόβλημα κατηγοριοποίησης το ποσοστό των προβλέψεων ενός μοντέλου που ήταν όντως σωστές. Αν και παρέχει μία καλή αρχική εκτίμηση για την απόδοση του μοντέλου, σε περίπτωση που υπάρχει μεγάλη ανισορροπία στις κλάσεις εξόδου η τιμή της μπορεί να είναι παραπλανητική. Η ορθότητα περιγράφεται από την σχέση 6.1:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (6.1)$$

Ακρίβεια

Η Ακρίβεια (Precision) σε ένα πρόβλημα κατηγοριοποίησης υπολογίζει για μία συγκεκριμένη κλάση το ποσοστό των προβλέψεων για αυτή την κλάση που ανήκαν όντως σε αυτή την κλάση. Η ακρίβεια περιγράφεται από την σχέση 6.2:

$$Precision = \frac{TP}{TP + FP} \quad (6.2)$$

Η Ακρίβεια αποτελεί μία χρήσιμη μετρική για την εκτίμηση των ψευδώς θετικών δειγμάτων όπου υψηλός αριθμός αυτών των δειγμάτων (δηλαδή χαμηλή τιμή αυτής της μετρικής) συνήθως επιβραδύνει ένα σύστημα ανίχνευσης κυβερνοεπιθέσεων αφού το σύστημα και οι υπεύθυνοι του θα πρέπει να αντιμετωπίσουν ένα κανονικό δείγμα ως επικίνδυνο καταναλώνοντας χρόνο και πόρους.

Ανάκληση

Η Ανάκληση (Recall) είναι μία μετρική η οποία σε ένα πρόβλημα κατηγοριοποίησης μετρά για μία συγκεκριμένη κλάση το ποσοστό των δειγμάτων που ανήκουν σε αυτή την κλάση που κατηγοριοποιήθηκαν σωστά σε αυτή την κλάση. Η μετρική αυτή είναι πολύ σημαντική στην αξιολόγηση μοντέλων ανίχνευσης κυβερνοεπιθέσεων γιατί συνήθως η αδυναμία ενός μοντέλου να ανιχνεύσει μία πραγματική επίθεση μπορεί να έχει καταστροφικές συνέπειες για ένα σύστημα. Η ανάκληση περιγράφεται από τη σχέση 6.3:

$$Recall = \frac{TP}{TP + FN} \quad (6.3)$$

Μετρική F_1 (F_1 -score)

Η F_1 μετρική συνδυάζει τις μετρικές της ανάκλησης και της ακρίβειας σε μία τιμή. Η F_1 μετρική περιγράφεται από τη σχέση 6.4:

$$F_1 = \frac{2}{\frac{1}{Recall} + \frac{1}{Precision}} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (6.4)$$

Η σχέση αυτή δίνει την ίδια βαρύτητα στην ανάκληση και στην ακρίβεια, το οποίο δεν είναι πάντοτε ιδανικό. Για παράδειγμα σε προβλήματα κυβερνοασφάλειας η ανάκληση θα μπορούσε να θεωρηθεί πιο σημαντική αφού μειωμένη ανίχνευση των πραγματικών ανωμαλιών και


κακόβουλων ροών πακέτων θα είχε καταστροφικές συνέπειες σε ένα σύστημα που δέχεται επίθεση. Για αυτό πολλές φορές χρησιμοποιείται κάποιος παράγοντας β βάσει της σχέσης 6.5:

$$F_{\beta} = \frac{1 + \beta^2}{\frac{\beta^2}{Recall} + \frac{1}{Precision}} \quad (6.5)$$

όπου ο παράγοντας β δίνει παραπάνω βάρος είτε στην Ακρίβεια είτε στην Ανάκληση. Για $\beta > 1$ η μετρική δίνει μεγαλύτερη βαρύτητα στην Ανάκληση ενώ για $0 < \beta < 1$ στην Ακρίβεια.

Μητρώο Σύγχυσης

Το Μητρώο Σύγχυσης (Confusion Matrix) είναι ένας πίνακας ο οποίος αποτυπώνει γραφικώς τα 4 βασικά μεγέθη που παράγουν τις προαναφερθέντες μετρικές αξιολόγησης, δηλαδή τα Αληθώς Θετικά (TP), Αληθώς Αρνητικά (TN), Ψευδώς Θετικά (FP) και Ψευδώς Αρνητικά (FN) δείγματα. Σε ένα πρόβλημα κατηγοριοποίησης, το μητρώο σύγχυσης μπορεί να απεικονίσει τα παραπάνω μεγέθη για οποιοδήποτε αριθμό κλάσεων εάν το πρόβλημα είναι πολυταξικό. Στην εικόνα 6.1 φαίνεται το Μητρώο Σύγχυσης για ένα δυαδικό πρόβλημα ταξινόμησης.




Σχήμα 6.1: Μητρώο Σύγχυσης

6.2 Τεχνικές Αξιολόγησης

Διάσπαση σε Υποσύνολα Εκπαίδευσης Επικύρωσης και Ελέγχου

Η διάσπαση ενός συνόλου δεδομένων σε υποσύνολα Εκπαίδευσης, Επικύρωσης και Ελέγχου είναι μία τεχνική αξιολόγησης μοντέλων μηχανικής μάθησης που εφαρμόζεται συνήθως σε μοντέλα νευρωνικών δικτύων όπου η εκπαίδευση και η αξιολόγηση τους είναι ιδιαίτερα χρονοβόρα και υπολογιστικά δαπανηρή. Αυτό θα καθιστούσε την χρήση άλλων τεχνικών αξιολόγησης όπως η Διασταυρούμενη Επικύρωση (Cross Validation) απαγορευτική μιας και το μοντέλο θα χρειαζόταν να εκπαιδευτεί και να αξιολογηθεί πολλές φορές. Το κόστος θα ήταν ακόμη μεγαλύτερο στην περίπτωση που τα δεδομένα είναι πολλά και το μοντέλο έχει σύνθετη αρχιτεκτονική όπως ένα Γλωσσικό Μοντέλο τύπου κωδικοποιητή.

Αρχικά το σύνολο δεδομένων διασπάται σε δύο υποσύνολα, στο Σύνολο Εκπαίδευσης και στο Σύνολο Ελέγχου. Έπειτα το Σύνολο Εκπαίδευσης διασπάται περεταίρω στο τελικό σύνολο Σύνολο Εκπαίδευσης και στο Σύνολο Επικύρωσης. Η διαδικασία αυτή φαίνεται στην εικόνα 6.2. Το μοντέλο εκπαιδεύεται με το Σύνολο Εκπαίδευσης (Training Set) ανανεώνοντας τις παραμέτρους του (στην περίπτωση των νευρωνικών δικτύων τα βάρη των συνάψεων μεταξύ των νευρώνων). Έπειτα, το μοντέλο αξιολογείται επάνω στο Σύνολο Επικύρωσης (Validation Set) όπου γίνεται έλεγχος της πορείας της εκπαίδευσης του μοντέλου δηλαδή αν υπάρχει υπερεκπαίδευση του μοντέλου πάνω στα δεδομένα ή δεν υπάρχει ανάγκη περεταίρω εκπαίδευσης επειδή μεγιστοποιήθηκε η απόδοση του ώστε να διακοπεί νωρίτερα. Αυτή η διαδικασία επαναλαμβάνεται τόσες φορές όσες και ο αριθμός των εποχών που έχουν οριστεί πριν την εκπαίδευση. Τέλος αφότου έχει ολοκληρωθεί η εκπαίδευση του μοντέλου, αυτό αξιολογείται επάνω στο Σύνολο Ελέγχου (Test set) το οποίο δεν έχει δει καθόλου κατά τη διάρκεια της εκπαίδευσης του, προκειμένου να μην υπάρχει διαρροή πληροφορίας και συνεπώς να παραχθεί μία αντικειμενική αξιολόγηση της απόδοσης του.



Σχήμα 6.2: Διάσπαση σε Υποσύνολα Εκπαίδευσης, Επικύρωσης και Ελέγχου

6.3 Αποτελέσματα

Στην ενότητα αυτή, παρουσιάζονται τα πειραματικά αποτελέσματα των μοντέλων που συζητήθηκαν στο κεφάλαιο 3 και τα σύνολα δεδομένων στο κεφάλαιο 5. Αποφασίστηκε, για λόγους πληρότητας σε όλα τα προβλήματα κατηγοριοποίησης να παρουσιαστούν όλες οι μετρικές για κάθε κλάση αναλυτικά. Όλες οι μετρικές προέκυψαν από την αξιολόγηση των μοντέλων επάνω στο σύνολο ελέγχου του κάθε συνόλου δεδομένων. Στο παράρτημα Β', παρέχονται περισσότερες λεπτομέρειες σχετικές με τα πειράματα όπως το μέγεθος κάθε συνόλου ελέγχου.

6.3.1 Δυαδική Κατηγοριοποίηση στο HDFS_{v1} Σύνολο Δεδομένων

		BERT	RoBERTa	ALBERT	DistilBERT
Accuracy (%)		99.8713	99.9826	99.8713	99.8521
Precision (%)	Benign	99.8747	99.9892	99.8765	99.8693
	Anomaly	99.7527	99.7621	99.6913	99.2606
Recall (%)	Benign	99.9928	99.9928	99.9910	99.9785
	Anomaly	95.8432	99.6437	95.9026	95.6650
F₁ score (%)	Benign	99.9337	99.9910	99.9337	99.9239
	Anomaly	97.7589	99.7029	97.7602	97.4296

Πίνακας 6.1: Δυαδική Κατηγοριοποίηση στο HDFS Σύνολο Δεδομένων

Στον πίνακα 6.1 φαίνονται τα αποτελέσματα κατηγοριοποίησης στο σύνολο δεδομένων HDFS στα γλωσσικά μοντέλα της εργασίας. Παρατηρείται εξαιρετική απόδοση στην δυαδική κατηγοριοποίηση των κειμένων σε όλα τα μοντέλα. Η συγκριτικά μειωμένη τιμή στην ανάκληση της κλάσης ανωμαλιών (Anomaly) οφείλεται στο γεγονός ότι αυτή η κλάση είναι μειοψηφική στο σύνολο εκπαίδευσης, το οποίο αντιμετωπίστηκε σε πολύ καλό βαθμό από την Focal Loss. Ωστόσο, τα μοντέλα σε συνδυασμό με την Focal Loss παρά την μεγάλη ανισορροπία στις κλάσεις έφεραν πολύ καλά αποτελέσματα. Το μοντέλο που έφερε την καλύτερη απόδοση ήταν το RoBERTa με ορθότητα στο 99.98% και ανάκληση στην κλάση ανωμαλιών ίση με 99.64% ξεπερνώντας κατά 4 ποσοστιαίες μονάδες τα υπόλοιπα μοντέλα στην ίδια μετρική.

6.3.2 Δυαδική Κατηγοριοποίηση στο Edge-IIoTset Σύνολο Δεδομένων

		DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)		99.9733	96.6085	99.9653	99.9601	99.9578
Precision (%)	Benign	99.9991	95.5146	99.9881	99.9746	99.9704
	Malicious	99.9119	99.6704	99.9110	99.9256	99.9276
Recall (%)	Benign	99.9630	99.8769	99.9627	99.9688	99.9696
	Malicious	99.9980	88.8132	99.9716	99.9393	99.9295
F_1 score (%)	Benign	99.9811	97.6470	99.9754	99.9717	99.9700
	Malicious	99.9549	93.9291	99.9413	99.9325	99.9285

Πίνακας 6.2: Δυαδική Κατηγοριοποίηση στο Edge-IIoTset Σύνολο Δεδομένων

Στον πίνακα 6.2 παρατίθενται τα αποτελέσματα της δυαδικής κατηγοριοποίησης ροών δικτυακών πακέτων, των μοντέλων που υλοποιούνται σε αυτή την εργασία επάνω στο Edge-IIoTset σύνολο δεδομένων. Όλα τα μοντέλα παρουσιάζουν εξαιρετικές μετρικές ωστόσο η προσέγγιση προεπεξεργασίας των δικτυακών ροών σε κείμενα για κατηγοριοποίηση με το DistilBERT έφερε τα καλύτερα αποτελέσματα πετυχαίνοντας το υψηλότερο Accuracy (99.97%) καθώς και τις υψηλότερες F_1 μετρικές και στις δύο κλάσεις του προβλήματος (99.98% και 99.95% αντίστοιχα).

6.3.3 Πολυταξική Κατηγοριοποίηση στο Edge-IIoTset Σύνολο Δεδομένων

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.8648	89.4249	98.8519	98.5344	98.3778
Precision (%)	99.9868	94.6168	99.9988	99.9754	99.9741
Recall (%)	99.9712	99.7940	99.9762	99.9762	99.9778
F_1 score (%)	99.9790	97.1364	99.9875	99.9758	99.9760

Πίνακας 6.3: Μετρικές για την Κλάση Benign

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.8648	89.4249	98.8519	98.5344	98.3778
Precision (%)	98.7545	89.1182	98.1377	97.1911	95.9954
Recall (%)	96.6390	86.5261	97.2260	96.4371	96.7437
F_1 score (%)	97.6853	87.8030	97.6797	96.8126	96.3681

Πίνακας 6.4: Μετρικές για την Κλάση DDoS

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.8648	89.4249	98.8519	98.5344	98.3778
Precision (%)	87.6895	46.6837	88.5041	89.5630	90.6284
Recall (%)	98.7930	46.6503	97.7600	93.0807	89.3168
F_1 score (%)	92.9107	46.6670	92.9021	91.2880	89.9678

Πίνακας 6.5: Μετρικές για την Κλάση Injection

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.8648	89.4249	98.8519	98.5344	98.3778
Precision (%)	97.4193	59.5363	97.6014	93.0981	91.9718
Recall (%)	90.9967	16.4035	89.7493	91.1233	91.2679
F_1 score (%)	94.0985	25.7205	93.5108	92.1001	91.6185

Πίνακας 6.6: Μετρικές για την Κλάση Malware

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.8648	89.4249	98.8519	98.5344	98.3778
Precision (%)	98.9386	65.3659	98.9273	97.8851	97.9752
Recall (%)	97.5533	66.5677	97.8219	97.8644	97.8644
F_1 score (%)	98.2411	65.9613	98.3715	97.8747	97.9198

Πίνακας 6.7: Μετρικές για την Κλάση Information Gathering

Στους πίνακες 6.3, 6.4, 6.5, 6.6 και 6.7 παρουσιάζονται τα αποτελέσματα των υλοποιημένων μοντέλων για το πρόβλημα της πολυταξικής κατηγοριοποίησης ροών, στο σύνολο δεδομένων Edge-IIoTset. Και εδώ το DistilBERT έφερε τη μεγαλύτερη τιμή στο Accuracy (98.86%) από τα υπόλοιπα μοντέλα. Όσον αφορά την F_1 μετρική κάθε κλάσης που ισορροπεί μεταξύ Ακρίβειας και Ανάκλησης, το προτεινόμενο μοντέλο υπερτερεί των υπολοίπων στις κλάσεις DDoS, Injection και Malware. Στις κλάσεις Benign και Information Gathering ξεπερνιέται οριακά από τον αλγόριθμο XGBoost. Επειδή όμως η κλάση Benign αντιπροσωπεύει καλοήγη δείγματα, το προτεινόμενο μοντέλο έχει οριακά χειρότερη απόδοση μόνο σε ένα είδος επίθεσης από ένα μόνο μοντέλο. Από τις τιμές της Ανάκλησης η χειρότερη τιμή της ήταν 90.99% ($\approx 91\%$) στην κλάση Malware οπότε το προτεινόμενο μοντέλο είναι καλό να κατηγοριοποιεί δικτυακές ροές σε διάφορα είδη επιθέσεων υπερτερώντας στην πλειονότητα των περιπτώσεων αρκετές σύγχρονες μεθόδους μηχανικής μάθησης.

6.3.4 Δυαδική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων

		DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)		98.1560	67.7498	98.2153	96.1717	95.4794
Precision (%)	Benign	95.5446	97.2613	99.9885	93.9583	92.0819
	Malicious	99.5622	67.2820	97.3828	97.3123	97.2847
Recall (%)	Benign	99.1563	4.5007	94.7190	94.7407	94.7426
	Malicious	97.6470	99.9355	99.9945	96.8999	95.8543
F_1 score (%)	Benign	97.3169	8.6033	97.2825	94.3479	93.3933
	Malicious	98.5953	80.4205	98.6714	97.1057	96.5642

Πίνακας 6.8: Δυαδική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων

Στον πίνακα 6.8 φαίνονται τα πειραματικά αποτελέσματα όλων των μοντέλων στο IoT-23 σύνολο δεδομένων στο πρόβλημα της δυαδικής κατηγοριοποίησης. Παρατηρείται ότι το DistilBERT με τον XGBoost έφεραν τα καλύτερα αποτελέσματα στο σύνολο ελέγχου. Για τα δύο καλύτερα μοντέλα, παρατηρώντας τις F_1 μετρικές για τις δύο κλάσεις του προβλήματος συμπεραίνεται ότι είναι οριακά ισοδύναμα. Ιδιαιτερότητα σε αυτό το σύνολο δεδομένων είναι ότι οι κακόβουλες ροές ήταν περισσότερες από τις καλοήθειες, κάτι που δεν συμβαίνει πάντα σε αντίστοιχα σύνολα δεδομένων.

6.3.5 Πολυταξική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.1487	67.2723	98.2477	96.1863	95.4782
Precision (%)	95.7391	97.7974	99.9790	93.9040	91.9876
Recall (%)	98.9318	4.8229	94.8512	94.8747	94.8820
F_1 score (%)	97.3093	9.1925	97.3476	94.3869	93.4124

Πίνακας 6.9: Μετρικές για την Κλάση Benign

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.1487	67.2723	98.2477	96.1863	95.4782
Precision (%)	99.8298	100	99.9923	99.9923	99.9845
Recall (%)	99.9690	99.6283	99.9923	99.9923	99.9923
F_1 score (%)	99.8994	99.8138	99.9923	99.9923	99.9884

Πίνακας 6.10: Μετρικές για την Κλάση DDoS

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.1487	67.2723	98.2477	96.1863	95.4782
Precision (%)	100	81.1321	99.4350	99.4350	100
Recall (%)	100	97.7273	99.4350	99.4350	98.8701
F_1 score (%)	100	88.6598	99.4350	99.4350	99.4318

Πίνακας 6.11: Μετρικές για την Κλάση Okiru

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.1487	67.2723	98.2477	96.1863	95.4782
Precision (%)	99.3801	63.4592	97.0227	96.9289	96.8961
Recall (%)	97.3999	99.9548	99.9957	96.3380	95.0875
F_1 score (%)	98.3801	77.6317	98.4868	96.6325	95.9833

Πίνακας 6.12: Μετρικές για την Κλάση PartOfAHorizontalPortScan

	DistilBERT	MLP	XGBoost	Random Forest	Decision Tree
Accuracy (%)	98.1487	67.2723	98.2477	96.1863	95.4782
Precision (%)	99.5180	98.2801	99.7589	99.8397	99.7597
Recall (%)	99.12	64	99.2803	99.6401	99.6002
F_1 score (%)	99.3186	77.5194	99.5190	99.7398	99.6799

Πίνακας 6.13: Μετρικές για την Κλάση C&C (Command and Control)

Στους πίνακες 6.9, 6.10, 6.11, 6.12 και 6.13 παρουσιάζονται τα αποτελέσματα του προτεινόμενου και των κλασσικών μοντέλων για την πολυταξική κατηγοριοποίηση ροών στο IoT-23 σύνολο δεδομένων. Η απόδοση του προτεινόμενου μοντέλου είναι εξαιρετική σε αυτό το σύνολο δεδομένων με τιμή ορθότητας 98.14% ελάχιστα μικρότερη από το XGBoost (98.24%). Μελετώντας τις υπόλοιπες μετρικές για κάθε κλάση, παρατηρείται ότι έχει προβλέψει σωστά όλα τα δείγματα για την κλάση Okiru ξεπερνώντας τα υπόλοιπα μοντέλα. Στις κλάσεις DDoS και C&C (Command and Control) το προτεινόμενο μοντέλο έχει όμοια απόδοση με τα υπόλοιπα μοντέλα όσον αφορά την F_1 μετρική. Για την κλάση PartOfAHorizontalPortScan το προτεινόμενο μοντέλο έχει ισοδύναμη απόδοση με τον XGBoost και ξεπερνά τους Random Forest, MLP και Decision Tree. Μελετώντας την τιμή της ανάκλησης για την κλάση Benign το προτεινόμενο μοντέλο ξεπερνά σε απόδοση τα υπόλοιπα μοντέλα τουλάχιστον κατά 4 ποσοστιαίες μονάδες.

Κεφάλαιο 7

Εξηγήσιμη Τεχνητή Νοημοσύνη

Με την πρόοδο της τεχνητής νοημοσύνης δημιουργούνται όλο και πιο σύνθετα μοντέλα μάθησης των οποίων ο τρόπος λειτουργίας και η αρχιτεκτονική είναι αρκετά χαώδης και περίπλοκη, καθιστώντας πολλές φορές πολύ δύσκολο να εξηγηθεί πως ένα μοντέλο έφτασε στην πρόβλεψη μιας συγκεκριμένης εισόδου και γιατί το δείγμα αυτό ταξινομήθηκε στην κλάση που ταξινομήθηκε. Ακόμη, πολλοί τομείς της ανθρώπινης δραστηριότητας που ενσωματώνουν τεχνικές μηχανικής μάθησης στις υπηρεσίες τους όπως η ιατρική, η τραπεζική και η κυβερνοασφάλεια υποχρεώνονται από την νομοθεσία να παρέχουν εξηγήσεις για ενέργειες που τελούνται ως αποτέλεσμα πρόβλεψης των μοντέλων τους. Ως εκ τούτου, έχει αναδυθεί ο κλάδος της Εξηγήσιμης Τεχνητής Νοημοσύνης (Explainable Artificial Intelligence) ώστε να λυθούν τα παραπάνω προβλήματα. Ο κλάδος αυτός συνεισφέρει με τέτοιο τρόπο ώστε οι άνθρωποι να εμπιστεύονται περισσότερο τα αποτελέσματα των μοντέλων μάθησης και να σιγουρεύονται ότι τα μοντέλα προβλέπουν ό,τι προβλέπουν για το σωστό λόγο. Ειδικά στην κυβερνοασφάλεια η εξηγήσιμη τεχνητή νοημοσύνη, συνδράμει επικουρικά στο έργο ενός υπεύθυνου ασφαλείας με το να δείχνει για παράδειγμα το σημείο ενός αρχείου καταγραφής που προκάλεσε μία ανωμαλία ή τα χαρακτηριστικά μίας ροής πακέτων που ήταν τα πιο καθοριστικά στο να κατηγοριοποιηθεί η ροή σε ένα συγκεκριμένο είδος επίθεσης.

7.1 Θεωρητικό Υπόβαθρο Εξηγήσιμης Τεχνητής Νοημοσύνης

7.1.1 Κατηγορίες Τεχνικών Εξηγήσιμης Τεχνητής Νοημοσύνης

Τεχνικές Ανεξάρτητες του Μοντέλου Μηχανικής Μάθησης

Αυτές οι τεχνικές μπορούν να εφαρμοστούν σε οποιοδήποτε μοντέλο μηχανικής μάθησης, από γραμμικά μοντέλα και δέντρα αποφάσεων έως μοντέλα μάθησης συνόλου και μετασχηματιστές, δηλαδή ανεξάρτητα από την αρχιτεκτονική του και τους εσωτερικούς του μηχανισμούς. Αγνοούν, την εσωτερική του λειτουργία και ασχολούνται μόνο πως αλλάζουν οι προβλέψεις του μοντέλου συναρτήσει αλλαγών στις τιμές των χαρακτηριστικών εισόδου. Σε αυτές τις τεχνικές ανήκουν ενδεικτικά οι SHAP [40] και LIME [51].

Τεχνικές Εξαρτώμενες του Μοντέλου Μηχανικής Μάθησης

Οι τεχνικές αυτές, μπορούν να εφαρμοστούν μόνο σε συγκεκριμένα μοντέλα ή οικογένεια μοντέλων μηχανικής μάθησης, εκμεταλλευόμενες τα ιδιαίτερα χαρακτηριστικά της αρχιτεκτονικής τους. Παραδείγματα τέτοιων τεχνικών αποτελούν οι: Grad-CAM [56], DeepLIFT [57], Integrated Gradients [59], LRP [8] για μοντέλα νευρωνικών δικτύων ή η οπτικοποίηση του δέντρου απόφασης για δέντρα απόφασης.

Καθολικές Μέθοδοι

Οι Καθολικές Μέθοδοι (Global Methods) μελετούν την μέση επιρροή των τιμών των χαρακτηριστικών εισόδου στις προβλέψεις του μοντέλου. Για παράδειγμα σε ένα σύνολο από δείγματα μπορεί να υπολογίζεται από τέτοιες μεθόδους, για κάθε χαρακτηριστικό η μέση τιμή των βαρών που έχει το χαρακτηριστικό αυτό στην πρόβλεψη κάθε δείγματος.

Τοπικές Μέθοδοι

Οι Τοπικές Μέθοδοι (Local Methods) χρησιμοποιούνται για να παρέχουν εξηγήσεις μεμονωμένων προβλέψεων του μοντέλου που μελετούν. Βρίσκουν και παρουσιάζουν δηλαδή τους παράγοντες που οδήγησαν το μοντέλο να κατηγοριοποιήσει ένα δείγμα σε μία κλάση.

7.1.2 Τεχνικές Εξηγήσιμης Τεχνητής Νοημοσύνης

Παρακάτω παρουσιάζονται οι δύο βασικές τεχνικές εξηγήσιμης τεχνητής νοημοσύνης που θα χρησιμοποιηθούν για την εξήγηση των προβλέψεων των γλωσσικών μοντέλων που πραγματεύεται η εργασία. Επιλέχθηκαν δύο τεχνικές, η SHAP και η Integrated Gradients η πρώτη για την ικανότητα της να εφαρμόζεται σε οποιοδήποτε μοντέλο και η δεύτερη για την ικανότητα της να εξηγήσει τις προβλέψεις οποιουδήποτε νευρωνικού δικτύου συμπεριλαμβανομένου και του BERT.

SHAP

Η SHAP (SHapley Additive exPlanations) [40] είναι μία τεχνική εξηγήσιμης τεχνητής νοημοσύνης ανεξάρτητη του μοντέλου μηχανικής μάθησης, η οποία βασίζεται στην θεωρία παιγνίων. Πρόκειται για μία τοπική μέθοδο, δηλαδή παρέχει εξηγήσεις για συγκεκριμένες προβλέψεις ενός μοντέλου αν και μπορεί να ρυθμιστεί κατάλληλα ώστε να λειτουργεί ως καθολική.

Η SHAP στην περίπτωση που εξηγεί κλασσικά μοντέλα μηχανικής μάθησης που λειτουργούν με διανύσματα ως εισόδους τους, μετρά το βάρος που έχει κάθε χαρακτηριστικό στην πρόβλεψη του μοντέλου. Το βάρος του κάθε χαρακτηριστικού σε μία πρόβλεψη ενός δείγματος είναι η Shapley τιμή του.

Σε ένα γλωσσικό μοντέλο όπως το BERT η τεχνική SHAP έχει θεμελιώδεις ομοιότητες όπως και όταν χρησιμοποιείται σε κλασσικά μοντέλα αλλά και μικρές διαφορές. Αρχικά στο BERT αντί χαρακτηριστικών έχουμε σύμβολα τα οποία έχουν παραχθεί από τον tokenizer τα οποία λαμβάνουν και αυτά μία Shapley τιμή η οποία δείχνει την ισχύ του κάθε συμβόλου

στην πρόβλεψη του κειμένου στο οποίο ανήκει. Η διαφορά εδώ με τα συνηθισμένα μοντέλα είναι ο υπολογισμός των Shapley τιμών. Στα μοντέλα μηχανικής μάθησης που δουλεύουν με διανύσματα στην είσοδο τους η Shapley τιμή ενός χαρακτηριστικού δίνεται από τη σχέση 7.1

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} (f(S \cup \{j\}) - f(S)) \quad (7.1)$$

Η τεχνική για κάθε χαρακτηριστικό j του συνόλου χαρακτηριστικών F του προβλήματος, υπολογίζει για κάθε υποσύνολο S του F που δεν περιλαμβάνει το j , τη διαφορά των προβλέψεων του μοντέλου με είσοδο το S και το S αλλά έχοντας ξαναπροσθέσει το j . Ουσιαστικά, η τεχνική ποσοτικοποιεί την αλλαγή στην έξοδο του μοντέλου αν αφαιρεθεί κάποιο χαρακτηριστικό από τα δεδομένα. Έτσι ένα σημαντικό χαρακτηριστικό στην πρόβλεψη του μοντέλου θα έχει και μεγάλη Shapley τιμή μιας και η πρόβλεψη του μοντέλου όταν αυτό απουσιάζει θα αλλάζει πολύ. Στα κλασσικά μοντέλα δεν είναι δυνατή η αφαίρεση ενός χαρακτηριστικού από το S και συνήθως αντικαθίσταται η τιμή του με τη μέση τιμή που έχει στο background σύνολο δεδομένων. Αυτό είναι συνήθως ένα υποσύνολο του συνόλου εκπαίδευσης. Στην περίπτωση των γλωσσικών μοντέλων συνήθως είτε αφαιρείται το σύμβολο από το κείμενο ή αντικαθίσταται με κάποιο άλλο ειδικό σύμβολο όπως το [MASK] ή το [PAD]. Τα παραπάνω είναι συνήθως λεπτομέρειες της εκάστοτε υλοποίησης του αλγορίθμου SHAP, οι οποίες ωστόσο επηρεάζουν τα αποτελέσματα. Ανεξαρτήτως του μοντέλου μάθησης, στον αλγόριθμο 7.1.2 φαίνεται η διαδικασία παραγωγής των Shapley τιμών.

Ψευδοκώδικας Υπολογισμού Shapley Τιμών

```

1: Input: Σύνολο χαρακτηριστικών  $F$ , μοντέλο μάθησης  $f$ .
2: Output: Shapley τιμές κάθε χαρακτηριστικού  $j$ .
3: for all  $j \in F$  do
4:    $\phi_j \leftarrow 0$ 
5:   for all  $S \subseteq F \setminus \{j\}$  do
6:      $\phi_j = \phi_j + \frac{|S|!(|F| - |S| - 1)!}{|F|!} \cdot (f(S \cup \{j\}) - f(S))$ 
7:   end for
8: end for
```

Integrated Gradients

Η Integrated Gradients [59] είναι μία τοπική τεχνική εξηγήσιμης τεχνητής νοημοσύνης η οποία εφαρμόζεται σε μοντέλα βαθιάς μάθησης, παρέχοντας εξηγήσεις για τις προβλέψεις ενός νευρωνικού δικτύου. Ως μέθοδος έχει σημαντικές ομοιότητες με την SHAP αλλά και διαφορές. Η βασική ιδέα σε αυτή τη μέθοδο είναι ότι κάθε χαρακτηριστικό λαμβάνει όπως και στην SHAP μία τιμή που καθορίζει το βάρος του στην πρόβλεψη του μοντέλου. Συγκεκριμένα, χρησιμοποιείται η μερική παράγωγος της εξόδου του μοντέλου ως προς το χαρακτηριστικό αυτό δηλαδή πόσο αλλάζει η πρόβλεψη του μοντέλου αν αλλάξει λίγο η τιμή αυτού του χαρακτηριστικού. Ωστόσο η κύρια διαφορά με την προηγούμενη τεχνική είναι ότι εδώ η τεχνική

για την εκάστοτε είσοδο δημιουργεί μέσω παρεμβολής μία σειρά από εισόδους ξεκινώντας από μία αρχική τιμή μέχρι να καταλήξει στην υπο εξήγηση είσοδο. Αυτή η αρχική τιμή είναι μία “ ουδέτερη είσοδος ” όπως ένα μηδενικό διάνυσμα σε ένα πολυεπίπεδο αντίληπτο, ένα άδειο κείμενο ή μία μηδενική ενσωμάτωση στην περίπτωση ενός γλωσσικού μοντέλου. Έπειτα για όλες αυτές τις εισόδους η τεχνική υπολογίζει την μεταβολή της πρόβλεψης του δικτύου για μικρή μεταβολή στο υπο μελέτη χαρακτηριστικό. Τέλος, προσθέτει όλες αυτές τις μεταβολές και πολλαπλασιάζει το αποτέλεσμα με την διαφορά της τιμής του χαρακτηριστικού στην είσοδο και της τιμής του στην αρχική είσοδο. Οπότε το βάρος του συγκεκριμένου χαρακτηριστικού μιας εισόδου δίνεται από τη σχέση 7.2

$$Integrated_gradient_i(x) = (x_i - x'_i) \int_0^1 \frac{\partial F(x' + \alpha \cdot (x - x'))}{\partial x_i} d\alpha \quad (7.2)$$

7.2 Μετρικές Αξιολόγησης Τεχνικών Εξηγήσιμης Τεχνητής Νοημοσύνης

7.2.1 Sensitivity

Η Ευαισθησία (Sensitivity) [19] είναι μία μετρική αξιολόγησης τεχνικών εξηγήσιμης τεχνητής νοημοσύνης η οποία μετρά το πόσο μεταβάλλεται η έξοδος της τεχνικής (τα βάρη των χαρακτηριστικών) όταν μετατοπίζεται ελαφρώς η είσοδος που θέλουμε να εξηγηθεί. Η Ευαισθησία περιγράφεται από την σχέση 7.3:

$$Sensitivity_{MAX}(\Phi, f, x, r) = \max_{\|y-x\| \leq r} \|\Phi(f, y) - \Phi(f, x)\| \quad (7.3)$$

Όπου Φ η μέθοδος εξηγήσιμης τεχνητής νοημοσύνης όπως η SHAP ή η Integrated Gradients που αναφέρθηκαν παραπάνω, f ο αλγόριθμος μάθησης που θέλουμε να εξηγηθούν οι προβλέψεις του και r συνήθως κάποιου είδους θόρυβος. Μία τεχνική η οποία παρουσιάζει μεγάλη ευαισθησία για μικρές αλλαγές στην είσοδο δεν είναι σταθερή άρα και λιγότερο έμπιστη.

7.2.2 Infidelity

Η Αναξιοπιστία (Infidelity) [67] είναι μία μετρική εξηγησιμότητας η οποία υπολογίζει το μέσο τετραγωνικό σφάλμα μεταξύ της προβλεφθείσας και της πραγματικής αλλαγής στην πρόβλεψη ενός μοντέλου μάθησης όταν μία είσοδος μετατοπίζεται ελαφρώς μέσω κάποιου θορύβου. Η Αναξιοπιστία περιγράφεται από την εξίσωση 7.4:

$$Infidelity(\Phi, f, x) = E_{I \sim \mu_I} [(I^\top \Phi(f, x) - (f(x) - f(x - I)))^2] \quad (7.4)$$

Όπου Φ η τεχνική εξηγησιμότητας, f το μοντέλο μάθησης, x η είσοδος που εξηγείται και I θόρυβος μέσης τιμής μ_I .

7.2.3 Faithfulness

Η Πιστότητα (Faithfulness) [29] είναι μία μετρική η οποία μετρά πόσο μία τεχνική εξηγήσιμης τεχνητής νοημοσύνης προσεγγίζει τον τρόπο με τον οποίο ένα μοντέλο μάθησης καταλήγει στις προβλέψεις του. Ουσιαστικά η μετρική αυτή λαμβάνει το αποτέλεσμα μίας τεχνικής εξηγήσιμης τεχνητής νοημοσύνης δηλαδή ένα σύνολο από χαρακτηριστικά τα οποία η τεχνική θεωρεί ως σημαντικά στις προβλέψεις του μοντέλου. Έπειτα αφαιρεί αυτά τα χαρακτηριστικά από το αρχικό σύνολο χαρακτηριστικών και τελεί εκ νέου την πρόβλεψη στο μειωμένο αυτό σύνολο. Εάν αλλάξει πολύ η πρόβλεψη του μοντέλου τότε τα χαρακτηριστικά που αφαιρέθηκαν όντως ήταν σημαντικά στην πρόβλεψη και η τεχνική σωστά τα θεώρησε έτσι. Οπότε η τεχνική είναι πιστή ως προς τις αρχικές υποθέσεις της. Υπάρχουν πολλοί ορισμοί στον ορισμό της Πιστότητας αλλά δύο κύριες εκφράσεις της αποτελούν η εξίσωση 7.5:

$$Faithfulness = \left| \frac{f(x) - f(x \setminus S)}{f(x)} \right| \quad (7.5)$$

είτε απλά η 7.6:

$$Faithfulness = |f(x) - f(x \setminus S)| \quad (7.6)$$

Όπου $f(x)$ η πρόβλεψη του μοντέλου για την είσοδο x και $f(x \setminus S)$ η πρόβλεψη του μοντέλου για την είσοδο x όταν αφαιρεθεί από αυτή το σύνολο των χαρακτηριστικών S που η τεχνική θεωρεί σημαντικά. Στα Μεγάλα Γλωσσικά Μοντέλα η αντίστοιχη μετρική καλείται πολλές φορές ως Πληρότητα (Comprehensiveness) ενώ υπάρχει και η αντίστροφη μετρική, η Επάρκεια (Sufficiency) η οποία εκφράζεται στη σχέση 7.7

$$Sufficiency = f(x) - f(S) \quad (7.7)$$

Αν η διαφορά είναι μικρή τότε τα χαρακτηριστικά (στην προκειμένη περίπτωση σύμβολα) που θεώρησε η τεχνική σημαντικά επαρκούν για την πρόβλεψη. Το S στην προκειμένη περίπτωση είναι το σύνολο των συμβόλων που η μέθοδος θεώρησε ως σημαντικά.

Συσχέτιση με τις Τιμές Leave One Out

Η συσχέτιση των βαρών κάθε συμβόλου στην πρόβλεψη του μοντέλου, που έχουν παραχθεί από κάποια τεχνική εξηγησιμότητας με τις βαθμολογίες Leave One Out, είναι η τιμή του συντελεστή Kendall Tau [32] μεταξύ των δύο παραπάνω μεγεθών. Η τιμή Leave One Out ενός συμβόλου είναι η αλλαγή στην πρόβλεψη του μοντέλου όταν αφαιρείται μόνο το συγκεκριμένο σύμβολο από όλα τα σύμβολα που απαρτίζεται ένα κείμενο. Αυτή η τιμή θεωρείται το πραγματικό βάρος του συμβόλου. Οπότε αυτή η μετρική υπολογίζει πόσο καλά η κάθε τεχνική προσεγγίζει τα πραγματικά βάρη των συμβόλων στις προβλέψεις του μοντέλου. Αποτελεί μία μετρική Πιστότητας.

AOPC Comprehensiveness

Η Πληρότητα όπως ορίστηκε προηγουμένως θεωρεί ένα σύνολο χαρακτηριστικών S ως σημαντικά ή μη σημαντικά στις προβλέψεις ενός μοντέλου, χωρίς να λαμβάνει υπόψη τα βάρη

των χαρακτηριστικών. Η AOPC Comprehensiveness (Area Over the Perturbation Curve Comprehensiveness) [17] λαμβάνει υπόψη όχι μόνο αν ένα χαρακτηριστικό είναι σημαντικό αλλά και πόσο σημαντικό (η τιμή που παίρνει από την τεχνική εξηγησιμότητας). Η συγκριμένη μετρική αρχικά απομονώνει τα χαρακτηριστικά με αρνητικά βάρη δηλαδή αυτά που δεν συνεισφέρουν θετικά στην πρόβλεψη της κλάσης για την οποία ζητείται να εξηγηθεί η πρόβλεψη και έπειτα υπολογίζει τη μέση τιμή των τιμών της Πληρότητας όταν αφαιρούνται τα x χαρακτηριστικά με τα μεγαλύτερα βάρη κάθε φορά.

AOPC Sufficiency

Η Area Over the Perturbation Curve Sufficiency [17] αποτελεί την επέκταση της Επάρκειας όπως αποτελεί επέκταση της Πληρότητας η AOPC Comprehensiveness που αναφέρθηκε στην παραπάνω παράγραφο. Τόσο η AOPC Comprehensiveness όσο και η AOPC Sufficiency είναι και αυτές μετρικές που εκφράζουν την Πιστότητα μίας τεχνικής εξηγήσιμης τεχνητής νοημοσύνης. Στους παρακάτω πίνακες, καταγράφονται οι τιμές αυτών των μετρικών επάνω στις τεχνικές SHAP και Integrated Gradients.

7.2.4 Αποτελέσματα Μετρικών Εξηγησιμότητας

Επειδή οι μέθοδοι εξηγησιμότητας που αναφέρθηκαν προηγουμένως, εφαρμόζονται επάνω σε γλωσσικά μοντέλα οι μετρικές που θα χρησιμοποιηθούν για την σύγκριση τους είναι οι AOPC Comprehensiveness και Sufficiency και η Συσχέτιση με τις τιμές Leave One Out, όλες μετρικές Πιστότητας.

HDFS

	AOPC Comprehensiveness	AOPC Sufficiency	Tau Correlation Leave One Out
SHAP	0.478162	0.193101	0.077371
Integrated Gradients	0.384065	0.276768	0.006568

Πίνακας 7.1: Αποτελέσματα Δυναμικού Μοντέλου DistilBERT στο HDFS Σύνολο Δεδομένων.

Στην δυαδική κατηγοριοποίηση των ομαδοποιημένων εγγράφων των αρχείων καταγραφής του συνόλου δεδομένων HDFS, η τεχνική SHAP ξεπέρασε την Integrated Gradients πετυχαίνοντας μεγαλύτερη τιμή AOPC Comprehensiveness (0.47 έναντι 0.38) και συνάμα μικρότερη τιμή AOPC Sufficiency (0.19 έναντι 0.27) καθιστώντας την καλύτερη για να παρέχει εξηγήσεις των αποτελεσμάτων του DistilBERT. Η SHAP πετυχαίνει καλύτερη τιμή στην Tau Correlation One Out 0.07 έναντι 0.006 της Integrated Gradients.

	AOPC Comprehensiveness	AOPC Sufficiency	Tau Correlation Leave One Out
SHAP	0.732002	0.808891	0.026985
Integrated Gradients	0.802553	0.804183	0.003643

Πίνακας 7.2: Αποτελέσματα Δυαδικού Μοντέλου ALBERT στο HDFS Σύνολο Δεδομένων

Στην περίπτωση που το μοντέλο προς εξήγηση είναι το ALBERT, η Integrated Gradients απέφερε καλύτερη τιμή AOPC Comprehensiveness (0.8 έναντι 0.73 της SHAP) και συνάμα μικρότερη τιμή AOPC Sufficiency (0.808 έναντι 0.804 της SHAP). Η SHAP σημείωσε καλύτερη τιμή στην Tau Correlation Leave One Out από την Integrated Gradients, συγκεκριμένα 0.02 έναντι 0.003.

	AOPC Comprehensiveness	AOPC Sufficiency	Tau Correlation Leave One Out
SHAP	0.300317	0.470687	0.072155
Integrated Gradients	0.452867	0.602336	0.020303

Πίνακας 7.3: Αποτελέσματα Δυαδικού Μοντέλου BERT στο HDFS Σύνολο Δεδομένων

Στην κατηγοριοποίηση των κειμένων από το BERT η SHAP ξεπερνά την Integrated Gradients στις μετρικές AOPC Sufficiency και Tau Correlation Leave One Out με τιμές 0.47 έναντι 0.6 και 0.07 έναντι 0.02 αντίστοιχα. Η Integrated Gradients εδώ είχε καλύτερη τιμή AOPC Comprehensiveness από την SHAP (0.45 έναντι 0.3).

	AOPC Comprehensiveness	AOPC Sufficiency	Tau Correlation Leave One Out
SHAP	0.538767	0.396337	0.018691
Integrated Gradients	0.659884	0.475647	0.014792

Πίνακας 7.4: Αποτελέσματα Δυαδικού Μοντέλου RoBERTa στο HDFS Σύνολο Δεδομένων

Για την δυαδική κατηγοριοποίηση του RoBERTa στο HDFS σύνολο δεδομένων, η SHAP πετυχαίνει καλύτερη απόδοση από την Integrated Gradients στις μετρικές AOPC Sufficiency και Tau Correlation Leave One Out με τιμές 0.39 έναντι 0.47 και 0.018 έναντι 0.014 αντίστοιχα. Αναφορικά με την μετρική AOPC Comprehensiveness, η Integrated Gradients πέτυχε καλύτερη τιμή (0.65) από την SHAP (0.53). Οι μέτριες τιμές στην AOPC Comprehensiveness σημαίνουν πως το μοντέλο δεν βασίζεται μόνο στα συγκεκριμένα-λίγα σύμβολα που θεώρησε σημαντικά η τεχνική για να κάνει τις προβλέψεις του, δηλαδή η προβλεπτική δύναμη των συμβόλων είναι πιο ομοιόμορφα κατανομημένη. Ουσιαστικά το μοντέλο χωρίς τα σημαντικά σύμβολα κατάφερε να μην αλλάξει τόσο η πρόβλεψη του βασιζόμενο στα γύρω συμφραζόμενα. Αυτή η συμπεριφορά είναι αναμενόμενη για ένα αμφίδρομο γλωσσικό μοντέλο.

IoT-23

	AOPC Comprehensiveness	AOPC Sufficiency	Tau Correlation Leave One Out
SHAP	0.661798	0.017548	0.138031
Integrated Gradients	0.519605	0.144175	0.059591

Πίνακας 7.5: Αποτελέσματα Δυαδικού Μοντέλου στο IoT-23 Σύνολο Δεδομένων

Στον πίνακα 7.5 φαίνονται τα αποτελέσματα των τεχνικών SHAP και Integrated Gradients στο σύνολο δεδομένων IoT-23 στο πρόβλημα της δυαδικής ταξινόμησης. Η τεχνική SHAP πετυχαίνει τιμή AOPC Comprehensiveness ίση με 0.66 ενώ η Integrated Gradients ίση με 0.51. Έπειτα, όσον αφορά το AOPC Sufficiency, η SHAP πετυχαίνει μικρότερη τιμή 0.01 έναντι 0.14 της Integrated Gradients. Η εικόνα που δίνουν οι τιμές των δύο αυτών μετρηκών είναι ότι η SHAP είναι καταλληλότερη για να εξηγή τις προβλέψεις του προτεινόμενου μοντέλου. Όσον αφορά τις τιμές της μετρικής Tau Correlation Leave One Out, η SHAP επιτυγχάνει τιμή ίση με 0.13 έναντι 0.05 της Integrated Gradients (καλύτερη η SHAP). Ωστόσο, και οι δύο τιμές βρίσκονται κοντά στο μηδέν που σημαίνει ότι ενώ και οι δύο μέθοδοι είναι σχετικά καλές στο να εντοπίζουν τα σημαντικά σύμβολα στις προβλέψεις του μοντέλου, δεν είναι ταυτόχρονα τόσο καλές στο να υπολογίζουν ακριβώς πόσο κάθε σύμβολο συνεισφέρει πραγματικά στην πρόβλεψη.

	AOPC Comprehensiveness	AOPC Sufficiency	Tau Correlation Leave One Out
SHAP	0.874244	0.108397	0.125569
Integrated Gradients	0.823597	0.155728	0.141568

Πίνακας 7.6: Αποτελέσματα Πολυταξικού Μοντέλου στο IoT-23 Σύνολο Δεδομένων

Η εικόνα στην πολυταξική κατηγοριοποίηση είναι αντίστοιχη με την δυαδική, όπου η AOPC Comprehensiveness κυμαίνεται από 0.87 στην SHAP και 0.82 στην Integrated Gradients. Η AOPC Sufficiency λαμβάνει τις τιμές 0.1 στην SHAP και 0.15 στην Integrated Gradients. Και εδώ από τις τιμές των δύο προηγούμενων μετρηκών η SHAP δείχνει ικανότερη. Εδώ η τιμή της Tau Correlation Leave One Out στην Integrated Gradients είναι λίγο καλύτερη από της SHAP (0.14 έναντι 0.12) που σημαίνει πως είναι λίγο καλύτερη στο να προσεγγίζει την πραγματική βαρύτητα κάθε συμβόλου στις προβλέψεις του μοντέλου. Ωστόσο επειδή και οι δύο τιμές είναι κοντά στο μηδέν, οι τεχνικές δεν είναι τόσο ικανές να προσεγγίζουν γενικά τα πραγματικά βάρη των συμβόλων στις προβλέψεις του προτεινόμενου μοντέλου, διατηρούν όμως την ικανότητα να εντοπίζουν τα σημαντικά σύμβολα.

Edge-IIoTset

	AOPC Comprehensiveness	AOPC Sufficiency	Tau Correlation Leave One Out
SHAP	0.743804	0.001588	0.104599
Integrated Gradients	0.721363	0.013199	0.065262

Πίνακας 7.7: Αποτελέσματα Δυναδικού Μοντέλου στο Edge-IIoTset Σύνολο Δεδομένων

Ο πίνακας 7.7 δείχνει την απόδοση των τεχνικών εξηγησιμότητας για τη δυαδική κατηγοριοποίηση στο Edge-IIoTset του μοντέλου DistilBERT. Η εικόνα εδώ είναι αντίστοιχη με την κατηγοριοποίηση στο IoT-23. Και εδώ η SHAP υπερτερεί της Integrated Gradients με τιμές AOPC Comprehensiveness 0.74 και 0.72 αντίστοιχα και τιμές AOPC Sufficiency 0.001 και 0.01 αντίστοιχα. Η τιμή της Tau Correlation Leave One Out είναι 0.1 στην SHAP και 0.06 στην Integrated Gradients. Ομοίως βάσει αυτής της μετρικής η SHAP θεωρείται καταλληλότερη ωστόσο και οι δύο διατηρούν χαμηλή ικανότητα να προσεγγίζουν ικανοποιητικά τα πραγματικά βάρη κάθε συμβόλου.

	AOPC Comprehensiveness	AOPC Sufficiency	Tau Correlation Leave One Out
SHAP	0.795728	0.058078	0.068549
Integrated Gradients	0.775055	0.116979	0.062290

Πίνακας 7.8: Αποτελέσματα Πολυταξικού Μοντέλου στο Edge-IIoTset Σύνολο Δεδομένων

Αντίστοιχα σύμφωνα με τον πίνακα 7.8, η τεχνική SHAP υπερτερεί με καλύτερες μετρικές Comprehensiveness, Sufficiency και Tau Correlation Leave One Out από την Integrated Gradients και συγκεκριμένα με 0.79 έναντι 0.77, 0.05 έναντι 0.11 και 0.0685 έναντι 0.0622 αντίστοιχα.

Κεφάλαιο 8

Σχετικές Εργασίες και Μελέτη Βιβλιογραφίας

Σε αυτό το κεφάλαιο γίνεται μία μελέτη της βιβλιογραφίας στα κοινά σύνολα δεδομένων στα ίδια προβλήματα και συγκρίνονται τα αποτελέσματα των μελετούμενων εργασιών με τα προτεινόμενα μοντέλα αυτής διπλωματικής. Ακόμη, παρουσιάζεται και μία εργασία σε ένα παραπλήσιο πρόβλημα σε άλλα σύνολα δεδομένων που δεν μελετήθηκαν εδώ.

8.1 Σχετικές Εργασίες για Ανίχνευση Ανωμαλιών Σε Αρχεία Καταγραφής Εφαρμογών

HDFS

Crispin Almodovar et al.

Στην εργασία [4] των Crispin Almodovar et al. μελετάται η χρήση ενός προεκπαιδευμένου γλωσσικού μοντέλου BERT στην ανίχνευση ανωμαλιών επάνω σε αρχεία καταγραφής εφαρμογών. Συγκεκριμένα, χρησιμοποιούνται τεχνικές αυτοεπιβλεπόμενης μάθησης προκειμένου το μοντέλο να μάθει από τα κανονικά δεδομένα και να δημιουργήσει ένα κατώφλι πέρα από το οποίο ένα δείγμα θα θεωρείται ανωμαλία κατά την αξιολόγηση. Οι ερευνητές παρουσίασαν και τα αποτελέσματα του μοντέλου τους επάνω σε άλλα σύνολα δεδομένων ωστόσο παρουσιάζονται μόνο τα αποτελέσματα στο HDFS σύνολο δεδομένων για να γίνει μία σύγκριση με το μοντέλο της διπλωματικής. Οπότε, στον πίνακα 8.1 παρουσιάζονται τα αποτελέσματα για το HDFS σύνολο δεδομένων.

Μοντέλο	Precision (%)	Recall (%)	F_1 score (%)
LogFiT (Προτεινόμενο δημιουργών)	99.78	90.7	95.02
DeepLog	100	60.9	75.7
LogBERT	24.02	82.8	37.24

Πίνακας 8.1: Δυαδική Κατηγοριοποίηση του Μοντέλου LogFiT των Crispin Almodovar et al. [4] στο HDFS Σύνολο Δεδομένων

Το προτεινόμενο μοντέλο των δημιουργών το LogFiT παρουσιάζει εξαιρετική τιμή Ακρίβειας (99.78%) και πολύ καλή τιμή στην Ανάκληση (90.7%). Πέτυχε την καλύτερη απόδοση από τα υπόλοιπα μοντέλα που δοκίμασαν οι ερευνητές. Σημειώνεται πως τα αποτελέσματα που παρουσιάζονται στον πίνακα 8.1 αφορούν την κλάση ανωμαλιών.

Συγκρίνοντας το μοντέλο LogFiT με το έργο αυτής της διπλωματικής, παρατηρείται ότι η Ακρίβεια του (99.78%) είναι ισοδύναμη με την Ακρίβεια των μοντέλων αυτής της διπλωματικής για την κλάση ανωμαλιών, όπου κυμαίνεται μεταξύ 99.2% και 99.76% σύμφωνα με τον πίνακα 6.1. Όσον αφορά την Ανάκληση της κλάσης ανωμαλιών το μοντέλο των ερευνητών πετυχαίνει τιμή ίση με 90.7% έναντι των μοντέλων αυτού του έργου όπου κυμαίνεται μεταξύ 95.6% στο χειρότερο μοντέλο και 99.6% στο καλύτερο. Η ανώτερη απόδοση του μοντέλου αυτής της διπλωματικής οφείλεται ενδεχομένως στην καλύτερη προεπεξεργασία των αρχείων καταγραφής και κυρίως στο γεγονός ότι αυτή η εργασία χρησιμοποιεί μεθόδους επιβλεπόμενης μάθησης στην οποία εάν τα χαρακτηρισμένα δεδομένα είναι αρκετά και υψηλής ποιότητας συνήθως επιτυγχάνουν καλύτερα αποτελέσματα από μεθόδους ημιεπιβλεπόμενης μάθησης.

Yihan Zhou et al.

Στην εργασία [69] των Yihan Zhou et al. προτείνεται μια διαφορετική προσέγγιση στην προεπεξεργασία των εγγραφών αρχείων καταγραφής, συγκεκριμένα στην συντακτική ανάλυση τους (parsing) με χρήση Μεγάλων Γλωσσικών Μοντέλων. Το ChatGPT [12] χρησιμοποιείται για αυτό το σκοπό και έπειτα αξιοποιείται κάποιο μοντέλο κωδικοποιητή εξειδικευμένο για ανίχνευση ανωμαλιών σε αρχεία καταγραφής όπως το LogBERT [27]. Τα πειράματα έγιναν και σε άλλα σύνολα δεδομένων όπως το BGL [46] αλλά εδώ παρουσιάζονται μόνο τα αποτελέσματα της προσέγγισης των ερευνητών πάνω στο σύνολο δεδομένων HDFS ώστε να γίνει σύγκριση με τα μοντέλα αυτής της εργασίας. Το προτεινόμενο μοντέλο τους απέφερε τα αποτελέσματα στο HDFS σύνολο δεδομένων που φαίνονται στον πίνακα 8.2.

Μοντέλο	Precision (%)	Recall (%)	F_1 score (%)
ChatGPT με LogBERT	89.4	85.2	87.4
Drain με LogBERT	87.1	78.2	82.3
AEL με LogBERT	86.5	79.4	81.2

Πίνακας 8.2: Αποτελέσματα Προτεινόμενου Μοντέλου στο HDFS Σύνολο Δεδομένων, Yihan Zhou et al. [69]

Το καλύτερο μοντέλο των ερευνητών ήταν ο συνδυασμός του ChatGPT και του LogBERT [27] στο HDFS όπου η Ακρίβεια της κλάσης ανωμαλιών ήταν 89.4% ενώ η Ανάκληση της ίση με 85.2% έναντι των μοντέλων αυτής της εργασίας που είχαν Ακρίβεια στην κλάση Ανωμαλιών μεταξύ 99.2% και 99.76% και Ανάκληση μεταξύ 95.6% και 99.6% σύμφωνα με τον πίνακα 6.1. Η καλύτερη απόδοση των μοντέλων αυτής της εργασίας οφείλεται μεταξύ άλλων στο γεγονός ότι εδώ χρησιμοποιείται επιβλεπόμενη μάθηση.

Mingyang Zhang et al.

Οι Mingyang Zhang et al. παρουσιάζουν το LogST [68], ένα μοντέλο ημιεπιβλεπόμενης μάθησης με στόχο την ανίχνευση ανωμαλιών στα αρχεία καταγραφής του συνόλου δεδομένων HDFS. Το μοντέλο χρησιμοποιεί το SBERT [50] και έναν συνδυασμό αλγορίθμων μείωσης διαστατικότητας, συσταδοποίησης και μίας Περιφραγμένης Επαναλαμβανόμενης Μονάδας (Gated Recurrent Unit ή GRU) [14] ώστε να εντοπίζει τις ανωμαλίες στα αρχεία καταγραφής. Στον πίνακα 8.3 φαίνονται τα αποτελέσματα του προτεινόμενου μοντέλου στο HDFS σύνολο δεδομένων. Σημειώνεται ότι επειδή τα αποτελέσματα του προτεινόμενου μοντέλου παρουσιάζονταν σε μορφή γραφήματος οι τιμές των μετρικών στον πίνακα 8.3 είναι προσεγγιστικές.

Ποσοστό (%)	Precision (%)	Recall (%)	F_1 score (%)
0.005	≈ 99	≈ 98	≈ 99
0.01	≈ 98	≈ 97	≈ 98
0.1	≈ 99	≈ 96	≈ 97.5
0.2	≈ 97	≈ 98	≈ 97.5
0.5	≈ 98	≈ 96	≈ 97

Πίνακας 8.3: Αποτελέσματα Μοντέλου LogST [68] στο HDFS (Mingyang Zhang et al.)

Οι Mingyang Zhang et al. προτείνουν ως μοντέλο την περίπτωση που χρησιμοποιείται το 50% των χαρακτηρισμένων δειγμάτων του συνόλου εκπαίδευσης στο σύνολο δεδομένων HDFS. Οπότε το προτεινόμενο μοντέλο των δημιουργών έχει Ακρίβεια στην κλάση ανωμαλιών ίση με 98% περίπου, έναντι των μοντέλων αυτής της διπλωματικής κυμαινόμενη μεταξύ 99.2% και 99.76% και Ανάκληση ίση με 96% περίπου έναντι 95.6% και 99.6% (πίνακας 6.1). Η προσέγγιση των ερευνητών είναι πρωτοποριακή και επιτυγχάνει απόδοση εφάμιλλη με τα προτεινόμενα μοντέλα αυτού του έργου.

8.2 Σχετικές Εργασίες σε Άλλα Σύνολα Δεδομένων

A. Alzu'bi et al.

Στην εργασία [5] οι A. Alzu'bi et al., διεξάγουν μία μελέτη εφαρμογής διάφορων αλγορίθμων μηχανικής και βαθιάς μάθησης στην κατηγοριοποίηση εγγραφών αρχείων καταγραφής είτε σε κατηγορίες επιθέσεων είτε σε είδη συμβάντων, σε διαφορετικά σύνολα δεδομένων. Συγκεκριμένα, χρησιμοποιούνται τα σύνολα δεδομένων AIT [33][34], MACCDC 2012 [42], TLDCDE

[61] καθώς και ένα σύνολο δεδομένων που κατασκεύασαν οι ίδιοι οι δημιουργοί για τους σκοπούς της εργασίας. Η μελέτη απέφερε τα αποτελέσματα στο συνδυαστικό σύνολο δεδομένων που φαίνονται στον πίνακα 8.4. Σημειώνεται ότι παρουσιάζονται μόνο τα μοντέλα μηχανικής και βαθιάς μάθησης που έφεραν την καλύτερη απόδοση στα δύο προβλήματα.

Είδος Κλάσεων	Μοντέλο	Accuracy	Weighted Average (%)		Macro Average (%)	
			Precision	F_1 score	Precision	F_1 score
Attack Type	XGBoost	98.01	97.94	97.96	96.86	96.27
	BERT	98.77	98.98	98.81	96.86	97.56
Event Type	SGD	99.05	99.02	99.03	97.26	96.82
	BERT	99.27	99.29	99.27	97.14	97.51

Πίνακας 8.4: Αποτελέσματα των Καλύτερων ML και DL Μοντέλων στην Πολυταξική Κατηγοριοποίηση του Συνδυαστικού Συνόλου Δεδομένων A. Alzu'bi et al. [5]

Η απόδοση κάθε μοντέλου είναι εξαιρετική και ιδιαίτερα του μοντέλου BERT όπου ξεπέρασε όλα τα μοντέλα της εργασίας.

8.3 Σχετικές Εργασίες για Κατηγοριοποίηση Ροών Δικτυακών Πακέτων

IoT-23

Alia Ahli et al.

Οι Alia Ahli et al. στην εργασία τους [3] πραγματοποιούν και δυαδική και πολυταξική κατηγοριοποίηση στο σύνολο δεδομένων IoT-23 [24], χρησιμοποιώντας τρεις αλγόριθμους μηχανικής μάθησης. Μελετούνται οι αλγόριθμοι των Τυχαίων Δασών, Πολυεπίπεδου Αντίληπτρου και Gradient Boosting [23]. Στο πρόβλημα της δυαδικής κατηγοριοποίησης τα προτεινόμενα μοντέλα τους πετυχαίνουν τις παρακάτω αποδόσεις στον πίνακα 8.5

Μοντέλο	Accuracy (%)	Precision (%)	Recall (%)	F_1 score (%)
Random Forest	98.6	99	99	99
MLP	87.2	88	99	93
Gradient Boosting	97.72	99	98	98

Πίνακας 8.5: Δυαδική Κατηγοριοποίηση Προτεινόμενων Μοντέλων στο IoT-23 Σύνολο Δεδομένων (Alia Ahli et al.) [3]

Στη δυαδική κατηγοριοποίηση στο IoT-23 οι ερευνητές πέτυχαν Ορθότητα ίση με 98.6% στο καλύτερο τους μοντέλο έναντι 98.15% του προτεινόμενου μοντέλου (πίνακας 6.8) δηλαδή οριακά ίδια. Δεν διευκρινίζεται εάν οι τιμές της Ακρίβειας, Ανάκλησης και F_1 μετρικής του πίνακα 8.5 αφορούν την κακόβουλη κλάση ή είναι averaged, αλλά σε κάθε περίπτωση είναι

οριακά ίσες (όλες στο 99%) με τα αποτελέσματα του προτεινόμενου μοντέλου σύμφωνα με τον πίνακα 6.8.

Ενώ στο πρόβλημα της πολυταξικής κατηγοριοποίησης προέκυψαν τα αποτελέσματα του πίνακα 8.6

Μοντέλο	Accuracy (%)	Precision (%)	Recall (%)	F_1 score (%)
Random Forest	98.34	98	98	98
MLP	70.1	70	70	70
Gradient Boosting	97.9	98	98	98

Πίνακας 8.6: Πολυταξική Κατηγοριοποίηση Προτεινόμενων Μοντέλων στο IoT-23 Σύνολο Δεδομένων (Alia Ahli et al.) [3]

Στην πολυταξική κατηγοριοποίηση, τα μοντέλα που είχαν τα καλύτερα αποτελέσματα ήταν ο Random Forest και ο Gradient Boosting οριακά ισοδύναμα με ορθότητα γύρω στο 98% και F_1 μετρική ίση με 98% και στα δύο μοντέλα. Δεν διευκρινίζεται αν τα παραπάνω αποτελέσματα είναι Macro ή Weighted Averaged ωστόσο η απόδοση τους παραμένει υψηλή συγκρίσιμη με τα αποτελέσματα του μοντέλου αυτής της εργασίας σύμφωνα με τους πίνακες 6.9, 6.10, 6.11, 6.12 και 6.13.

Nada Abdalgawa et al.

Οι Nada Abdalgawa et al. στην εργασία τους [2] προτείνουν μία καινοτόμα προσέγγιση στην κατηγοριοποίηση ροών δικτυακών πακέτων στο σύνολο δεδομένων IoT-23 [24] συνδυάζοντας κλασσικά μοντέλα μηχανικής μάθησης και γεννητικά νευρωνικά δίκτυα όπως τους Αντιπαλικούς Αυτοκωδικοποιητές (Adversarial Autoencoders) [43] καθώς και τα Αμφίδρομα Γεννητικά Αντιπαλικά Δίκτυα (Bidirectional Generative Adversarial Networks) [18]. Συγκεκριμένα, προχώρησαν στην πολυταξική κατηγοριοποίηση των ροών του συνόλου δεδομένων και παρήγαγαν τα ακόλουθα αποτελέσματα

Κλάση	Precision (%)	Recall (%)	F_1 score (%)
Benign	99	99	99
DDoS	100	100	100
C&C-HeartBeat-Attack	99	100	99
C&C-PartOfAHorizontalPortScan	94	93	93
C&C-HeartBeat	93	93	93
PartOfAHorizontalPortScan	99	99	99
Okiru	98	98	98
Attack	100	100	100
C&C	96	96	96

Πίνακας 8.7: Πολυταξική Κατηγοριοποίηση του Μοντέλου AAE-KNN στο IoT-23 Σύνολο Δεδομένων [2] (Nada Abdalgawa et al.)

Κλάση	Precision (%)	Recall (%)	F_1 score (%)
Benign	99	99	99
DDoS	100	100	100
C&C-HeartBeat-Attack	100	99	99
C&C-PartOfAHorizontalPortScan	94	92	93
C&C-HeartBeat	93	93	93
PartOfAHorizontalPortScan	99	99	99
Okiru	98	98	98
Attack	100	100	100
C&C	96	95	96

Πίνακας 8.8: Πολυταξική Κατηγοριοποίηση του Μοντέλου BiGAN-KNN στο IoT-23 Σύνολο Δεδομένων [2] (Nada Abdalgawa et al.)

Τα δύο προτεινόμενα μοντέλα των ερευνητών πέτυχαν εξαιρετική απόδοση σε όλες τις κλάσεις του συνόλου δεδομένων. Τα μοντέλα των ερευνητών και το προτεινόμενο μοντέλο αυτής της εργασίας διαφέρουν στις κλάσεις που χρησιμοποιούν για την πολυταξική κατηγοριοποίηση μιας και το προτεινόμενο μοντέλο μελετά μόνο τις κλάσεις Benign, DDoS, PartOfAHorizontalPortScan, Okiru ενώ οι κλάσεις C&C έχουν συγχωνευτεί σε μία. Έτσι, η σύγκριση γίνεται μόνο στις κοινές κλάσεις.

Παρατηρώντας τις F_1 μετρικές των μοντέλων, βλέπουμε ότι το μοντέλο αυτής της διπλωματικής πετυχαίνει τιμή για την κλάση DDoS ίση με 99.89% (πίνακας 6.10) έναντι των δύο μοντέλων των ερευνητών που πέτυχαν τέλεια κατηγοριοποίηση (100%), δηλαδή οριακά ισοδύναμη. Στην κλάση Okiru, το προτεινόμενο μοντέλο προβλέπει σωστά όλα τα δείγματα του συνόλου ελέγχου με F_1 μετρική ίση με 100% (πίνακας 6.11) έναντι των μοντέλων των ερευνητών (98% και στα δύο μοντέλα). Στην κλάση PartOfAHorizontalPortScan, τα μοντέλα των ερευνητών ξεπέρασαν για λίγο το μοντέλο της διπλωματικής αυτής με τιμές 99% και τα δύο έναντι 98.3% (πίνακας 6.12). Στην κλάση C&C (Command and Control) το προτεινόμενο μοντέλο πέτυχε F_1 μετρική ίση με 99.3% σύμφωνα με τον πίνακα 6.13, ξεπερνώντας τα μοντέλα των ερευνητών που ήταν στο 96%.

Edge-IIoTset

Mohamed Amine Ferrag et al.

Στην εργασία [21] των Mohamed Amine Ferrag et al. προτείνεται μία τεχνική μετατροπής ροών δικτυακών πακέτων σε μία κειμενική μορφή ώστε να μπορούν να χρησιμοποιηθούν από ένα γλωσσικό μοντέλο και να κατηγοριοποιηθούν αντιστοίχως. Συγκεκριμένα, σε αυτή την εργασία μελετήθηκε η πολυταξική κατηγοριοποίηση σε όλα τα είδη επιθέσεων που περιγράφονται στον πίνακα 5.3 στο κεφάλαιο 5. Η κατηγοριοποίηση αυτή διαφέρει από την προσέγγιση που ακολουθήθηκε σε αυτή την διπλωματική εργασία όπου ομαδοποιήθηκαν τα δείγματα τα οποία ανήκαν στην ίδια κατηγορία επιθέσεων προκειμένου να αντιμετωπιστεί η ανισορροπία στις

κλάσεις του προβλήματος. Στον πίνακα 8.9 φαίνονται οι μετρικές της Ακρίβειας, Ανάκλησης και F_1 για κάθε είδος επίθεσης στο Edge-IIoTset καθώς και της Ορθότητας.

Είδος	Precision (%)	Recall (%)	F_1 score (%)
Normal	100	100	100
TCP DoS	100	100	100
UDP DoS	100	100	100
HTTP DoS	89	99	94
ICMP DoS	100	100	100
Port Scanning	87	100	93
OS Fingerprinting	0	0	0
Vulnerability Scanning	100	94	97
XSS	94	76	84
SQL Injection	85	83	84
Upload	79	86	83
Backdoor	82	94	87
Password	85	81	83
Ransomware	100	40	57
Accuracy (%)	98.2		

Πίνακας 8.9: Πολυταξική Κατηγοριοποίηση του Μοντέλου securityBERT (Mohamed Amine Ferrag et al.) στο Edge-IIoTset Σύνολο Δεδομένων [21]

Το προτεινόμενο μοντέλο των Mohamed Amine Ferrag et al. παρουσιάζει εξαιρετική τιμή ορθότητας στο 98.2% συγκρίσιμη με την ορθότητα του προτεινόμενου μοντέλου στον πίνακα 6.3 ίση με 98.86%.

Mohamed Amine Ferrag, Othmane Friha et al.

Η εργασία των Mohamed Amine Ferrag, Othmane Friha et al. [20] είναι η εργασία όπου παρουσιάζεται το σύνολο δεδομένων Edge-IIoTset. Στο πλαίσιο της, εκτός από τη δομή του συνόλου δεδομένων δηλαδή το πλήθος των εγγράφων του, την κατανομή τους στις κλάσεις εξόδου, τα χαρακτηριστικά των δειγμάτων του καθώς και την μεθοδολογία που ακολουθήθηκε για να παραχθούν και να συλλεχθούν τα πακέτα, οι δημιουργοί πραγματοποίησαν πειραματική αξιολόγηση διάφορων τεχνικών μηχανικής μάθησης σε διάφορες συνθήκες (κεντριοποιημένη και ομοσπονδιακή μάθηση) αλλά και με διαφορετικές παραδοχές. Συγκεκριμένα, έχει μελετηθεί η περίπτωση της δυαδικής κατηγοριοποίησης και δύο είδη πολυταξικής, η μία με βάση την κατηγορία επίθεσης και η άλλη με βάση το είδος της. Ωστόσο, επειδή η έκδοση του συνόλου δεδομένων που χρησιμοποιήθηκε σε αυτή την διπλωματική εργασία διέθετε ελάχιστο αριθμό δειγμάτων σε ορισμένες κλάσεις και αποφασίστηκε να γίνει κατηγοριοποίηση μόνο ανά κατηγορία επιθέσεων, θα παρουσιαστούν μόνο τα αποτελέσματα τους για την δυαδική και την πολυταξική σε κατηγορίες επιθέσεων κατηγοριοποίηση.

Στον πίνακα 8.10 παρουσιάζονται τα αποτελέσματα των ερευνητών για την δυαδική κατηγοριοποίηση των ροών στο σύνολο δεδομένων ταξινομώντας τις ροές σε καλοήθειες ή κακόβουλες.

	DNN	Random Forest	Decision Tree	SVM	K-NN
Accuracy (%)	99.99	99.99	99.98	99.99	99.99

Πίνακας 8.10: Δυαδική Κατηγοριοποίηση στο Edge-IIoTset (Mohamed Amine Ferrag, Othmane Friha et al.) [20]

Η τιμή της Ορθότητας των μοντέλων που μελέτησαν οι Mohamed Amine Ferrag, Othmane Friha et al.) είναι πολύ υψηλή (99.99%) και συγκρίσιμη με την τιμή του προτεινόμενου μοντέλου αυτής της διπλωματικής εργασίας (99.97%) που φαίνεται στον πίνακα 6.2.

Στους πίνακες 8.11, 8.12, 8.13, 8.14 και 8.15 παρουσιάζονται τα αποτελέσματα των δημιουργών για την πολυταξική κατηγοριοποίηση ανά κατηγορία επίθεσης.

	DNN	Random Forest	Decision Tree	SVM	K-NN
Accuracy (%)	96.01	82.9	77.9	85.62	83.39
Precision (%)	100	100	100	100	100
Recall (%)	100	100	100	100	100
F_1 score (%)	100	100	100	100	100

Πίνακας 8.11: Μετρικές για την Κλάση Benign [20]

	DNN	Random Forest	Decision Tree	SVM	K-NN
Accuracy (%)	96.01	82.9	77.9	85.62	83.39
Precision (%)	92	98	73	96	88
Recall (%)	99	83	92	83	90
F_1 score (%)	95	90	81	89	89

Πίνακας 8.12: Μετρικές για την Κλάση DDoS [20]

	DNN	Random Forest	Decision Tree	SVM	K-NN
Accuracy (%)	96.01	82.9	77.9	85.62	83.39
Precision (%)	66	67	61	67	63
Recall (%)	90	82	57	91	86
F_1 score (%)	76	74	59	77	73

Πίνακας 8.13: Μετρικές για την Κλάση Injection [20]

	DNN	Random Forest	Decision Tree	SVM	K-NN
Accuracy (%)	96.01	82.9	77.9	85.62	83.39
Precision (%)	97	73	85	97	93
Recall (%)	48	72	69	68	73
F_1 score (%)	64	73	76	80	82

Πίνακας 8.14: Μετρικές για την Κλάση Malware [20]

	DNN	Random Forest	Decision Tree	SVM	K-NN
Accuracy (%)	96.01	82.9	77.9	85.62	83.39
Precision (%)	96	76	82	74	82
Recall (%)	74	80	62	92	58
F_1 score (%)	84	78	71	82	68

Πίνακας 8.15: Μετρικές για την Κλάση Information Gathering [20]

Συγκρίνοντας τα αποτελέσματα της πολυταξικής κατηγοριοποίησης σε κατηγορίες επιθέσεων των δημιουργών παρατηρείται ότι το προτεινόμενο μοντέλο αυτής της διπλωματικής εργασίας ξεπερνά σε Ορθότητα όλα τα μοντέλα των δημιουργών με τιμή 98.86% (πίνακας 6.3) έναντι 96.01% του καλύτερου τους μοντέλου τα βαθιά νευρωνικά δίκτυα. Στην κλάση DDoS το μοντέλο αυτής της εργασίας πέτυχε F_1 μετρική ίση με 97.6% (6.4) έναντι 95% του καλύτερου μοντέλου των δημιουργών. Στην κλάση Injection το καλύτερο μοντέλο τους (SVM) πέτυχε τιμή F_1 ίση με 77% έναντι 92% (πίνακας 6.5) του προτεινόμενου μοντέλου. Στις κλάσεις Malware και Information Gathering το προτεινόμενο μοντέλο είχε F_1 τιμές 94% και 98.2% (πίνακες 6.6 και 6.7) αντίστοιχα έναντι του K-NN 82% και 84% των βαθιών νευρωνικών δικτύων αντίστοιχα. Το προτεινόμενο μοντέλο αποδίδει συνολικά καλύτερα γεγονόσ που οφείλεται εν μέρει σε πιθανώς καλύτερη προεπεξεργασία.

Κεφάλαιο 9

Επίλογος

Σε αυτό το κεφάλαιο παρατίθενται τα συμπεράσματα των πειραμάτων που διεξήχθησαν στο πλαίσιο αυτής της εργασίας. Αρχικά, παρουσιάζονται τα συμπεράσματα για κάθε πείραμα σε κάθε σύνολο δεδομένων. Έπειτα παρατίθενται τα συμπεράσματα που προέκυψαν από την εφαρμογή των τεχνικών εξηγήσιμης τεχνητής νοημοσύνης στα προτεινόμενα μοντέλα των πειραμάτων. Τέλος προτείνονται κάποιες ιδέες με σκοπό τη βελτίωση των προτεινόμενων μοντέλων, τόσο στην απόδοση όσο και στην βελτιστοποίηση τους.

9.1 Συμπεράσματα για Ανίχνευση Ανωμαλιών σε Αρχεία Καταγραφής Εφαρμογών

Στο πρόβλημα της ανίχνευσης ανωμαλιών επάνω σε αρχεία καταγραφής εφαρμογών η απόδοση των γλωσσικών μοντέλων κωδικοποιητών είναι πολύ καλή σύμφωνα με τον πίνακα 6.1. Σχεδόν όλες οι μετρικές υπερβαίνουν το 99% με εξαίρεση την ανάκληση της κλάσης Ανωμαλιών που κυμαίνονταν από 95.6% έως 99.6%. Συμπεραίνεται η εξαιρετική ικανότητα των γλωσσικών μοντέλων τύπου BERT να ανιχνεύουν ανωμαλίες σε αρχεία καταγραφής. Η συγκριτικά μειωμένη απόδοση του DistilBERT σε σχέση με το καλύτερο μοντέλο, το RoBERTa, μπορεί να θεωρηθεί αποδεκτή, ακόμα και ελκυστική μιας και με μία μικρή έκπτωση στην ανάκληση το μοντέλο έχει σημαντικά λιγότερες απαιτήσεις σε μνήμη και είναι γρηγορότερο στην εκπαίδευση και αξιολόγηση του.

9.2 Συμπεράσματα για Κατηγοριοποίηση Ροών Δικτυακών Πακέτων

9.2.1 Δυαδική Κατηγοριοποίηση

Στο πρόβλημα της δυαδικής κατηγοριοποίησης ροών δικτυακών πακέτων σε καλοήθειες ή κακόβουλες, το προτεινόμενο μοντέλο παρουσιάζει εξαιρετική απόδοση και στα δύο σύνολα δεδομένων. Αναδεικνύεται η ικανότητα της προτεινόμενης προσέγγισης μετατροπής ροών δικτυακών πακέτων σε κείμενα σε συνδυασμό με ένα γλωσσικό μοντέλο τύπου κωδικοποιητή να

ανιχνεύει την ύπαρξη ή μη μίας κυβερνοεπίθεσης. Παρά την ανισορροπία στις κλάσεις εξόδου η αρχιτεκτονική του προτεινόμενου μοντέλου είναι ικανή να την χειρίζεται απόδοτικά χωρίς ιδιαίτερες εκπτώσεις στην απόδοση.

9.2.2 Πολυταξική Κατηγοριοποίηση

IoT-23

Όσον αφορά την πολυταξική κατηγοριοποίηση ροών στο σύνολο δεδομένων IoT-23, το προτεινόμενο μοντέλο παρουσιάζει εξαιρετική απόδοση προβλέποντας σωστά σχεδόν όλα τα δείγματα του συνόλου ελέγχου με ορθότητα στο 98.14%. Το DistilBERT ξεπερνά σε απόδοση τους αλγορίθμους των Τυχαίων Δασών, του Δέντρου Αποφάσεων και του Πολυεπίπεδου Αντίληπτρου, ενώ στις περισσότερες κλάσεις η απόδοση του είναι περίπου ισοδύναμη με τον XGBoost. Στην κλάση με τα λιγότερα δείγματα την Okiru το προτεινόμενο μοντέλο πρόβλεψε σωστά όλα τα δείγματα της. Ωστόσο, αναφέρεται με επιφύλαξη γιατί ο αριθμός των δειγμάτων αυτής της κλάσης στο σύνολο ελέγχου ήταν σχετικά μικρός. Ωστόσο, ολικά διακρίνεται η ικανότητα του προτεινόμενου μοντέλου να ξεχωρίζει τις κακόβουλες ροές σε διαφορετικά είδη επιθέσεων.

Edge-IIoTset

Στο πρόβλημα της πολυταξικής κατηγοριοποίησης στο Edge-IIoTset σύνολο δεδομένων, το προτεινόμενο μοντέλο είναι ικανό να προβλέψει σωστά τη συντριπτική πλειοψηφία των δειγμάτων του συνόλου ελέγχου πετυχαίνοντας τιμή ορθότητας στο 98.86%. Μελετώντας τις τιμές ακρίβειας για κάθε κλάση ξεχωριστά, αυτές κυμαίνονται μεταξύ 87.6% και 99.98% ανάλογα την κλάση. Αυτό δείχνει έναν ελαφρώς παραπάνω αριθμό ψευδώς θετικών δειγμάτων για την κλάση Injection. Ωστόσο, εφόσον σε ζητήματα κυβερνοασφάλειας δίνεται παραπάνω βαρύτητα στην ανάκληση, η ελαφρώς μειωμένη τιμή της ακρίβειας για αυτή την κλάση μπορεί να θεωρηθεί αποδεκτή. Οι τιμές της ανάκλησης για κάθε κλάση κυμαίνονται μεταξύ 91% για την κλάση Malware και 99.97% για την Benign κλάση. Ακόμα και για την κλάση Malware το προτεινόμενο μοντέλο κατηγοριοποιεί σωστά πάνω από το 90% των δειγμάτων της οπότε συμπεραίνεται η πολύ καλή ικανότητα του προτεινόμενου μοντέλου να κατηγοριοποιεί σωστά διάφορα είδη επιθέσεων.

9.3 Συμπεράσματα Τεχνικών Εξηγήσιμης Τεχνητής Νοημοσύνης

Γενικά Πορίσματα

Από την εφαρμογή των τεχνικών εξηγησιμότητας SHAP και Integrated Gradients στο πρόβλημα ταξινόμησης ροών από το DistilBERT, η SHAP υπερτερεί της Integrated Gradients έχοντας ταυτόχρονα υψηλότερη τιμή Comprehensiveness και συνάμα χαμηλότερη τιμή Sufficiency. Οπότε η SHAP θεωρείται ικανότερη στο να εξηγή τις προβλέψεις του DistilBERT και

στα δύο σύνολα δεδομένων Edge-IoTset και IoT-23, σε όλα τα είδη κατηγοριοποίησης. Το κύριο μειονέκτημα αυτής της μεθόδου είναι το γεγονός πως είναι ιδιαίτερα αργή σε σύγκριση με την Integrated Gradients, οπότε εάν είναι επιθυμητή μία μικρή έκπτωση στην ποιότητα των εξηγήσεων με αντάλλαγμα γρηγορότερους υπολογισμούς, η δεύτερη ίσως αποτελεί καλύτερη επιλογή.

Και οι δύο τεχνικές και στα δύο προβλήματα, πέτυχαν τιμές Tau Correlation Leave One Out μεταξύ 0 και 0.1 που σε συνδυασμό με τις τιμές των προαναφερθέντων μετρικών σημαίνει πως ενώ οι τεχνικές έβρισκαν τα σημαντικά σύμβολα για την κατηγοριοποίηση ήταν λιγότερο ικανές να προσδιορίσουν τα πραγματικά βάρη των συμβόλων. Αυτό θα μπορούσε να εξηγηθεί από το γεγονός ότι στα γλωσσικά μοντέλα, χαρακτηριστικά τα οποία είναι σημαντικά στις προβλέψεις των μοντέλων συνήθως διασπώνται σε υπολέξεις. Κατά τον υπολογισμό των Leave One Out βαθμολογιών, η αφαίρεση μίας υπολέξης ενός χαρακτηριστικού αλλάζει τα συμφραζόμενα του κειμένου λόγω του μηχανισμού προσοχής. Αυτό έχει ως αποτέλεσμα οι υπολέξεις του ίδιου χαρακτηριστικού να έχουν διαφορετικά βάρη στις προβλέψεις. Αντίθετα, η εκάστοτε τεχνική (λ.χ SHAP) υπολογίζει το βάρος κάθε υπολέξης σύμφωνα με την εξίσωση 7.1 δηλαδή τη μέση συνεισφορά της κάθε υπολέξης σε πολλά υποσύνολα χαρακτηριστικών οπότε τα τελικά βάρη των υπολέξεων της ίδιας λέξης καταλήγουν να είναι αρκετά όμοια μεταξύ τους. Πρακτικά, ο υπολογισμός των βαρών των συμβόλων τόσο από τη SHAP όσο και από την Integrated Gradients είναι πολύπλευρος αφού γίνεται μέσω πολλών παραλλαγών της εισόδου (υποσύνολα χαρακτηριστικών ή εισοδοί μέσω παρεμβολής) ενώ ο υπολογισμός των Leave One Out τιμών είναι μονόπλευρος. Οπότε, οι τιμές αυτές θα διαφέρουν αρκετά από τις αντίστοιχες Leave One Out τιμές το οποίο συνεπάγεται χαμηλό συντελεστή συσχέτισης Tau.

Στο πρόβλημα της ανίχνευσης ανωμαλιών στα αρχεία καταγραφής, η μέτρια απόδοση των μετρικών AOPC Comprehensiveness και AOPC Sufficiency οφείλεται στην ανισορροπία των κλάσεων. Η πλειοψηφία των δειγμάτων προς εξήγηση ανήκουν στην κανονική κλάση, όπου δεν υπάρχουν μεμονωμένα σύμβολα με ισχυρή επίδραση στις προβλέψεις του μοντέλου. Οπότε η αφαίρεση των πιο σημαντικών συμβόλων δεν επιφέρει τόσο μεγάλη μείωση στην πρόβλεψη του μοντέλου. Αντιθέτως, στο πρόβλημα της κατηγοριοποίησης ροών είναι γνωστά τα συγκεκριμένα χαρακτηριστικά που έχουν βάρος στις προβλέψεις (οι τιμές των χαρακτηριστικών των ροών κωδικοποιημένες σε κείμενο) και η δομή των κειμένων είναι κοινή, οπότε η αφαίρεση τους επιφέρει μεγάλη μείωση στην απόδοση του μοντέλου.

9.4 Προτάσεις για Μελλοντική Έρευνα και Πιθανές Επεκτάσεις

Ενώ επιστρατεύτηκαν ειδικές τεχνικές στην αρχιτεκτονική των γλωσσικών μοντέλων όπως η LoRa για την επιτάχυνση και την μείωση των υπολογιστικών τους απαιτήσεων, η απόδοση τους θα μπορούσε να βελτιστοποιηθεί περαιτέρω με τεχνικές όπως ο Κβαντισμός (Quantization). Ταυτόχρονα, ενδιαφέρον επίσης θα παρουσίαζε η μελέτη μικρών γλωσσικών μοντέλων με πολύ μικρό αριθμό παραμέτρων σε συνδυασμό με τις παραπάνω τεχνικές βελτιστοποίησης ώστε να συγκριθεί η απόδοσή τους στα ίδια προβλήματα με τα κλασσικά γλωσσικά μοντέλα.

Στο πρόβλημα της ανίχνευσης ανωμαλιών επάνω σε αρχεία καταγραφής εφαρμογών, ακόμη ένα πιθανό πρόβλημα που θα μπορούσε να προκύψει και σε κάποιο άλλο σύνολο δεδομένων εκτός του HDFS είναι το μήκος των κειμένων. Εάν σε κάποιο block αντιστοιχηθούν πολλές εγγραφές, το παραγόμενο κείμενο μπορεί να ξεπεράσει σε αριθμό τα σύμβολα που μπορεί να χειριστεί ένα συνηθισμένο γλωσσικό μοντέλο και έτσι το μοντέλο να αναγκαστεί να περικόψει τα πλεονάζοντα σύμβολα χάνοντας πολύτιμη πληροφορία. Αυτό θα μπορούσε να αντιμετωπιστεί με διάφορους τρόπους όπως με τη χρήση κάποιου γλωσσικού μοντέλου κωδικοποιητή που χειρίζεται εγγενώς περισσότερα σύμβολα σε ένα κείμενο όπως το Longformer [9] ή να τροποποιηθεί κατάλληλα το μητρώο ενσωματώσεων θέσης των μοντέλων τύπου BERT.

Επιπροσθέτως, όσον αφορά το πρόβλημα κατηγοριοποίησης ροών πακέτων σε κλάσεις επιθέσεων, ενδιαφέρον θα παρουσίαζε η μελέτη εναλλακτικών μεθόδων κατασκευής κειμένων από ροές, μέσω τεχνικών Μηχανικής Προτροπών (Prompt Engineering), οι οποίες θα παρέιχαν περεταίρω πληροφορία στο μοντέλο με σκοπό να αυξηθεί η απόδοση του και η κατασκευή τους να απαιτεί λιγότερους πόρους.

Τέλος, ενώ η χρήση τεχνικών εξηγήσιμης τεχνητής νοημοσύνης μπορεί να βοηθήσει σημαντικά έναν υπεύθυνο ασφαλείας, δίνοντας του πληροφορίες για μία κακόβουλη ροή ή μία εγγραφή σε ένα αρχείο καταγραφής, ο υπολογισμός των εξηγήσεων για τα δείγματα γίνεται ακολουθιακά γεγονός που τον καθιστά αργό. Οπότε, υπάρχει η ανάγκη υλοποιήσεων οι οποίες θα παραλληλοποιούν τον παραπάνω υπολογισμό.


Παράρτημα Α΄

Διαγράμματα Σύγκρισης Αποτελεσμάτων Γλωσσικών Μοντέλων

Σε αυτό το παράρτημα, παρατίθενται τα διαγράμματα σύγκρισης των γλωσσικών μοντέλων όλων των πειραμάτων αυτής της εργασίας που προέκυψαν από την αξιολόγηση τους στο σύνολο ελέγχου κάθε πειράματος.


Α'.1 Δυαδική Κατηγοριοποίηση στο HDFS Σύνολο Δεδομένων

Μητρώο Σύγχυσης για το Μοντέλο DistilBERT




Σχήμα Α'.1: Μητρώο Σύγχυσης για το DistilBERT

Μητρώο Σύγκρισης για το Μοντέλο ALBERT




Σχήμα Α.2: Μητρώο Σύγκρισης για το ALBERT

Μητρώο Σύγκρισης για το Μοντέλο BERT




Σχήμα Α'.3: Μητρώο Σύγκρισης για το BERT

Μητρώο Σύγκρισης για το Μοντέλο RoBERTa




Σχήμα Α.4: Μητρώο Σύγκρισης για το RoBERTa

Α'.2 Δυαδική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων




Σχήμα Α'.5: Μητρώο Σύγχυσης για το DistilBERT

Α'.3 Δυαδική Κατηγοριοποίηση στο Edge-IIoTset Σύνολο Δεδομένων




Σχήμα Α'.6: Μητρώο Σύγκρισης για το DistilBERT

Α'.4 Πολυταξική Κατηγοριοποίηση στο IoT-23 Σύνολο Δεδομένων



Σχήμα Α'.7: Μητρώο Σύγκρισης για το DistilBERT

Α'.5 Πολυταξική Κατηγοριοποίηση στο Edge-IIoTset Σύνολο Δεδομένων



Σχήμα Α'.8: Μητρώο Σύγχυσης για το DistilBERT

Παράρτημα Β΄

Πειραματικές Λεπτομέρειες

Β΄.1 Παράμετροι Γλωσσικών Μοντέλων ανά Πρόβλημα

Σε αυτό το παράρτημα, καταγράφονται οι τιμές των παραμέτρων εκπαίδευσης και αξιολόγησης των γλωσσικών μοντέλων ανά κατηγορία πειραμάτων σύμφωνα με τον πίνακα Β΄.1.

Παράμετρος	Ανίχνευση Ανωμαλιών σε Αρχεία Καταγραφής Εφαρμογών	Κατηγοριοποίηση Ροών Δικτυακών Πακέτων
Ρυθμός Μάθησης	$2e - 5$	$2e - 5$
Weight Decay	0.01	0.01
r	7	7
α	14	14
lora dropout	0.1	0.1
Μέγεθος Δέσμης Συνόλου Εκπαίδευσης	16	16
Μέγεθος Δέσμης Συνόλου Ελέγχου	64	64
Εποχές Εκπαίδευσης	3	2
Ποσοστό Δειγμάτων στο Σύνολο Επικύρωσης	10%	10%
Ποσοστό Δειγμάτων στο Σύνολο Ελέγχου	10%	10%

Πίνακας Β΄.1: Παράμετροι Γλωσσικών Μοντέλων

Β'.2 Πηγαίος Κώδικας

Ο πηγαίος κώδικας αυτής της διπλωματικής εργασίας ο οποίος περιλαμβάνει τους κώδικες προεπεξεργασίας των δεδομένων, των μοντέλων που υλοποιήθηκαν καθώς και τους κώδικες για τις τεχνικές εξηγήσιμης τεχνητής νοημοσύνης είναι διαθέσιμος στο ακόλουθο αποθετήριο:

<https://github.com/Vergosss/Thesis>

Βιβλιογραφία

- [1] Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard, Yangqing Jia, Rafal Jozefowicz, Lukasz Kaiser, Manjunath Kudlur, Josh Levenberg, Dandelion Mané, Rajat Monga, Sherry Moore, Derek Murray, Chris Olah, Mike Schuster, Jonathon Shlens, Benoit Steiner, Ilya Sutskever, Kunal Talwar, Paul Tucker, Vincent Vanhoucke, Vijay Vasudevan, Fernanda Viégas, Oriol Vinyals, Pete Warden, Martin Wattenberg, Martin Wicke, Yuan Yu and Xiaoqiang Zheng. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015.
- [2] Nada Abdalgawad, A Sajun, Yara Kaddoura, Imran A Zuolkernan and F Aloul. Generative deep learning to detect cyberattacks for the iot-23 dataset. *IEEE Access*, 10:6430–6441, 2021.
- [3] Alia Ahli, Ayesha Raza, Kevser Ovaz Akpinar and Mustafa Akpinar. Binary and multi-class classification on the iot-23 dataset. Στο *2023 Advances in Science and Engineering Technology International Conferences (ASET)*, σελίδες 1–7. IEEE, 2023.
- [4] Crispin Almodovar, Fariza Sabrina, Sarvnaz Karimi and Salahuddin Azad. Logfit: Log anomaly detection using fine-tuned language models. *IEEE Transactions on Network and Service Management*, 21(2):1715–1723, 2024.
- [5] Ahmad Alzu’bi, Omar Darwish, Amjad Albashayreh and Yahya Tashtoush. Cyberattack event logs classification using deep learning with semantic feature analysis. *Computers & Security*, 150:104222, 2025.
- [6] Jason Ansel, Edward Yang, Horace He, Natalia Gimelshein, Animesh Jain, Michael Voznesensky, Bin Bao, Peter Bell, David Berard, Evgeni Burovski, Geeta Chauhan, Anjali Chourdia, Will Constable, Alban Desmaison, Zachary DeVito, Elias Ellison, Will Feng, Jiong Gong, Michael Gschwind, Brian Hirsh, Sherlock Huang, Kshiteej Kalambarkar, Laurent Kirsch, Michael Lazos, Mario Lezcano, Yanbo Liang, Jason Liang, Yinghai Lu, CK Luk, Bert Maher, Yunjie Pan, Christian Puhersch, Matthias Reso, Mark Saroufim, Marcos Yukio Siraichi, Helen Suk, Michael Suo, Phil Tillet, Eikan Wang, Xiaodong Wang, William Wen, Shunting Zhang, Xu Zhao, Keren Zhou,

- Richard Zou, Ajit Mathews, Gregory Chanan, Peng Wu and Soumith Chintala. Pytorch 2: Faster machine learning through dynamic python bytecode transformation and graph compilation. Στο *Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2 (ASPLOS '24)*. ACM, 2024.
- [7] Giuseppe Attanasio, Eliana Pastor, Chiara Di Bonaventura and Debora Nozza. ferret: a framework for benchmarking explainers on transformers. Στο *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. Association for Computational Linguistics, 2023.
- [8] Sebastian Bach, Alexander Binder, Grégoire Montavon, Frederick Klauschen, Klaus Robert Müller and Wojciech Samek. On pixel-wise explanations for non-linear classifier decisions by layer-wise relevance propagation. *PLOS ONE*, 10(7):1–46, 2015.
- [9] Iz Beltagy, Matthew E. Peters and Arman Cohan. Longformer: The long-document transformer, 2020.
- [10] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [11] Leo Breiman, Jerome Friedman, Richard A Olshen and Charles J Stone. *Classification and Regression Trees*. Wadsworth International Group, 1984.
- [12] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever and Dario Amodei. Language models are few-shot learners, 2020.
- [13] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. Στο *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, σελίδες 785–794. ACM, 2016.
- [14] Kyunghyun Cho, Bartvan Merriënboer, Dzmitry Bahdanau and Yoshua Bengio. On the properties of neural machine translation: Encoder–decoder approaches. Στο *Proceedings of SSST-8, Eighth Workshop on Syntax, Semantics and Structure in Statistical Translation* Dekai Wu, Marine Carpuat, Xavier Carreras and Eva Maria Vecchi, επιμελητές, σελίδες 103–111, Doha, Qatar, 2014. Association for Computational Linguistics.
- [15] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Mach. Learn.*, 20(3):273–297, 1995.

- [16] Jacob Devlin, Ming Wei Chang, Kenton Lee and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding, 2019.
- [17] Jay DeYoung, Sarthak Jain, Nazneen Fatema Rajani, Eric Lehman, Caiming Xiong, Richard Socher and Byron C. Wallace. ERASER: A benchmark to evaluate rationalized NLP models. Στο *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* Dan Jurafsky, Joyce Chai, Natalie Schluter and Joel Tetreault, επιμελητές, σελίδες 4443–4458, Online, 2020. Association for Computational Linguistics.
- [18] Jeff Donahue, Philipp Krähenbühl and Trevor Darrell. Adversarial feature learning, 2017.
- [19] Kemal Erdem. Measuring xai methods with infidelity and sensitivity. <https://erdem.pl>, 2021.
- [20] Mohamed Amine Ferrag, Othmane Friha, Djallel Hamouda, Leandros Maglaras and Helge Janicke. Edge-IIoTset: A new comprehensive realistic cyber security dataset of IoT and IIoT applications for centralized and federated learning. *IEEE Access*, 10:40281–40306, 2022.
- [21] Mohamed Amine Ferrag, Mthandazo Ndhlovu, Norbert Tihanyi, Lucas C. Cordeiro, Merouane Debbah, Thierry Lestable and Narinderjit Singh Thandi. Revolutionizing cyber threat detection with large language models: A privacy-preserving bert-based lightweight model for iot/iiot devices, 2024.
- [22] Evelyn Fix and J. L. Hodges. Discriminatory analysis. nonparametric discrimination: Consistency properties. *International Statistical Review / Revue Internationale de Statistique*, 57(3):238–247, 1989.
- [23] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [24] Sebastian Garcia, Agustin Parmisano and Maria Jose Erquiaga. IoT-23: A labeled dataset with malicious and benign IoT network traffic, 2020.
- [25] Corrado Gini. *Variabilità e mutabilità*. Studio, 1912.
- [26] Frank E. Grubbs. Sample Criteria for Testing Outlying Observations. *The Annals of Mathematical Statistics*, 21(1):27 – 58, 1950.
- [27] Haixuan Guo, Shuhan Yuan and Xintao Wu. Logbert: Log anomaly detection via bert, 2021.
- [28] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel

- J. Smith, Robert Kern, Matti Pícus, Stephan Hoyer, Marten H. van Kerkwijk, Matthew Brett, Allan Haldane, Jaime Fernández del Río, Mark Wiebe, Pearu Peterson, Pierre Gérard-Marchant, Kevin Sheppard, Tyler Reddy, Warren Weckesser, Hameer Abbasi, Christoph Gohlke and Travis E. Oliphant. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020.
- [29] Weiche Hsieh, Ziqian Bi, Chuanqi Jiang, Junyu Liu, Benji Peng, Sen Zhang, Xuanhe Pan, Jiawei Xu, Jinlang Wang, Keyu Chen, Pohsun Feng, Yizhu Wen, Xinyuan Song, Tianyang Wang, Ming Liu, Junjie Yang, Ming Li, Bowen Jing, Jintao Ren, Junhao Song, Hong Ming Tseng, Yichao Zhang, Lawrence K. Q. Yan, Qian Niu, Silin Chen, Yunze Wang and Chia Xin Liang. A comprehensive guide to explainable ai: From classical models to llms, 2024.
- [30] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang and Weizhu Chen. Lora: Low-rank adaptation of large language models, 2021.
- [31] J. D. Hunter. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007.
- [32] M. G. KENDALL. A new measure of rank correlation. *Biometrika*, 30(1-2):81–93, 1938.
- [33] Max Landauer, Florian Skopik, Maximilian Frank, Wolfgang Hotwagner, Markus Wurzenberger and Andreas Rauber. Maintainable log datasets for evaluation of intrusion detection systems. *IEEE Transactions on Dependable and Secure Computing*, 20(4):3466–3482, 2023.
- [34] Max Landauer, Florian Skopik, Markus Wurzenberger, Wolfgang Hotwagner and Andreas Rauber. Have it your way: Generating customized log datasets with a model-driven simulation testbed. *IEEE Transactions on Reliability*, 70(1):402–415, 2021.
- [35] Zhenzhong Lan, Mingda Chen, Sebastian Goodman, Kevin Gimpel, Piyush Sharma and Radu Soricut. Albert: A lite bert for self-supervised learning of language representations, 2020.
- [36] Quentin Lhoest, Albert Villanova del Moral, Yacine Jernite, Abhishek Thakur, Patrick von Platen, Suraj Patil, Julien Chaumond, Mariama Drame, Julien Plu, Lewis Tunstall, Joe Davison, Mario Šaško, Gunjan Chhablani, Bhavitvya Malik, Simon Brandeis, Teven Le Scao, Victor Sanh, Canwen Xu, Nicolas Patry, Angelina McMillan-Major, Philipp Schmid, Sylvain Gugger, Clément Delangue, Théo Matussière, Lysandre Debut, Stas Bekman, Pierric Cistac, Thibault Goehringer, Victor Mustar, François Lagunas, Alexander Rush and Thomas Wolf. Datasets: A community library for natural language processing. Στο *Proceedings of the 2021 Conference*

- on Empirical Methods in Natural Language Processing: System Demonstrations*, σελίδες 175–184, Online and Punta Cana, Dominican Republic, 2021. Association for Computational Linguistics.
- [37] Tsung Yi Lin, Priya Goyal, Ross Girshick, Kaiming He and Piotr Dollár. Focal loss for dense object detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(2):318–327, 2020.
- [38] Fei Tony Liu, Kai Ming Ting and Zhi Hua Zhou. Isolation forest. Στο *2008 Eighth IEEE International Conference on Data Mining*, σελίδες 413–422, 2008.
- [39] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach, 2019.
- [40] Scott Lundberg and Su In Lee. A unified approach to interpreting model predictions, 2017.
- [41] Scott M Lundberg and Su In Lee. A unified approach to interpreting model predictions, 2017.
- [42] Maccdc 2012 dataset. <https://www.netresec.com/?page=MACCDC>, χ.χ.
- [43] Alireza Makhzani, Jonathon Shlens, Navdeep Jaitly, Ian Goodfellow and Brendan Frey. Adversarial autoencoders, 2016.
- [44] Sourab Mangrulkar, Sylvain Gugger, Lysandre Debut, Younes Belkada, Sayak Paul and Benjamin Bossan. PEFT: State-of-the-art parameter-efficient fine-tuning methods. <https://github.com/huggingface/peft>, 2022.
- [45] Christoph Molnar. *Interpretable Machine Learning*. Christoph Molnar, 3η έκδοση, 2025.
- [46] Adam J. Oliner and Jon Stearley. What supercomputers say: A study of five system logs. *Proc. of IEEE/IFIP International Conference on Dependable Systems and Networks (DSN)*, 2007.
- [47] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [48] Charles Pierse. Transformers Interpret, 2021.
- [49] J. R. Quinlan. Induction of decision trees. *Machine Learning*, 1(1):81–106, 1986.
- [50] Nils Reimers and Iryna Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks, 2019.

- [51] Marco Tulio Ribeiro, Sameer Singh and Carlos Guestrin. "why should i trust you?": Explaining the predictions of any classifier, 2016.
- [52] F Rosenblatt. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6):386–408, 1958.
- [53] David E. Rumelhart, Geoffrey E. Hinton and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- [54] Victor Sanh, Lysandre Debut, Julien Chaumond and Thomas Wolf. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter, 2020.
- [55] Bernhard Schölkopf, John C. Platt, John Shawe-Taylor, Alex J. Smola and Robert C. Williamson. Estimating the support of a high-dimensional distribution. *Neural Computation*, 13(7):1443–1471, 2001.
- [56] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, 128(2):336–359, 2019.
- [57] Avanti Shrikumar, Peyton Greenside and Anshul Kundaje. Learning important features through propagating activation differences, 2019.
- [58] W. Stallings and L. Brown. *Computer Security: Principles and Practice*. Pearson Education, 2014.
- [59] Mukund Sundararajan, Ankur Taly and Qiqi Yan. Axiomatic attribution for deep networks, 2017.
- [60] The pandas development team. pandas-dev/pandas: Pandas, 2020.
- [61] Daniel Tovarňák, Stanislav Špaček and Jan Vykopal. Traffic and log data captured during a cyber defense exercise. *Data in Brief*, 31:105784, 2020.
- [62] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser and Illia Polosukhin. Attention is all you need, 2023.
- [63] Michael L. Waskom. seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021, 2021.
- [64] Wes McKinney. Data Structures for Statistical Computing in Python. Στο *Proceedings of the 9th Python in Science Conference* Stéfan van der Walt and Jarrod Millman , επιμελητής, σελίδες 56 – 61, 2010.
- [65] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen

- Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest and Alexander M. Rush. Transformers: State-of-the-art natural language processing. Στο *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, σελίδες 38–45, Online, 2020. Association for Computational Linguistics.
- [66] Wei Xu, Ling Huang, Armando Fox, David Patterson and Michael Jordan. Detecting large-scale system problems by mining console logs. *Proc. of the 22nd ACM Symposium on Operating Systems Principles (SOSP)*, 2009.
- [67] Chih Kuan Yeh, Cheng Yu Hsieh, Arun Sai Suggala, David I. Inouye and Pradeep Ravikumar. On the (in)fidelity and sensitivity for explanations, 2019.
- [68] Mingyang Zhang, Jianfei Chen, Jianyi Liu, Jingchu Wang, Rui Shi and Hua Sheng. Logst: Log semi-supervised anomaly detection based on sentence-bert. Στο *2022 7th International Conference on Signal and Image Processing (ICSIP)*, σελίδες 356–361, 2022.
- [69] Yihan Zhou, Yan Chen, Xuanming Rao, Yukang Zhou, Yuxin Li and Chao Hu. Leveraging large language models and bert for log parsing and anomaly detection. *Mathematics*, 12(17), 2024.
- [70] Jieming Zhu, Shilin He, Jinyang Liu and Michael R. Lyu. Loghub: A large collection of system log datasets for ai-driven log analytics. *IEEE International Symposium on Software Reliability Engineering (ISSRE)*, 2023.

Συντομογραφίες - Αρκτικόλεξα - - Ακρωνύμια

βλπ	βλέπε
κ.λπ.	και λοιπά
κ.ο.κ	και ούτω καθεξής
ALBERT	A Lite BERT
AAE	Adversarial Auto Encoder
AIT	Austrian Institute of Technology
AOPC	Area Over the Perturbation Curve
ARP	Address Resolution Protocol
BERT	Bidirectional Encoder Representations from Transformers
BGL	Blue Gene/L
BiGAN	Bidirectional Generative Adversarial Networks
DDoS	Distributed Denial of Service
DeepLIFT	Deep Learning Important FeaTures
DistilBERT	Distilled BERT
DNS	Domain Name System
DoS	Denial of Service
FN	False Negative
FP	False Positive
Grad-CAM	Gradient-weighted Class Activation Mapping
GRU	Gated Recurrent Unit
HDFS	Hadoop Distributed File System
HTTP	Hypertext Transfer Protocol
ICMP	Internet Control Message Protocol
IG	Integrated Gradients
IoT	Internet of Things
IIoT	Industrial Internet of Things
K-NN	K-Nearest Neighbors
LIME	Local Interpretable Model-agnostic Explanations
LoRa	Low Rank Adaptation
LRP	Layer-wise Relevance Propagation

MACCDC	Mid-Atlantic Collegiate Cyber Defense Competition
MLP	Multilayer Perceptron
MQTT	Message Queuing Telemetry Transport
OS	Operating System
OSI	Open Systems Interconnection
RoBERTa	Robustly Optimized BERT Pretraining Approach
SGD	Stochastic Gradient Descent
SHAP	SHapley's Additive explanations
SQL	Structured Query Language
SVM	Support Vector Machine
TCP	Transfer Control Protocol
TN	True Negative
TP	True Positive
UDP	User Datagram Protocol
XAI	Explainable Artificial Intelligence
XGBoost	eXtreme Gradient Boosting
XSS	Cross Site Scripting

Απόδοση ξενόγλωσσων όρων

Απόδοση

ακρίβεια
ανάκληση
αναξιοπιστία
ανίχνευση ανωμαλιών
αποκωδικοποιητής
απόσταξη
αρχείο καταγραφής
διαρροή δεδομένων
διασταυρούμενη επικύρωση
δέντρο απόφασης
έγχυση
ενσωμάτωση
ενσωμάτωση θέσης
ενσωμάτωση συμβόλου
ενσωμάτωση τμήματος
εξηγήσιμη τεχνητή νοημοσύνη
επάρκεια
εποχή εκπαίδευσης
ευαισθησία
εστιακή συνάρτηση σφάλματος
ιός
κακόβουλος
κακόβουλο λογισμικό
καλοήθης
καλούπι
κατάντη εργασία
κατηγορική διασταυρούμενη εντροπία
κβαντισμός
κυβερνοασφάλεια
κυβερνοεπίθεση
κωδικοποιητής

Ξενόγλωσσος όρος

precision
recall
infidelity
anomaly detection
decoder
distillation
log file
data leakage
cross validation
decision tree
injection
embedding
position embedding
token embedding
segment embedding
explainable artificial intelligence
sufficiency
training epoch
sensitivity
focal loss function
virus
malicious
malware
benign
template
downstream task
categorical cross entropy
quantization
cybersecurity
cyberattack
encoder

λογισμικό κατασκοπείας	spyware
λυτρισμικό	ransomware
μεγάλο γλωσσικό μοντέλο	large language model
μέγεθος δέσμης	batch size
μετασχηματιστής	transformer
μητρώο σύγχυσης	confusion matrix
μηχανική προτροπών	prompt engineering
ογκομετρική	volumetric
ορθότητα	accuracy
πακέτο	packet
παλινδρόμηση	regression
πιστότητα	faithfulness
πληρότητα	comprehensiveness
πολυεπίπεδο αντίληπτο	multilayer perceptron
προσαρμογή	fine-tuning
προσαρμογή χαμηλής τάξης	low rank adaptation
ροή	flow
ρυθμός μάθησης	learning rate
σάρωση δικτύου	network scanning
σάρωση ευπαθειών	vulnerability scanning
σάρωση θυρών	port scanning
σκουλήχι	worm
συλλογή πληροφοριών	information gathering
σύνολο εκπαίδευσης	training set
σύνολο ελέγχου	test set
σύνολο επικύρωσης	validation set
τυχαίο δάσος	random forest
υπερπροσαρμογή	overfitting
χρονοσφραγίδα	timestamp
μηχανισμός αυτοπροσοχής πολλαπλών κεφαλών	multi-head self-attention mechanism





ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙ-
ΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Χρήση Μεγάλων Γλωσσικών Μοντέλων στην
Ανίχνευση Κυβερνοεπιθέσεων

Γεώργιος Π. Βέργος

ΠΑΤΡΑ
ΣΕΠΤΕΜΒΡΙΟΣ 2025



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙ-
ΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Χρήση Μεγάλων Γλωσσικών Μοντέλων στην
Ανίχνευση Κυβερνοεπιθέσεων

Γεώργιος Π. Βέργος

ΠΑΤΡΑ
ΣΕΠΤΕΜΒΡΙΟΣ 2025

